

ESF Woche 1 — Grundlagen & Qualitativ

Lesen + Übungen am Ende jedes Abschnitts. In deinem Tempo.

Was ist empirische Sozialforschung (ESF)?

Definition:

„Empirische Forschung ist die systematische Erfassung und Deutung sozialer/gesundheitsbezogener Tatbestände.“ (Brosius et al., 2008)

Die Definition hat drei unverzichtbare Säulen:

Komponente	Bedeutung
Systematisches Erfassen	Methodisch geplante Datenerhebung (nicht: Zufall oder Bauchgefühl)
Tatbestände	Überprüfung von Theorien/Hypothesen über menschliches Verhalten
Deutung	Analyse & Interpretation der Daten für Erkenntnisgewinn

■■ Prüfungsfalle: Die Gala-Umfrage

„Soll Heidi Klum sich scheiden lassen?“

Ist das ESF?

- ✓ Erfasst? Ja (Befragung)
- ✗ Tatbestände? Nein (private Meinung, keine überprüfbare Theorie)
- ✗ Deutung? Ja, aber zwecklos (keine wissenschaftliche Erkenntnis)

→ **NEIN. Das ist Gossip, keine Forschung.**

Abgrenzung: Alltag vs. Wissenschaft

Empirisch vorzugehen heißt:

- **Sammeln** von Erfahrung über die Realität
- **Systematisieren** der Erfahrung
- **Dokumentieren** → *Intersubjektivität*: nachvollziehbar, wiederholbar, überprüfbar durch andere
- **Zuverlässigkeit & Gültigkeit** gewährleisten

Die Alltagsbefragung endet mit Meinungen. Die wissenschaftliche Forschung endet mit überprüfbarem Wissen.

Theorie & Hypothese – Das Rückgrat der Forschung

Theorie

Netzwerk von **bewährten Hypothesen** und **empirischen Gesetzmäßigkeiten**, die Sachverhalte beschreiben, erklären, vorhersagen.

Beispiel PT:

Gleichgewichtstraining → verbesserte Muskelkraft + Propriozeption → schnellere Reaktionen → bessere Gleichgewichtsfähigkeit → weniger Stürze

Eigenschaften einer guten Theorie:

- Logisch konsistent
- Falsifizierbar (nicht tautologisch)
- Allgemeingültig
- Einfach
- Überprüfbar

Hypothese

Provisorische Antwort auf eine wissenschaftliche Frage.

Bedingungen für wissenschaftliche Hypothesen:

Kriterium	Beispiel: ✓	Beispiel: ✗
Konditionalsatz	„Wenn Patienten weniger schlafen, dann haben sie mehr Schmerzen“	„Schlafen ist wichtig“
Empirisch überprüfbar	Messbar (Schlafdauer, Schmerzskala)	„Im Himmel ist es friedlicher“
Allgemeingültig	Gilt für Population, nicht nur eine Person	„Herr Müller braucht PT“
Falsifizierbar	Kann widerlegt werden	„PT hilft oder auch nicht“
Operationalisierbar	Variablen klar definiert	Vage Begriffe

■ ■ **Häufiger Fehler:** „Vielleicht hilft PT“ – Das ist falsifizierbar! (Wenn „vielleicht“ raus, wird's wissenschaftlich.)

Deduktion vs. Induktion – Der Kreislauf

Deduktion: Allgemein → Einzelfall

→ Theorie besagt: „Alle Therapien mit Evidenz wirken“

→ Diese PT hat Evidenz

→ Also: Diese PT wirkt

Induktion: Einzelfall → Allgemein

→ In einer Studie mit 50 Patienten wirkt PT

→ Also: PT wirkt in der Grundgesamtheit

Zusammenhang (Zyklus):

1. Theorie → Hypothese aufstellen (deduktiv)

2. Empirie → Daten sammeln

3. Daten können Theorie **bestätigen**, **widerlegen** oder **modifizieren**

4. Neue Theorie entsteht (induktiv)

Quantitativ vs. Qualitativ

Aspekt	Quantitativ	Qualitativ
Datenform	Zahlen (numerisch)	Text, Beschreibungen
Theorie-Rolle	Hypothesen testen (deduktiv)	Hypothesen entwickeln (induktiv)
Messung	Standardisiert, objektiv	Offen, interpretativ
Stichprobe	Groß, repräsentativ	Klein, fokussiert
Ziel	Ursachen erklären (Kausalität)	Sinnverstehen (Subjektivität)
Beispiele PT	RCT, Fragebogenstudien	Expert:inneninterviews, Beobachtungen

Verifikation & Falsifikation – Die Wahrheit ist relativ

■ Verifikation (Popper-Kritik):

Man kann eine Theorie nicht durch empirische Studien beweisen. Warum? Weil man nicht *alle* Fälle untersuchen kann.

■ Falsifikation ist auch problematisch:

Nur weil eine Studie zeigt, dass PT nicht hilft, bedeutet das nicht, dass die Theorie falsch ist. (Vielleicht waren nur ungünstige Patienten in der Stichprobe.)

✓ **Lösung: H_0 & H_1 (Statistische Hypothesen)**

- H_0 (Nullhypothese): „PT hilft NICHT in der Grundgesamtheit“
 - H_1 (Alternativhypothese): „PT hilft in der Grundgesamtheit“
 - Daten → p-Wert → Entscheidung: Für H_0 oder H_1 ?
 - Ab $p < 0,05$ sprechen wir uns gegen H_0 aus (nicht „PT wirkt sicher!“).
-

Physiotherapie & Ergotherapie im Fokus

Forschungsbereiche:

- Wirksamkeit von Interventionen (Schmerz, Mobilität, Funktion)
 - Gesundheitsverhalten von Patient:innen
 - Berufszufriedenheit von Therapeut:innen
 - Prävention und Risikofaktoren
-

Lernkontrolle: Erklär's zurück!

Szenario: Ein Kollege sagt dir: „*Ich habe 10 Patienten mit Rückenschmerz tratiert. 8 sind schmerzfrei geworden. Also wirkt meine Methode!*“

Fragen:

1. Ist das ESF? (Begründe mit den 3 Komponenten.)
 2. Was ist der wissenschaftliche Fehler? (Hinweis: Stichprobe, Falsifikation)
 3. Wie würde eine wissenschaftliche Hypothese dazu lauten?
-

Übungen

3 ÜBUNGSAUFGABEN – Kapitel 1: Grundlagen der Empirischen Sozialforschung

■ ÜBUNG 1 (EINSTIEG) – Zuordnung & Begriffe

Aufgabe: Zuordnung – Ist das empirische Sozialforschung?

Ordne die folgenden Szenarien den Kriterien der ESF zu. Schreibe für jedes Szenario:

- **Systematisch erfasst?** (Ja/Nein)
- **Tatbestände überprüft?** (Ja/Nein)
- **Deutung/Erkenntnis?** (Ja/Nein)
- **Fazit: ESF ja/nein?**

Szenario	ETatb	Deut	ESF?
A) Ein PT fragt 30 Patienten nach ihrer Schmerzsituation vor/nach 8 Wochen Training mit standardisiertem Fragebogen. Die Ergebnisse zeigen im Mittel 40% Schmerzreduktion.			
B) In einer Arztpraxis fällt auf: „Patienten, die viel trainieren, haben weniger Schmerzen. Das ist einfach so.“			
C) Eine Ergotherapeutin beobachtet 15 Schlaganfallpatienten beim ADL-Training über 6 Wochen, führt Tagebuch, interviewt Angehörige. Frage: Wie verändern sich Alltagskompetenzen während der Therapie?			
D) Eine Gesundheitszeitung schreibt: „Ist Yoga schlecht für Ihre Wirbelsäule?“ und zitiert zufällig 4 Leser:innen, die schlechte Erfahrungen machten.			

■ MUSTERLÖSUNG Übung 1

Szenario	Erfasst?	Tatbestand?	Deutung?	ESF?
A)	✓ Ja (Fragebogen, standardisiert, n=30)	✓ Ja (Schmerz messbar, theoretisches Konstrukt)	✓ Ja (Analyse vor/nach, Erkenntnis über Trainingseffekt)	■ JA

B)	✗ Nein (nur Eindruck, keine systematische Erfassung)	✓ Ja (Training-Schmerz-Beziehung ist Tatbestand)	✗ Nein (keine Beziehung/ziehbarer Deutung, Korrelation ≠ Kausalität nicht belegt)	■ NEIN
C)	✓ Ja (Beobachtung, Tagebuch, Interviews = qualitative Systematik)	✓ Ja (ADL-Kompetenzen = überprüfbarer Tatbestand)	✓ Ja (Prozessanalyse, Sinnverstehen)	■ JA
D)	✗ Nein (4 Zitate = nicht systematisch, Selektionsbias)	■■ Grenzfall (Rückenschmerz ja, aber durch Manipulation der Evidenz nicht richtig adressiert)	✗ Nein (verzerrt, nicht objektiv)	■ NEIN

■■ Häufige Fehler Übung 1

Fehler 1: „B ist ESF, weil man ja Daten hat.“

→ **Korrekt:** Beobachtung ≠ systematische Erfassung. Ohne standardisierte Messung, ohne Kausalitätsprüfung ist es Alltag.

Fehler 2: „C ist nicht ESF, weil es nur 15 Personen sind.“

→ **Korrekt:** Qualitative Forschung braucht keine große Stichprobe. Systematik und Dokumentation machen's wissenschaftlich.

Fehler 3: „D könnte ESF sein, wenn man die 4 Zitate in ein Paper schreibt.“

→ **Korrekt:** Medienmanipulation bleibt Medienmanipulation. ESF braucht Transparenz, Reproduzierbarkeit, Unverzerrtheit.

== ■ ÜBUNG 2 (MITTELSCHWER) – Mini-Fall & Hypothesenkonstruktion

Aufgabe: Forschungslogik und Hypothesen

Szenario:

Ein junger PT interessiert sich für die Frage: „Wirkt Propriozeptives Training (PT) besser als Standardtraining bei der Sturzprävention bei älteren Menschen?“

Er formuliert folgende Hypothesen:

1. „Propriozeptives Training ist einfach besser.“

2. „Wenn ältere Menschen (>65 Jahre) propriozeptives Training machen, dann haben sie weniger Stürze pro Jahr als die Vergleichsgruppe mit Standardtraining.“
3. „Propriozeptives Training wird die Sturzrate vielleicht reduzieren.“
4. „Ältere Menschen mögen propriozeptives Training.“

Fragen:

a) **Welche der Hypothesen sind wissenschaftlich korrekt formuliert?** (Mehrfachantwort möglich)
Begründe mit den 4 Kriterien: Konditionalsatz, empirisch überprüfbar, allgemeingültig, falsifizierbar.

b) **Erkläre den Unterschied zwischen Hypothese 2 und 3:**

Welche ist wissenschaftlich verwendbar und warum?

c) **Formuliere aus H2 die statistische Nullhypothese (H₀) und Alternativhypothese (H₁):**
(Hinweis: H₀ sagt immer: „Es gibt KEINEN Unterschied/Effekt“)

■ MUSTERLÖSUNG Übung 2

a) **Welche sind wissenschaftlich korrekt?**

Hypothese	Konditionalsatz?	Empirisch überprüfbar?	Allgemeingültig?	Falsifizierbar?	✓/✗
1 „PT ist einfach besser“	✗ Nein (keine wenn-dann-Struktur)	■■ Vage (was = „besser“?)	✓ Ja	✗ Nein (nicht widerlegbar)	■
2 „Wenn PT, dann weniger Stürze als Standard“	✓ Ja (wenn-dann)	✓ Ja (Sturzrate messbar)	✓ Ja (Population definiert)	✓ Ja (kann widerlegt werden)	■
3 „PT vielleicht weniger Stürze“	✓ Ja (grammatikalisch)	■■ Problematisch („vielleicht“ = unscharf)	✓ Ja	✗ Nein (nicht falsifizierbar: egal, was rauskommt, war „vielleicht“ richtig)	■
4 „Ältere Menschen mögen PT“	✓ Ja	✓ Ja (subjektive Präferenz messbar)	✓ Ja	✓ Ja	■

→ Nur H2 und H4 sind korrekt (aber H4 beantwortet nicht die Forschungsfrage!)

b) Unterschied H2 vs. H3:

H2	H3
„Wenn ältere Menschen propriozeptives Training machen, dann haben sie weniger Stürze pro Jahr als die Vergleichsgruppe.“	„PT wird die Sturzrate vielleicht reduzieren.“
Spezifisch, Richtung klar, messbar	Unspezifisch, wischiwaschi, nicht falsifizierbar
Kann widerlegt werden: Wenn beide Gruppen gleich viele Stürze haben → H2 falsch	Kann nicht widerlegt werden: Egal ob PT hilft oder nicht → „vielleicht“ war ja richtig
→ Wissenschaftlich brauchbar	→ Nicht brauchbar

c) Statistische Hypothesen aus H2:

H₀ (Nullhypothese):

„In der Grundgesamtheit gibt es **KEINEN** signifikanten Unterschied in der jährlichen Sturzrate zwischen der propriozeptiven Trainingsgruppe und der Standardtrainingsgruppe bei älteren Menschen (>65 Jahren).“

H₁ (Alternativhypothese):

„In der Grundgesamtheit gibt es einen signifikanten Unterschied: die propriozeptive Trainingsgruppe hat **WENIGER** Stürze pro Jahr als die Standardtrainingsgruppe.“

Hinweis: H₀ wird **getestet** (nicht bewiesen!). Wenn $p < 0,05$ → wir lehnen H₀ ab (sprechen uns für H₁ aus). Aber: H₀ ist nicht „bewiesen“, nur „wahrscheinlicher“.

■ Häufige Fehler Übung 2

Fehler 1: „H3 ist auch in Ordnung, weil sie ja eine Hypothese ist.“

→ **Korrekt:** „Vielleicht“ macht jede Aussage nicht-falsifizierbar. Wissenschaft braucht klare Vorhersagen.

Fehler 2: „H₁ sollte heißen: ‚PT hilft sicher‘.“

→ **Korrekt:** Statistische H₁ sagt nie „sicher“ – nur „signifikant“ (mit Fehlerwahrscheinlichkeit). Und nur wenn $p < 0,05$.

Fehler 3: „H₀ ist die ‚schlechte‘ Hypothese.“

→ **Korrekt:** H₀ ist neutral. Wir testen damit, ob Daten gegen sie sprechen. Sie zu akzeptieren ist genauso valide wie sie abzulehnen.

➡■ ÜBUNG 3 (FORTGESCHRITTEN) – Theorie, Forschungsdesign & Interpretation

Aufgabe: Gesamtverständnis – Quantitativ vs. Qualitativ

Szenario:

Eine Gesundheitswissenschaftlerin möchte verstehen: „*Warum nehmen Berufstätige mit chronischen Rückenschmerzen Physiotherapie an oder nicht?*“

Sie plant zwei parallele Studien:

Studie A (Quantitativ):

- 800 Berufstätige mit Rückenschmerz (n=800)
- Fragebogen: demografische Daten, Schmerzintensität (NRS 0–10), Selbstwirksamkeit (Skala), Adhärenz (ja/nein)
- Statistische Frage: „*Gibt es einen Zusammenhang zwischen Selbstwirksamkeit und Adhärenz?*“
- Geplant: Korrelation, logistische Regression

Studie B (Qualitativ):

- 25 Berufstätige mit Rückenschmerz (n=25, davon 12 nehmen PT an, 13 nicht)
- Offene Leitfaden-Interviews (30–45 min)
- Forschungsfrage: „*Welche Beweggründe und Barrieren erleben Menschen?*“
- Geplant: Thematische Analyse, induktive Kategorienentwicklung

Teil A: Theorie & Logik

Frage A1: Ordne die Studien der Forschungslogik zu:

- ✓ Studie A: **Deduktiv oder Induktiv?** (Begründung in 1–2 Sätzen)
- ✓ Studie B: **Deduktiv oder Induktiv?** (Begründung in 1–2 Sätzen)

Frage A2: Welche Studie „testet“ Hypothesen und welche „entwickelt“ sie?

Teil B: Vergleich der Ansätze

Fülle die Tabelle aus oder kreuze an:

Aspekt	Studie	
	A	B
	(Quantitativ)	
Welche Datenform?		
Wer wird untersucht?		
Wie wird gemessen?		

Kann man Ergebnisse verallgemeinern (generalisieren)?		
Ist die Stichprobe „repräsentativ“?		
Können Subjektivität/Sinnverstehen berücksichtigt werden?		

Teil C: Mini-Kopfrechnen (nur für diesen Modul!)

Eine der 25 Personen in Studie B berichtet: „Ich hab ja keine Zeit für PT, ich arbeite 50h/Woche.“

Wie viele der 25 interviewten Personen müssten MINDESTENS diesen Grund angeben, damit man sagen kann: „Die Mehrheit nennt Zeitmangel als Grund“?

→ Berechne: Wie viel sind >50% von 25?
(Ohne Taschenrechner!)

Teil D: Interpretation eines p-Werts

Studie A findet: *Korrelation zwischen Selbstwirksamkeit und Adhärenz: $r = 0,35$, $p = 0,003$*

Frage D1: Was bedeutet $p = 0,003$?

- A) Die Wahrscheinlichkeit, dass die Korrelation „echt“ ist
- B) Wenn es KEINEN Effekt gibt (H₀ stimmt), wäre dieses Ergebnis nur in 0,3% der Fälle zu erwarten
- C) Der Effekt ist „groß“

Frage D2: Darf man danach sagen: „Selbstwirksamkeit VERURSACHT Adhärenz“?
(Ja/Nein + Begründung in 1–2 Sätzen)

■ MUSTERLÖSUNG Übung 3

Teil A: Theorie & Logik

Frage A1:

Studie	Logik	Begründung
A (Quantitativ)	Deduktiv	Sie geht von einer theoretischen Annahme aus (Selbstwirksamkeit → Verhalten), testet diese mit Daten und prüft eine vorformulierte Hypothese.

B (Qualitativ)	Induktiv	Sie startet ohne feste Hypothese, sammelt offene Daten und entwickelt aus den Aussagen der Teilnehmer induktiv Kategorien und Konzepte.
-----------------------	-----------------	---

Frage A2:

- **Studie A testet Hypothesen:** Vorformulierte H1 (Zusammenhang Selbstwirksamkeit-Adhärenz) wird durch Daten überprüft.
- **Studie B entwickelt Hypothesen:** Keine vorfixierte Hypothese; aus Interviews entstehen neue Konzepte über Barrieren/Beweggründe.

Teil B: Vergleich der Ansätze

Aspekt	Studie A (Quantitativ)	Studie B (Qualitativ)
Welche Datenform?	Zahlen: NRS, Skalenwerte, Häufigkeiten	Text: Interview-Transkripte, Zitate
Wer wird untersucht?	800 Personen (groß, breit)	25 Personen (klein, fokussiert)
Wie wird gemessen?	Standardisiert: gleiche Fragen für alle, objektive Auswertung	Offen: Leitfaden, aber Raum für Narrativ, interpretativ
Kann man Ergebnisse verallgemeinern (generalisieren)?	Ja, eher: Die 800 sind hoffentlich repräsentativ für die ~6 Mio. Berufstätigen mit Rückenschmerz in Deutschland.	Nein, nicht im statistischen Sinne: 25 sind zu wenig für „echte“ Generalisierung, aber Ergebnisse können theoretisch transferiert werden.
Ist die Stichprobe „repräsentativ“?	Anspruch ja: Sollte alle Schichten, Altersgruppen, Berufszweige proportional abbilden.	Nein, nicht repräsentativ: Ziel ist Sättigung (neue Interviews bringen keine neuen Erkenntnisse), nicht Repräsentativität.

Können Subjektivität/Sinnverstehen berücksichtigt werden?	Bedingt: Skalen messen Konstrukte, aber nicht die gelebte Erfahrung.	Ja, zentral: Warum Menschen entscheiden, wie sie denken – das ist das Thema.
--	---	---

Teil C: Mini-Kopfrechnen

Aufgabe: Wie viele der 25 müssen MINDESTENS den Grund nennen, damit es „Mehrheit“ ist?

Rechnung:

- Mehrheit = >50%
- 50% von 25 = $25 \div 2 = 12,5$
- >50% = **mindestens 13 Personen**

Antwort: Wenn 13 oder mehr Personen Zeitmangel nennen → Mehrheit.

Teil D: Interpretation eines p-Werts

Frage D1: Was bedeutet $p = 0,003$?

Antwort: B ist korrekt.

Option	Bewertung
A) Die Wahrscheinlichkeit, dass die Korrelation „echt“ ist	✗ Falsch. Das ist eine häufige Fehlinterpretation. Der p-Wert beschreibt nicht die Wahrscheinlichkeit der Hypothese selbst.
B) Wenn es KEINEN Effekt gibt (H_0 stimmt), wäre dieses Ergebnis nur in 0,3% der Fälle zu erwarten	✓ Richtig. Das ist die korrekte Definition: p-Wert = bedingte Wahrscheinlichkeit der Daten unter Annahme von H_0 .
C) Der Effekt ist „groß“	✗ Falsch. p-Wert sagt nichts über Effektgröße aus. $r = 0,35$ ist ein schwacher bis mittlerer Effekt (siehe Cohen).

Frage D2: Darf man sagen: „Selbstwirksamkeit VERURSACHT Adhärenz“?

Antwort: NEIN.

Begründung:

1. **Korrelation $\neq$ Kausalität:** Studie A ist eine Querschnittstudie (alle Messungen gleichzeitig). Man kann nicht wissen, ob:

- Selbstwirksamkeit → Adhärenz
- Adhärenz → Selbstwirksamkeit (Erfolg macht Menschen selbstwirksamer)
- Eine dritte Variable (z.B. Alter, Sozialstatus) beide beeinflusst

Nur Längsschnittstudien oder RCTs können Kausalität nahelegen. Hier fehlte die Zeitachse.

Zudem: $r = 0,35$ erklärt nur ~12% der Varianz. Viele andere Faktoren spielen eine Rolle.

■ Häufige Fehler Übung 3

Fehler 1: „Studie B hat nur 25 Personen, also ist sie nicht wissenschaftlich.“

→ **Korrekt:** Qualitative Studien haben andere Standards. $n=25$ kann sehr solide sein, wenn Sättigung erreicht wird. Nicht jede Studie braucht $n=800$.

Fehler 2: „ $p = 0,003$ heißt: Die Wahrscheinlichkeit, dass unsere Hypothese stimmt, ist 99,7%.“

→ **Korrekt:** Das ist ein klassischer Fehler. p sagt nichts über die Wahrscheinlichkeit der Hypothese aus! Es sagt: *Wenn H_0 wahr ist, wäre dieses Ergebnis selten.*

Fehler 3: „Weil $p < 0,05$, muss Selbstwirksamkeit Adhärenz verursachen.“

→ **Korrekt:** Signifikanz $\neq$ Kausalität. Statistik kann Kausalität nicht beweisen, nur Muster zeigen.

Fehler 4: „Studie B sollte 800 Interviews machen, damit die Ergebnisse gelten.“

→ **Korrekt:** Qualitative Forschung ist nicht quantitativ skalierbar. Bei 800 Interviews wäre die Datenflut unanalysierbar. Sättigung ($\approx 12\text{--}30$ Interviews) ist das Gütekriterium.

■ ZUSAMMENFASSUNG: Was wird im Format abgefragt?

Fragetyp	Anteil	Beispiel
Zuordnung / Verständnis	40–50%	„Ist das ESF? Begründe mit den 3 Komponenten.“
Mini-Fall / Szenario	30–40%	„Formuliere eine wissenschaftliche Hypothese zu X“
Interpretation	20–25%	„Was bedeutet dieser p-Wert?“ / „Darf man das so sagen?“
Kopfrechnen	5–10%	„Wie viele von 25 sind $>50\%$?“

Keine: SPSS-Output, komplexe Formeln, Standardabweichungen ausrechnen.

■ LERNZIELE NOCHMAL ÜBERPRÜFT?

Nach den 3 Übungen solltest du können:

- Die 3 Komponenten von ESF erkennen und anwenden
 - Wissenschaftliche Hypothesen von unscharfen Aussagen unterscheiden
 - Deduktion (Test) vs. Induktion (Entwicklung) zuordnen
 - Quantitativ und Qualitativ vergleichen – Stärken/Schwächen benennen
 - p-Wert RICHTIG interpretieren (nicht: „Hypothese ist 95% wahr“)
 - Warum Korrelation $\neq$ Kausalität
 - Repräsentativität und Sättigung unterscheiden
 - **Wenn 80% sicher: zum nächsten Kapitel!**
-

Kernfrage

Wie gewinnen wir **sichere Erkenntnisse** über die Realität – durch reine Logik, durch Beobachtung, oder durch systematische Falsifizierung?

1. Die drei großen Schulen

Rationalismus (Descartes, 17. Jh.)

- **Kern:** Vernunft und Logik sind die einzigen Erkenntnisquellen
- **Methode:** Deduktion – von allgemeinen Regeln zu Einzelfällen
- **Beispiel:** Satz des Pythagoras ($a^2 + b^2 = c^2$) – mathematisch beweisbar, nicht empirisch notwendig
- **Problem:** Das „Warum“ bleibt offen → Gott als Antwort

Empirismus (Locke, 17. Jh.)

- **Kern:** Alle Ideen entstehen durch Beobachtung der Außenwelt
- **Methode:** Induktion – von einzelnen Beobachtungen zu allgemeinen Regeln
- **Beispiel:** „Ich sehe 100 weiße Schwäne → **Alle** Schwäne sind weiß“
- **Problem:** **Naturkausalität nicht beweisbar** – Was heute wahr ist, muss morgen nicht gelten

Kritischer Rationalismus (Popper, 20. Jh.)

- **Kern:** Wir können nicht verifizieren (beweisen), aber falsifizieren (widerlegen)
- **Methode:** Hypothesen aufstellen und versuchen, sie zu **widerlegen**
- **Das Einhorn-Problem:** „Noch so viele weiße Schwäne beweisen nicht, dass **ALLE** Schwäne weiß sind – eine Beobachtung eines schwarzen Schwans falsifiziert dies sofort“
- **Relevanz für Forschung:** Theorien sind provisorisch, nie endgültig verifiziert

2. Warum Kritischer Rationalismus für empirische Forschung zentral ist

Rationalismus	Empirismus	Kritischer Rationalismus ✓
		Praktische Strategie: Hypothesen klar formulieren, gezielt testen, Falsifizierer suchen Zu Logik abgeleitet Problem (unendliche Wiederholung Realwelt nötig)
		Ergebnisse sind Evidenz gegen H₀ , nicht „Beweis“

Resultat: In Forschung sagen wir nicht „PT hilft **definitiv**“, sondern „Evidenz spricht **derzeit** gegen H₀ (p < 0,05)“.

3. Deduktion vs. Induktion in der Praxis

Deduktion: Allgemein → Einzelfall

Theorie: „PT reduziert Rückenschmerz“ Hypothese: „Wenn Patient PT erhält, sinkt sein Schmerz“ Test: 50 Patienten mit PT untersuchen Ergebnis: "Theorie in dieser SP bestätigt" → Unterstützung der Theorie

Ansatz: Theorietestend, quantitativ

Induktion: Einzelfall → Allgemein

Beobachtung: 5 Patienten berichten: „PT hilft mir mit Schmerzbewältigung“ Frage: Warum hilft PT? (nicht: Hilft es generell?) Methode: Interviews, offene Fragen Ergebnis: Neue Theorie: „PT aktiviert Bewältigungsstrategien durch therapeutische Beziehung“

Ansatz: Theoriegenerierend, qualitativ

4. Quantitativ vs. Qualitativ: Erkenntnisziele

Quantitativ	Qualitativ
Was? Misst messbare Effekte (Schmerz: 0–10)	Warum/Wie? Versteht Sinnkonstruktionen
Hypothese vorab festgelegt	Hypothesen entstehen aus Daten

Große Stichproben, statistisch repräsentativ	Kleine Samples, detailliert (z. B. 5–10 Interviews)
„Deduktiv“: Test bestehender Theorie	„Induktiv“: Neue Theorie entwickeln
Beispiel: RCT (50 Patienten, Schmerzreduktion?)	Beispiel: Experteninterviews (Warum Therapieabbruch?)

5. Positivismuskritik: Warum auch Qualitative Forschung nötig ist

Husserl (1859–1938): Reine Quantifizierung verliert den **Sinn**

- Zahlen allein erklären nicht, **warum** Menschen handeln
- Eine Schmerzskala (5/10) erfasst nicht, wie die Krankheit das Leben verändert
- **Lösung:** Kombination von Quanti + Quali oder Mixed Methods

Beispiel: Eine Studie zeigt, dass 80% Schmerzreduktion erzielen (quanti). Qualitativ erfahren wir: Für ältere Patienten war nicht der Schmerz, sondern die **Angst vor Bewegung** das Hauptproblem.

6. Prüfungsfallen – Merksätze

■■ Falsifikation ≠ Verifizierung

- Positive Studie → „H■ unterstützt“ (nicht: verifiziert)
- Negative Studie → „H■ nicht abgelehnt“ (nicht: falsifiziert die Theorie!)

■■ Naturkausalität nicht beweisbar

- Du kannst nicht beweisen, dass PT **immer** hilft
- Du kannst nur zeigen: In dieser SP, unter diesen Bedingungen, $p = 0,03$

■■ Stichprobeneffekt

- „PT hilft 20 Patienten“ ≠ „PT hilft der gesamten Bevölkerung“
- Deshalb: Repräsentative Stichproben, Konfidenzintervalle

Erklär-es-zurück-Frage

Du erklärst einem Klienten, warum eine neue Therapiemethode noch „experimentell“ ist, obwohl erste Studien vielversprechend sind.

- Welche philosophische Position vertrittst du dabei?
- Warum reicht eine positive Studie nicht als „Beweis“?
- Warum sollten qualitative Studien **zusätzlich** helfen, die Methode zu verstehen?

Lernziel-Check: Kannst du erklären, warum Popper Induktion kritisierte, aber trotzdem die Induktive Statistik (p-Wert) in Forschung Standard ist? (Hinweis: Probabilistische Aussagen vs. absolute Beweise)

Übungen

3 Übungsaufgaben: Philosophische Grundlagen & Erkenntnistheorie

ÜBUNG 1: Zuordnung (Einstieg)

Aufgabentyp: 6 Aussagen → 3 Schulen zuordnen

Ordne jede Aussage der passenden epistemischen Schule zu:

A) Rationalismus | B) Empirismus | C) Kritischer Rationalismus

Nr.	Aussage	Schule
1	„Eine Therapie ist bewiesen, wenn wir noch keinen Fall kennen, wo sie geschadet hat.“	
2	„Wir formulieren eine Hypothese und versuchen systematisch, sie zu widerlegen.“	
3	„Die Wahrheit erkennen wir durch reine logische Deduktion, nicht durch Ausprobieren.“	
4	„Aus 100 erfolgreichen Behandlungen folgt logisch: Die Methode funktioniert immer.“	
5	„Theorien sind vorläufig; jede kann durch eine neue Beobachtung falsifiziert werden.“	
6	„Schmerzskalen entstehen durch Abstraktion von vielen Patientenbeobachtungen.“	

Musterlösung Übung 1

Nr.	Aussage	Schule	Erklärung
1	„Eine Therapie ist bewiesen, wenn wir noch keinen Fall kennen, wo sie geschadet hat.“	B) Empirismus	Induktives Denken (Einzelbeobachtungen → Regel). Aber: klassischer Fehler! Induktion beweist nicht.

2	„Wir formulieren eine Hypothese und versuchen systematisch, sie zu widerlegen.“	C) Kritischer Rationalismus	Poppers Falsifikationsprinzip – Kern des modernen Forschens
3	„Die Wahrheit erkennen wir durch reine logische Deduktion, nicht durch Ausprobieren.“	A) Rationalismus	Descartes: Vernunft vor Erfahrung.
4	„Aus 100 erfolgreichen Behandlungen folgt logisch: Die Methode funktioniert immer.“	B) Empirismus	Typischer empiristischer Fehlschluss – das Schwanen-Problem!
5	„Theorien sind vorläufig; jede kann durch eine neue Beobachtung falsifiziert werden.“	C) Kritischer Rationalismus	Popper: Provisionalität und Falsifizierbarkeit.
6	„Schmerzskalen entstehen durch Abstraktion von vielen Patientenbeobachtungen.“	B) Empirismus	Induktion: Spezifische Beobachtungen → allgemeines Messinstrument.

Häufiger Fehler

■ Verwechslung Empirismus ↔ Kritischer Rationalismus

- **Empirismus** = „Ich beobachte → Regel entsteht“ (naiv)
- **Kritischer Rationalismus** = „Ich formuliere Regel → Ich suche Gegenbeispiel“ (aktiv falsifizierend)

Merksatz: **Empirismus ist passiv (Induktion), Kritischer Rationalismus ist aktiv (Falsifikation).**

ÜBUNG 2: Mini-Fall mit Forschungslogik (Mittelschwer)

Aufgabentyp: Szenario interpretieren, Forschungsansatz wählen

Szenario

Eine Physiotherapeutin stellt fest:

- **Beobachtung:** 6 Patienten mit Tennisarm berichten spontan: „Seit ich in der PT rede, geht es mir

mental besser – ich verstehe, warum ich Schmerz habe."

- Sie fragt sich: „Ist es die Mobilisation oder die therapeutische Beziehung, die hilft?"

Fragen (a–d)

a) Welche epistemische Strategie liegt dieser Beobachtung zugrunde?

- [] Deduktion (Theorie → Hypothese → Test)
- [] Induktion (Beobachtung → Theorie → Frage)
- [] Falsifikation (Hypothese aufstellen, dann widerlegen)

b) Sollte die PT jetzt direkt eine große RCT mit 100 Patienten machen, um die Hypothese zu testen?

Begründe kurz (1–2 Sätze).

c) Ein Kollege sagt: „Weil 6 Patienten berichten, dass die therapeutische Beziehung hilft, ist das bewiesen."

Welches erkenntnistheoretische Problem erkennt du hier? (Welche Schule verkennt er?)

d) Welcher Forschungsansatz passt JETZT am besten – quantitativ oder qualitativ? Warum?

Musterlösung Übung 2

a) Induktion

✓ Die PT beobachtet konkrete Fälle → entwickelt daraus eine neue Frage/Hypothese.
Das ist typisch induktiv (bottom-up, datengesteuert).

b) NEIN, nicht sofort eine RCT.

Begründung:

„Die Frage ‚Warum hilft es?‘ ist noch nicht geklärt. Eine große quantitative Studie würde nur testen, **dass** es hilft oder nicht – aber nicht **warum**. Erst müssen qualitative Daten die Mechanismen klären, dann kann eine RCT diese Hypothesen deduktiv testen."

Alternative: „Mixed-Methods-Ansatz: Erst qualitativ (Interviews, n=10–15), dann quantitativ (RCT mit gezielten Outcomes)."

c) Das Induktionsproblem / Empirismus-Naivität

Der Kollege begeht den klassischen **Verifikationsfehler**:

- 6 Fälle bestätigen etwas NICHT als wahr
- Es könnte ein **Selektionsbias** sein (nur motivierte Patienten berichten Sinnkonstruktionen?)
- Es könnte **Placebo** sein (Aufmerksamkeit, nicht therapeutische Beziehung spezifisch)

Nach Popper: Wir können diese Hypothese falsifizieren, wenn wir Patienten finden, die **keine** therapeutische Beziehung haben, aber gleich profitieren.

d) Qualitativ (zunächst)

Begründung:

- **Warum:** Neue Theorie entwickeln, nicht Test bestehender
 - **Wie:** Leitfaden-Interviews (n=8–12 Patienten), offene Fragen: „Wie hat dir das Gespräch mit mir geholfen?“
 - **Ziel:** Kategorien bilden (Hoffnung? Verständnis? Kontakt?) → später quantitativ operationalisieren
 - **Dann:** RCT, um zu prüfen: Therapeutic Alliance (Skala) → Schmerzreduktion?
-

Häufige Fehler

- „Weil es 6 Fällen hilft, ist es bewiesen“ → Verwechslung: Induktion ≠ Verifikation
 - ✓ „6 Fälle sind Hinweise, nicht Beweise. Wir brauchen Systematik.“
 - Gleich quantitativ forschen, ohne Mechanismen zu verstehen
 - ✓ Erst qualitativ verstehen, dann quantitativ messen.
-
-

ÜBUNG 3: Interpretation (Vertiefung – prüfungsnah)

Aufgabentyp: Prüfung lesen, erkenntnistheoretische Logik bewerten

Szenario: Prüfung einer neuen Entspannungsmethode

Ein Team führt folgende Studie durch:

- **Design:** RCT mit 80 Patienten (Interventions- vs. Wartelisten-Kontrolle)
 - **Outcome:** Angststörung (GAD-7-Skala, 0–21 Punkte)
 - **Ergebnis:** Interventionsgruppe: $\bar{X}$ 12,5 (SD=3,2) → $\bar{X}$ 8,3 (SD=3,1) nach 8 Wochen
 - **Statistik:** $t(78) = 6,8, p < 0,001$
 - **Publikation:** Titel: „Entspannungsmethode heilt Angststörung – klinisch bestätigt“
-

Fragen (a–d)

a) Bewerte die Aussage im Titel aus epistemologischer Sicht.

Welche(n) Fehler erkennst du bezüglich Falsifikation/Verifikation?

b) Die Wartelisten-Kontrolle zeigt keine Veränderung ($\bar{X}$ 14,2 → $\bar{X}$ 13,8).

Erkläre, warum dies die Hypothese nicht falsifiziert, sondern nur gegen H₁ spricht.

c) Ein Praktiker liest die Studie und sagt: „Jetzt weiß ich, dass die Methode wirkt – ich kann sie jedem mit Angst empfehlen.“

Welche(n) Grenzen der Studie übersieht dieser Praktiker?

(Mind. 2 Punkte: Stichprobe, Generalisierbarkeit, Mechanismen, Moderatoren)

d) Wie würde ein kritischer Rationalist einen nächsten Schritt planen?

(Wie würde man versuchen, die Hypothese zu falsifizieren?)

Musterlösung Übung 3

a) Epistemologische Fehler im Titel

Der Titel macht **zwei Verifikationsfehler**:

Verifizierungsfehler:

- Titel sagt: „**heilt** Angststörung“ (absolute Aussage)
- Statistik zeigt: $p < 0,001$, aber das bedeutet „H■ abgelehnt“, NICHT „Methode bewiesen“
- Korrekt: „Evidenz spricht gegen H■“ oder „reduziert Symptome in dieser SP“

Naturkausalitätsproblem (Hume/Popper):

- Nur 1 Studie kann eine Theorie nicht verifizieren
- Nächster Schwarz-Schwan könnte sie falsifizieren

✓ Besserer Titel:

„Entspannungsmethode reduziert GAD-7-Symptome in RCT (N=80, $p < 0,001$) – Hinweis auf Wirksamkeit, weitere Studien nötig.“

b) Warum Fehlen von Veränderung in KG die H■ nicht falsifiziert

Situation:

- IG: 12,5 → 8,3 (Reduktion 4,2 Punkte)
- KG: 14,2 → 13,8 (Reduktion 0,4 Punkte)
- $p < 0,001$ (signifikanter Unterschied zwischen IG und KG)

Logik:

- H■: IG-Reduktion = KG-Reduktion (keine Methodeneffekt)
- H■: IG-Reduktion > KG-Reduktion (Methodeneffekt)
- **Ergebnis: H■ abgelehnt ✓**

ABER das falsifiziert NICHT eindeutig die Methode, wenn KG sich nicht ändert, weil:

- Es könnte **natürlicher Verlauf** sein (ohne Intervention verbessern sich Patienten auch)
- Es könnte **Placebo/therapeutische Aufmerksamkeit** sein, nicht die spezifische Methode
- **Moderatoren** (Therapiemotivation, Alter, Komorbiditäten) könnten unerwartet wirken

→ **Falsifikation würde bedeuten:** IG-Reduktion = KG-Reduktion (oder schlechter). Dann: H■ nicht abgelehnt = Hypothese gefälscht.

c) Grenzen der Studie – was der Praktiker übersieht

Grenze	Bedeutung
1. Stichprobe (N=80)	Nur diese 80 Patienten getestet. Gelten die Ergebnisse für Rentner? Für Menschen mit PTBS? Für Online-Kurse? Unbekannt.

2. Spezifische Wirksamkeit	Die Studie testet: Methode ja/nein. Sie testet NICHT: Ist es die spezifische Technik oder nur „Aufmerksamkeit eines Therapeuten“? (→ Mechanismen)
3. Langzeiteffekt	8 Wochen ist kurz. Nach 6 Monaten verschwindet der Effekt vielleicht (Rückfallrate?).
4. Nebenwirkungen	Wurden Dropouts, Verschlechterungen, UAWs erfasst?
5. Moderatoren	Hilft es allen oder nur Subgruppen? (z. B. nur für Patienten mit leichter Angst?)

✓ **Bessere Aussage des Praktikers:**

„Diese Studie zeigt vielversprechende Hinweise. Für meine Patienten sollte ich prüfen, ob sie den Ein- und Ausschlusskriterien ähneln, und zusätzliche Studien einfordern.“

d) Kritisch-rationaler nächster Schritt: Falsifikationsversuche

Ein Kritischer Rationalist würde versuchen, die Hypothese zu **widerlegen**:

Ansatz 1: Spezifität-Test (Mechanismen)

- Hypothese: „Spezifische Entspannungstechnik reduziert Angst“
- Falsifikationsversuch: Vergleich mit **aktiver Kontrolle** (z. B. Gesprächstherapie ohne Entspannung)
- Wenn: Beide Gruppen gleich profitieren → Hypothese falsifiziert (es ist nicht die spezifische Technik)
- Wenn: Nur Entspannungsgruppe profitiert → Hypothese gestützt

Ansatz 2: Moderatoren-Test

- Hypothese: „Methode wirkt universell“
- Falsifikationsversuch: Subgruppen-Analysen (Alter, Schweregrad, Komorbiditäten)
- Wenn: Nur unter 30J. wirksam, nicht über 50J. → Hypothese eingeschränkt/falsifiziert

Ansatz 3: Replikation in anderer Population

- Hypothese: „Ergebnis mit N=80 in Klinik generalisiert“
- Falsifikationsversuch: Andere Klinik, Online-Setting, andere Therapeuten
- Wenn: Effekt verschwindet → Hypothese falsifiziert

Ansatz 4: Long-term Follow-up

- Hypothese: „Effekt bleibt bestehen“
- Falsifikationsversuch: 6-, 12-Monats-Follow-up
- Wenn: Rückkehr zu Baseline → Hypothese zeitlich eingeschränkt/falsifiziert

Häufige Fehler

■ „ $p < 0,001$ bedeutet, die Methode ist bewiesen“

✓ $p < 0,001$ bedeutet: H_0 ist unwahrscheinlich. Nicht: H_1 ist wahr.

■ „Weil KG keine Verbesserung zeigt, ist die Methode spezifisch wirksam“

✓ Das beweist nur, dass IG besser ist – nicht, warum (Placebo? spezifische Technik?).

■ „Eine Studie reicht für Praxis-Empfehlung“

✓ Systematische Suche nach Gegenbeweisen (Falsifikationsversuche) ist nötig.

ZUSAMMENFASSUNG: Prüfungsrelevante Kernpunkte

Konzept	Merksatz	Typische Prüfungsfrage
Rationalismus	Vernunft vor Erfahrung (Descartes)	„Welche Schule: Mathematik-Beweis ohne Experimente?“ → Rationalismus
Empirismus	Beobachtung → Regel (Locke)	„Induktion aus 100 Fällen?“ → Empirismus (aber kein Beweis!)
Kritischer Rationalismus	Hypothese → aktiv falsifizieren (Popper) ✓	„Wie testet man moderne Forschung?“ → Falsifikation, Provisionalität
Deduktion	Theorie → Hypothese → Test	Quantitativ, theorietestend
Induktion	Beobachtung → Hypothese → Theorie	Qualitativ, theoriegenerierend
Verifizierungs-Fehler	Positive Studien = kein Beweis	„Beweist $p < 0,001$, dass die Methode wirkt?“ → NEIN, nur gegen H_0
Falsifikations-Stärke	1 Gegenbeispiel = Widerlegung	„Alle Schwäne weiß“ + schwarzer Schwan → falsifiziert

Naturkausalität	Unmöglich zu beweisen (Hume)	„Warum kann man nicht sagen: PT hilft immer ?" → Naturkausalität nicht beweisbar, Stichprobeneffekt
-----------------	------------------------------	---

Feedback für Lernende

- ✓ Wenn du Übung 1 mit >5/6 schaffst: Grundkonzepte sitzen.
- ✓ Wenn du Übung 2 Frage (d) begründest: Forschungslogik verstanden.
- ✓ Wenn du Übung 3 Falsifikation vs. Verifikation unterscheidest: Prüfungsreif.

Häufigstes Missverständnis: „Große p-Werte = Theorie bestätigt.“

→ **Nein:** p-Wert testet nur H_0 , nicht H_1 . Größere/bessere Studien nötig!

1. Die Hierarchie: Theorie → Hypothese → statistische Hypothese

Eine **Theorie** ist ein Netz von Aussagen, das ein Phänomen erklärt. Sie ist zu weit und zu abstrakt, um direkt getestet zu werden.

Eine **wissenschaftliche Hypothese** ist ein konkreter, aus der Theorie abgeleiteter Konditionalsatz – das Werkzeug, mit dem Theorie und Realität in Kontakt kommen.

Ein **statistisches Hypothesenpaar (H_0/H_1)** ist die Operationalisierung dieser Hypothese: messbare Variablen, konkrete Gruppen, quantifizierte Erwartungen.

Metapher: Die Theorie ist die Landkarte. Die wissenschaftliche Hypothese ist die Route. H_0 und H_1 sind die Ampeln auf dieser Route – sie liefern eine binäre Entscheidung.

2. Die 6 Kriterien wissenschaftlicher Hypothesen

Kriterium	Bedeutung	Typischer Fehler
Konditionalsatz	„Wenn...dann" oder „Je...desto"	Aussage ohne diese Struktur
Empirisch überprüfbar	Muss an der Realität testbar sein	Metaphysische/religiöse Fragen
Allgemeingültig	Gilt für eine ganze Klasse von Fällen, nicht für Einzelfälle	„Frau Schmidt braucht PT"

Falsifizierbar	Es muss ein denkbares Ergebnis geben, das die Hypothese widerlegt	Tautologien
Widerspruchsfrei	Keine innere Widersprüchlichkeit	„A ist größer und kleiner als B“
Operationalisierbar	Die Variablen müssen messbar gemacht werden können	Vage Konstrukte ohne Messinstrument

3. Prüfungsfallen im Detail

Tautologie: „Entweder der Patient verbessert sich oder er verbessert sich nicht.“ – Das ist zwingend wahr, also nicht falsifizierbar → keine Hypothese.

Einzelfallaussage: „Herr Müller profitiert von manueller Therapie.“ – Keine Generalisierbarkeit → keine wissenschaftliche Hypothese.

Fehlende Konditionalsatz-Struktur: „PT ist wirksam bei Nackenschmerzen.“ – Das ist eine Behauptung, kein testbarer Konditionalsatz.

4. Von der wissenschaftlichen zur statistischen Hypothese

Schritt 1: Wissenschaftliche Hypothese formulieren.

„Wenn Patienten mit LBP Physiotherapie erhalten, dann reduziert sich ihre Schmerzintensität stärker als ohne Behandlung.“

Schritt 2: Variablen operationalisieren (z. B. Schmerz = NRS 0–10).

Schritt 3: Hypothesenpaar bilden – **komplementär**, d. h. H_0 und H_1 decken zusammen alle möglichen Ausgänge ab.

H_0 : Patienten mit LBP, die PT erhalten, zeigen im Mittel keine größere Reduktion der NRS-Schmerzintensität als Patienten ohne PT.

H_1 : Patienten mit LBP, die PT erhalten, zeigen im Mittel eine größere Reduktion der NRS-Schmerzintensität als Patienten ohne PT.

Merkregel:

- H_0 = Verneinung, Status quo, „kein Effekt“
- H_1 = die inhaltlich interessante Annahme

Gerichtet vs. ungerichtet:

- Gerichtet: H_1 sagt die *Richtung* voraus (größer/kleiner)

- Ungerichtet: H_1 sagt nur einen *Unterschied* voraus (verschieden)

5. Was ist KEINE wissenschaftliche Hypothese – Kurzcheck

- „Vielleicht hilft Fango.“ → kein Konditionalsatz, nicht falsifizierbar
 - „Alle Menschen sind sterblich.“ → nicht empirisch testbar im Forschungssinne
 - „Je mehr Fango, desto besser.“ → fehlt Operationalisierung von „besser“
 - „Wenn es regnet oder nicht regnet, ist es nass oder nicht.“ → Tautologie
-

6. Rechenbeispiel (Prüfungsniveau)

Keine Formelrechnung nötig. Typische Aufgabe:

Drei Schmerzwerte vor Therapie: 8, 6, 4. Mittelwert?
→ $(8 + 6 + 4) / 3 = 18 / 3 = 6$

Mehr Rechenaufwand kommt in dieser Hypothesenebene nicht vor.

Kernbegriffe auf einen Blick

- **Theorie** – abstraktes Erklärungsnetz
 - **Wissenschaftliche Hypothese** – Konditionalsatz, der 6 Kriterien erfüllt
 - H_0 – Nullhypothese, behauptet keinen Effekt
 - H_1 – Alternativhypothese, behauptet den erwarteten Effekt
 - **Operationalisierung** – Übersetzung eines Konstrukts in eine messbare Variable
 - **Falsifizierbarkeit** – Hypothese muss scheitern *können*
-

Erklär-es-zurück-Frage

Jemand zeigt dir diese Aussage: „**Physiotherapie ist gut für Patienten.**“

Erkläre, welche der 6 Kriterien diese Aussage **nicht** erfüllt, und formuliere daraus eine korrekte wissenschaftliche Hypothese sowie das dazugehörige statistische Hypothesenpaar (H_0 und H_1).

Übungen

3 Übungsaufgaben zu Kapitel 3: Theorien, Hypothesen und Variablenbeziehungen

ÜBUNG 1 (Einführung): Zuordnung – Hypothese oder nicht?

Aufgabentyp: Zuordnung + Begründung

Schwierigkeit: ■ (Einstieg)

Prüfungszeit: 5–7 Min

Aufgabe

Ordne die folgenden 5 Aussagen in zwei Kategorien:

- **A:** Ist eine wissenschaftliche Hypothese (erfüllt alle 6 Kriterien)
- **B:** Ist KEINE wissenschaftliche Hypothese (welches Kriterium fehlt?)

#	Aussage	Kat	Welches Kriterium fehlt?
1	„Wenn Patienten mit Nackenschmerzen ein Stabilisationstraining absolvieren, dann verbessert sich ihre Haltefunktion besser als ohne Training.“		
2	„Entweder die Therapie wirkt oder sie wirkt nicht.“		
3	„Mobilisation ist wertvoll für die Patientenzufriedenheit.“		
4	„Je mehr Sitzungen ein Patient erhält, desto niedriger wird sein Schmerzwert auf der NRS (0–10).“		
5	„Herr Müller braucht dringend eine Rotatorenmanschetten-Therapie.“		

✓ MUSTERLÖSUNG Übung 1

#	Aussage	Kategorie	Welches Kriterium fehlt?
---	---------	-----------	--------------------------

1	„Wenn Patienten mit Nackenschmerzen ein Stabilisationstraining absolvieren, dann verbessert sich ihre Haltefunktion besser als ohne Training.“	A ✓	— (erfüllt alle 6)
2	„Entweder die Therapie wirkt oder sie wirkt nicht.“	B ✗	Falsifizierbarkeit (Tautologie)
3	„Mobilisation ist wertvoll für die Patientenzufriedenheit.“	B ✗	Operationalisierbarkeit („wertvoll“ unklar, „Patientenzufriedenheit“ nicht gemessen)
4	„Je mehr Sitzungen ein Patient erhält, desto niedriger wird sein Schmerzwert auf der NRS (0–10).“	A ✓	— (erfüllt alle 6, Variablen operationalisiert)
5	„Herr Müller braucht dringend eine Rotatorenmanschetten-Therapie.“	B ✗	Allgemeingültigkeit (Einzelfallaussage)

■ Häufige Fehler

Aussage 1 als falsch einsortiert, weil „besser“ unklar ist

- ■ **Fehler:** Annahme, dass es auch hier an Operationalisierung fehlt
- ✓ **Korrektur:** „Haltefunktion“ *kann* operationalisiert werden (z. B. durch Kraft-, Ausdauer-, Positionshaltungs-Tests); die Aussage gibt die Richtung vor (besser)

Aussage 4 übersehen, dass „je-desto“ gerichtet ist

- ■ **Fehler:** „Das ist zu allgemein, alle Patienten sind verschieden“
- ✓ **Korrektur:** Wissenschaftliche Hypothesen beziehen sich auf Populationen/Klassen, nicht Individuen. Diese Hypothese kann für eine Patientengruppe gelten.

Aussage 3 als ausreichend operationalisiert einsortiert

- ■ **Fehler:** „Patientenzufriedenheit“ ist ein klares Konstrukt
- ✓ **Korrektur:** „Wertvoll“ bleibt eine Wertung und kein messbares Kriterium. Besser: „erhöht die Zufriedenheit“ + Messinstrument (z. B. Likert-Skala)

ÜBUNG 2 (Mittel): Mini-Fall mit Reformulation

Aufgabentyp: Text → Hypothese reformulieren + H₀/H₁ bilden

Schwierigkeit: ■■ (anwendend)

Prüfungszeit: 10–12 Min

Aufgabe

Fallszenario:

Eine Physiotherapeutin möchte untersuchen, ob **Atemtraining** die **Schlafqualität** bei Patienten mit **chronischer Obstruktiver Lungenerkrankung (COPD)** verbessert. Sie hat gelesen, dass Entspannungstechniken helfen, aber sie weiß noch nicht genau, wie sie das formulieren soll.

Ihre erste Formulierung (zu schwach):

„Atemtraining ist gut für die Schlafqualität bei COPD-Patienten.“

Aufgabenteil A: Kritik

Beschreibe **alle** Mängel dieser Formulierung bezogen auf die 6 Kriterien.

Aufgabenteil B: Reformulation

Formuliere eine **korrekte wissenschaftliche Hypothese** mit:

- Konditionalsatz
- Operationalisierte Variablen
- Allgemeingültig (nicht einzelner Patient)
- Falsifizierbar

Aufgabenteil C: Statistisches Hypothesenpaar

Bilde **H₀** und **H₁** auf Basis deiner reformulierten Hypothese. Nutze ein konkretes Messinstrument für Schlafqualität (z. B. PSQI-Score 0–21, höher = schlechter).

✓ MUSTERLÖSUNG Übung 2

Aufgabenteil A: Kritik der Originalformulierung

Kriterium	Status	Begründung
Konditionalsatz	■■ Schwach	„ist gut“ ist keine Wenn-dann-Struktur; besser: „Wenn...dann...“
Empirisch überprüfbar	✓ Ja	COPD und Schlafqualität sind in der Realität messbar

Allgemeingültig	✓ Ja	Bezieht sich auf COPD-Patienten als Klasse
Falsifizierbar	✓ Ja	Es ist denkbar, dass Atemtraining <i>nicht</i> hilft
Widerspruchsfrei	✓ Ja	Keine innere Widersprüchlichkeit
Operationalisierbar	■ Nein	„gut“ ist vage; „Schlafqualität“ ist nicht operationalisiert

Fazit: Fehlen: **Konditionalsatz-Struktur** und **Operationalisierung**

Aufgabenteil B: Reformulation

Wissenschaftliche Hypothese:

„Wenn COPD-Patienten strukturiertes Atemtraining (3× 30 Min/Woche über 8 Wochen) durchführen, dann reduziert sich ihre Schlafstörung (gemessen via PSQI-Score) stärker als in einer Kontrollgruppe ohne Atemtraining.“

Warum besser:

- ✓ **Konditionalsatz** („Wenn...dann“)
- ✓ **Operationalisiert:** Atemtraining (Dauer/Frequenz), COPD-Patienten (Population), Schlafqualität (PSQI-Score)
- ✓ **Allgemeingültig:** gilt für diese Patientengruppe
- ✓ **Falsifizierbar:** Es ist möglich, dass PSQI in beiden Gruppen gleich sinkt
- ✓ **Widerspruchsfrei**

Aufgabenteil C: H₀ und H₁

H₀ (Nullhypothese):

COPD-Patienten, die strukturiertes Atemtraining erhalten, zeigen im Mittel **keine signifikante Reduktion des PSQI-Scores** im Vergleich zu COPD-Patienten ohne Atemtraining.

Oder formal: $\mu_{\text{Training}} = \mu_{\text{Kontrolle}}$
(oder: PSQI-Reduktion ist in beiden Gruppen gleich)

H₁ (Alternativhypothese):

COPD-Patienten, die strukturiertes Atemtraining erhalten, zeigen im Mittel **eine signifikant größere Reduktion des PSQI-Scores** im Vergleich zu COPD-Patienten ohne Atemtraining.

Oder formal: $\mu_{\text{Training}} < \mu_{\text{Kontrolle}}$
(weil PSQI niedriger = besser)

Anmerkung: Dies ist eine **gerichtete Hypothese** (einseitig), da die Hypothese eine bestimmte Richtung angibt.

■ Häufige Fehler

H■ und H■ nicht als komplementär formuliert

- ■ **Fehler:** H■: „Es gibt keinen Unterschied“ | H■: „Es gibt einen Unterschied“ — zu ungerichtet
- ✓ **Korrektur:** H■ und H■ müssen zusammen alle möglichen Ausgänge decken; wenn H■ falsch ist, muss H■ wahr sein

„Operationalisierung“ nur für Atemtraining, nicht für Schlafqualität

- ■ **Fehler:** „Atemtraining durchführen“ ist klar, aber Schlafqualität bleibt vage
- ✓ **Korrektur:** Beides muss messbar sein (z. B. PSQI, Polysomnographie, Schlaftagebuche)

H■ als „negative“ Hypothese verfasst

- ■ **Fehler:** H■: „Atemtraining schadet der Schlafqualität“
- ✓ **Korrektur:** H■ behauptet Abwesenheit eines Effekts, nicht einen gegenteiligen Effekt

ÜBUNG 3 (Schwer): Interpretation einer Studie + kritisches Hinterfragen

Aufgabentyp: Fallstudie, Interpretation, Kritik

Schwierigkeit: ■■■ (Prüfungsniveau)

Prüfungszeit: 12–15 Min

Aufgabe

Studien-Abstract (fiktiv):

Titel: „Effekt von manueller Therapie auf funktionale Mobilität bei älteren Patienten mit Hüftarthrose“

Hintergrund: Manuelle Therapie ist eine häufig eingesetzte Intervention. Frühere Studien deuten auf eine verbesserte Mobilität hin.

Design: RCT mit 120 Patienten (> 65 Jahre, Hüftarthrose-Diagnose). Gruppe A: 6 Wochen manuelle Therapie + Heimübung (n=60). Gruppe B: nur Heimübung (n=60). Messungen: Timed-Up-and-Go-Test (TUG) vor/nach, Schmerzskala (NRS).

Ergebnis:

- Gruppe A: TUG 18,2 s → 14,5 s (Reduktion 3,7 s)
- Gruppe B: TUG 19,1 s → 16,8 s (Reduktion 2,3 s)
- Differenz: 1,4 s zugunsten Gruppe A

- p-Wert: 0,24
- Schlussfolgerung der Autoren: „Manuelle Therapie zeigte eine Tendenz zur Verbesserung der Mobilität, könnte aber auch aufgrund von Placebo wirken.“

Aufgabenteil A: Rekonstruktion der Hypothesen

1. **Formuliere die vermutete wissenschaftliche Hypothese**, die hinter dieser Studie steht.
2. **Formuliere das korrespondierende H_0 und H_1** (auf Basis des TUG-Tests).

Aufgabenteil B: Interpretation des p-Wertes

Drei Aussagen zum p-Wert von 0,24. Markiere **richtig (R)** oder **falsch (F)**:

#	Aussage	R/F
1	Der p-Wert von 0,24 bedeutet, dass mit 24%iger Wahrscheinlichkeit manuelle Therapie wirksam ist.	
2	Der p-Wert von 0,24 bedeutet, dass wir H_0 nicht ablehnen können (auf dem 5%-Niveau).	
3	Der p-Wert von 0,24 bedeutet, dass die beobachtete Differenz von 1,4 s zufällig entstanden sein könnte (wenn H_0 wahr ist).	

Aufgabenteil C: Kritische Analyse

Die Autoren schreiben:

„Manuelle Therapie zeigte eine **Tendenz zur Verbesserung** der Mobilität, könnte aber auch aufgrund von **Placebo wirken**.“

Frage: Inwiefern ist diese Schlussfolgerung **wissenschaftlich problematisch** bezogen auf:

1. Die statistische Hypothesenlogik (H_0/H_1)
2. Die Operationalisierung von „Placebo“
3. Das RCT-Design (zweite Gruppe)

Aufgabenteil D: Verbesserungsvorschlag

Wie könnte die Studie **methodisch oder in der Hypothesenformulierung verbessert** werden, um klarere Aussagen über Manuelle Therapie vs. Placebo zu treffen?

✓ MUSTERLÖSUNG Übung 3

Aufgabenteil A: Rekonstruktion der Hypothesen

Wissenschaftliche Hypothese (rekonstruiert):

„Wenn ältere Patienten (> 65 Jahre) mit Hüftarthrose manuelle Therapie zusätzlich zur Heimübung erhalten, dann verbessert sich ihre funktionale Mobilität (gemessen via TUG-Test in Sekunden) stärker als Patienten, die nur Heimübung durchführen.“

Statistisches Hypothesenpaar:

H₀: Ältere Patienten (> 65 Jahre) mit Hüftarthrose, die manuelle Therapie + Heimübung erhalten, zeigen im Mittel **keine signifikant bessere Verbesserung im TUG-Test** als Patienten mit nur Heimübung.

($\mu_{\text{MT+HÜ}} - \text{Baseline} = \mu_{\text{HÜ}} - \text{Baseline}$, oder: Differenzen sind gleich)

H₁: Ältere Patienten (> 65 Jahre) mit Hüftarthrose, die manuelle Therapie + Heimübung erhalten, zeigen im Mittel **eine signifikant bessere Verbesserung im TUG-Test** als Patienten mit nur Heimübung.

($\mu_{\text{MT+HÜ}} - \text{Baseline} > \mu_{\text{HÜ}} - \text{Baseline}$, gerichtet)

Aufgabenteil B: Interpretation des p-Wertes

#	Aussage	R/F	Begründung
1	Der p-Wert von 0,24 bedeutet, dass mit 24%iger Wahrscheinlichkeit manuelle Therapie wirksam ist.	F	Das ist ein häufiger Fehler! Der p-Wert ist nicht die Wahrscheinlichkeit, dass H ₀ wahr ist. Er ist die bedingte Wahrscheinlichkeit des Datenmusters <i>unter der Annahme, dass H₀ wahr ist</i> .
2	Der p-Wert von 0,24 bedeutet, dass wir H ₀ nicht ablehnen können (auf dem 5%-Niveau).	R	Da $0,24 > 0,05$, können wir die Nullhypothese nicht ablehnen. Statistische Signifikanz liegt nicht vor.

3	Der p-Wert von 0,24 bedeutet, dass die beobachtete Differenz von 1,4 s zufällig entstanden sein könnte (wenn H_0 wahr ist).	R	Das ist eine gültige Interpretation: Wenn es keinen echten Unterschied gibt (H_0 wahr), würden wir eine Differenz von $\geq 1,4$ s mit einer Wahrscheinlichkeit von 24 % rein zufällig beobachten.
---	---	---	---

Aufgabenteil C: Kritische Analyse der Autoren-Schlussfolgerung

Die Aussage „**Tendenz zur Verbesserung, könnte aber auch Placebo sein**“ ist in drei Punkten problematisch:

1. Statistische Hypothesenlogik:

- ■ **Problem:** Der p-Wert von 0,24 führt zu **Nichtablehnung von H_0** . Es gibt keine statistisch signifikante Verbesserung.
- ✓ **Korrektur:** Die Autoren sollten schreiben: „Wir konnten keinen signifikanten Unterschied nachweisen. Eine klinisch relevante Verbesserung in MT+HÜ versus HÜ allein ist auf dieser Stichprobe nicht belegt.“
- ■■ **Fallstrick:** Eine „Tendenz“ nach $p > 0,05$ zu behaupten, ist Wishful Thinking und verletzt die Logik des Hypothesentestens.

2. Operationalisierung von „Placebo“:

- ■ **Problem:** Was ist „Placebo“ konkret? Die Studie hat keine Placebo-Kontrollgruppe (z. B. Sham-Manipulation).
- ✓ **Korrektur:** Die Autoren könnte Placebeffekte nur durch eine weitere Gruppe isolieren (z. B. Sham-MT + Heimübung). Hier ist „Placebo“ nur eine Post-hoc-Spekulation.

3. RCT-Design:

- ✓ **Gut:** Es gibt eine Kontrollgruppe (HÜ allein). Dadurch können Placebeffekte *teilweise* kontrolliert werden (Aufmerksamkeit, Therapist-Patient-Interaktion sind in beiden Gruppen vorhanden).
- ■ **Problem:** Aber die Studie kann **nicht** zwischen „echtem Effekt der MT“ und „Verstärkung durch Therapist-Aufmerksamkeit“ unterscheiden. Dafür bräuchte man Sham-MT.

Zusammenfassung:

Die Schlussfolgerung ist **spekulativ und unbelegt**. Sie widerspricht der statistischen Entscheidung (Nichtablehnung von H_0).

Aufgabenteil D: Methodische Verbesserungen

Option 1: Design-Verbesserung (Ideal)

Dreier-Design einführen:

- **Gruppe A:** MT + Heimübung

- **Gruppe B:** Sham-MT + Heimübung (Placebo-Kontrolle)
- **Gruppe C:** Heimübung allein

Vorteil: Dann können MT-Spezifika von Placebeffekten (Aufmerksamkeit, Zuwendung) getrennt werden.

Option 2: Hypothesen-Anpassung

Falls Sham-MT nicht machbar ist:

Ursprüngliche Hypothese:

„MT ist besser als HÜ allein.“

Ehrlichere Hypothese:

„MT + HÜ ist besser als HÜ allein“ (kombinierten Effekt prüfen, nicht MT-spezifisch)

Oder:

„MT hat einen zusätzlichen Effekt zu HÜ von mindestens 2 Sekunden TUG-Reduktion.“ (klinisch relevante Schwelle setzen, statt auf p-Wert zu hoffen)

Option 3: Stichprobengröße prüfen

- Bei $p = 0,24$ und Differenz von nur 1,4 s könnte die Studie **underpowered** sein.
- **Faustregel:** Vor der Studie eine Power-Analyse durchführen: Wie viele Patienten brauchte ich, um ein klinisch relevantes Effekt (z. B. 2–3 s) mit 80 % Power zu erkennen?
- Die Autoren hätten die Stichprobe vergrößern sollen.

■ Häufige Fehler

p-Wert als Wahrscheinlichkeit der Hypothese missverstanden

- **■ Fehler:** „ $p = 0,24$ bedeutet, MT wirkt zu 24 %“
- **✓ Korrektur:** p ist $P(\text{Daten} \mid H_0)$, nicht $P(H_0 \mid \text{Daten})$

„Tendenz“ nach nicht-signifikantem Ergebnis als wissenschaftlich gültig akzeptiert

- **■ Fehler:** „Die Richtung stimmt, also liegt ein Effekt vor“
- **✓ Korrektur:** Ohne statistische Signifikanz können wir nicht zwischen echtem Effekt und Rauschen unterscheiden.

Placebo-Effekte ohne Placebo-Kontrollgruppe behauptet

- **■ Fehler:** „Der Unterschied könnte Placebo sein“ (spekulativ)
- **✓ Korrektur:** Nur mit Sham-Gruppe ist das testbar.

RCT-Design nicht gewürdigt

- **■ Fehler:** „RCT reicht nicht, um Placebo auszuschließen“
- **✓ Korrektur:** RCT *kontrolliert* viele Störvariablen; Sham-Design ist zusätzliche Verfeinerung,

nicht Ersatz.

Zusammenfassung aller 3 Übungen

Übung	Fokus	Kernkompetenz	Typischer Fehler
1	Zuordnung + Kriterien	Alle 6 Kriterien schnell prüfen	Operationalisierung vs. Konditionalsatz verwechseln
2	Reformulation + H_0/H_1	Von schwachen zu starken Hypothesen	H_0 nicht komplementär zu H_1
3	p-Wert-Interpretation + Kritik	Hypothesenlogik in realer Studie anwenden	p-Wert missverstehen; Placebos spekulieren

Prüfungs-Checkliste: Was könnte fehlschlagen?

- ☐ Ich verwechsle die 6 Kriterien untereinander
- ☐ Ich formuliere H_0 und H_1 nicht komplementär
- ☐ Ich interpretiere p-Wert als Wahrscheinlichkeit einer Hypothese (statt als bedingte Wahrscheinlichkeit der Daten)
- ☐ Ich akzeptiere „Tendenzen“ nach $p > 0,05$ als signifikant
- ☐ Ich behaupte Placebo-Effekte ohne Placebo-Kontrollgruppe
- ☐ Ich verwechsle „wissenschaftliche Hypothese“ mit „Behauptung“ oder „Vermutung“

Viel Erfolg! ■

Lernmodul: Qualitative Forschung – Paradigma und Design

Kerndifferenz: Verstehen vs. Erklären

Quantitativ: erklärt durch Messwerte, Häufigkeiten, Zusammenhänge zwischen Variablen.

Qualitativ: versteht durch Rekonstruktion von Sinngebungen, Lebenswelten, Handlungskontexten.

Die qualitative Forschung fragt nicht „Wie häufig?“, sondern „Warum handelt jemand so und welchen Sinn gibt er/sie dieser Handlung?“ Sie sucht nach dem **Warum hinter den Mustern**, nicht nur den Mustern selbst.

Das qualitative Paradigma: Vier tragende Säulen

1. Interpretativismus

Realität ist nicht objektiv vorhanden, sondern wird durch Menschen **kontextabhängig konstruiert**. Der gleiche Sachverhalt wird je nach sozialem, kulturellem, historischem Kontext unterschiedlich bedeutsam.

→ **Konsequenz:** Verschiedene Perspektiven sind nicht Störquelle, sondern Erkenntnisgewinn.

2. Induktion (Theoriegenerierung)

Theorie entsteht *aus dem Material*, nicht *vor dem Material*. Der Forschungsprozess ist iterativ: Datenerhebung und Analyse laufen parallel. Mit jeder Erhebung wird die Fragestellung geschärft (Fine-Tuning).

→ **Nicht wild interpretieren:** Induktion folgt **regelgeleiteten Verfahren** (Kategoriebildung, Kodierung, Analyse nach standardisierten Schritten).

3. Reflexivität des Forschenden

Der Forscher/die Forscherin ist *Teil des Feldes*, nicht außerhalb davon.

- Themenwahl ist beeinflusst durch Vorverständnis
- Interaktion mit Teilnehmenden prägt Daten
- Interpretationen hängen von der Perspektive ab

Das ist kein Makel, sondern die Methode: Vorverständnis wird *transparent gemacht* und *dokumentiert* (nicht eliminiert).

4. Offenheit

Gegenüber eintreffenden, unerwarteten Informationen. Phänomene werden *zunächst vorläufig* untersucht, keine vorschnelle Kategorisierung. Das Relevanzsystem liegt in den Daten selbst, nicht in Lehrbüchern.

Kernelemente qualitativer Forschung

Merkmal	Ausprägung
Daten	Narratives Material (Interviews, Beobachtungsprotokolle, Feldnotizen, Videos)

Stichprobe	Klein, absichtlich gewählt (1–5 Fälle; nicht zufällig)
Sättigungspunkt	Keine neuen Informationen = Stichprobe ist ausreichend (theoretische Sättigung)
Design	Flexibel, emergent, kontextgesteuert
Prozess	Zirkular, iterativ: Datenerhebung und Analyse parallel
Ziele	Exploration, Explanation, Detail/Tiefe, Generierung von Konzepten

Wann ist qualitative Forschung notwendig?

- ✓ **Sichtweise und Erfahrungen der Betroffenen** sind zentral (z.B. Leben mit Behinderung)
 - ✓ **Lebenswelten** und alltägliche Kontexte sollen verstanden werden
 - ✓ **Sinnkonstruktionen** von Handlungen klären (warum Patienten Therapie abbrechen)
 - ✓ **Wenig beforschte Phänomene** erkunden (Startpunkt für Theorien)
 - ✓ **Unerwartete Konsequenzen** oder Effekte entdecken
-

Erhebungsmethoden

Interview (semistrukturiert)

- Leitfaden mit offenen Fragen
- Nachfragen und Erzählauffordernder Charakter
- Erfasst: Meinungen, Erfahrungen, Pläne, Gefühle
- PT/ET-Beispiel: Erfahrungen von Eltern mit Frühförderung

Beobachtung (teilnehmend)

- Im natürlichen Kontext (Kindergarten, Therapiesetting)
- Fokus auf Verhaltensmuster, Interaktionen, Routinen
- Rollenspektrum: Vollständige Teilnahme bis Vollständige Beobachtung
- PT/ET-Beispiel: Wie Therapeuten mit widerstrebenden Kindern umgehen

Gruppendiskussion (Focus Group)

- Stimulation durch Gruppendynamik
- Erfasst spontane Reaktionen, Widersprüche, Meinungsspektrum
- PT/ET-Beispiel: Sichtweisen verschiedener Therapeuten auf Akademisierung

Gütekriterien qualitativer Forschung

Achtung: Qualitativ = nicht unkritisch. Auch hier braucht es Qualitätsstandards:

Kriterium	Überprüfung
Regelgeleitetheit	Systematisches, nachvollziehbares Vorgehen (Kodierregeln dokumentiert)
Verfahrensdokumentation	Vorverständnis, Sampling, Auswahl der Methode, Auswertungsstrategie transparent
Intercoder-Reliabilität	Mehrere Kodierer → gleiches Ergebnis? (Reproduzierbarkeit)
Nähe zum Gegenstand	Gleichberechtigtes Verhältnis zu TN, Offenheit
Kommunikative Validierung	Ergebnisse mit TN rückgekoppelt: Finden sie sich darin wieder?
Triangulation	Mehrere Datenquellen/Methoden/Perspektiven → Plausibilität erhöht

Forschungsdesigns (kurz)

- **Ethnografisch:** Kulturen von Gruppen verstehen (teilnehmende Beobachtung zentral)
 - **Phänomenologisch:** Wie erleben Menschen Wirklichkeit? Subjektive Perspektiven
 - **Grounded Theory:** Theorie aus Daten generieren; systematische Kategoriebildung
-

Häufige Prüfungsfallen

■■ „Kleine Stichproben sind unprofessionell“ → Falsch. Absichtliche Auswahl (Purposive Sampling) ist gezielt und wissenschaftlich.

■■ „Ich kann einfach interpretieren wie ich will“ → Falsch. Regelgeleitet und dokumentiert.

■■ „Subjektivität verfälscht die Ergebnisse" → Falsch. Sie ist reflexiv zu nutzen, nicht zu verstecken.

■■ „Forschungsfrage ist starr" → Falsch. Fine-Tuning und Modifikation sind vorgesehen (iterativ).

Erklär-es-zurück

Szenario: Du leitest eine qualitative Studie zu „Wie erleben Ergotherapeuten die Akademisierung ihres Berufs?" Du hast 3 Interviews durchgeführt und merkst: Die Themen verschieben sich, eine neue Frage wird wichtig.

Frage: Warum ist das *normal und methodisch sinnvoll* – und nicht ein Zeichen fehlerhafter Planung? (Nenne das Konzept und erkläre die Konsequenz für Sampling.)

Übungen

3 Übungsaufgaben: Qualitative Forschung – Paradigma und Design

ÜBUNG 1: Zuordnung (Leicht)

Aufgabe: Ordne die Aussagen den qualitativen Paradigma-Säulen zu.
Jede Säule kann mehrfach oder gar nicht verwendet werden.

Aussage	Säule
A) „Der Forscher dokumentiert seine Vorurteile offen und arbeitet damit transparent.“	1. Interpretativismus
B) „Zwei verschiedene Patienten bewerten die gleiche Therapie völlig unterschiedlich – das ist kein Messfehler, sondern Realität.“	2. Induktion
C) „Nach 5 Interviews erkennen wir plötzlich: Ein ganz neues Thema ist relevant. Wir stellen die Interviewfragen um.“	3. Reflexivität
D) „Die Kategorien für die Auswertung entstehen aus den Daten selbst, nicht aus Lehrbüchern.“	4. Offenheit
E) „Wir brechen die Datenerhebung ab, weil wir keine neuen Informationen mehr bekommen – theoretische Sättigung.“	—

ÜBUNG 2: Mini-Fall mit Interpretation (Mittel)

Szenario:

Eine Logopädin plant eine qualitative Studie: „Warum brechen manche Patienten die Stimmtherapie ab?“ Sie hat 4 Interviews geplant, alle mit berufstätigen Frauen (30–50 Jahre). Nach 2 Interviews merkt sie: Das Material ist reichhaltig, aber eine wichtige Perspektive fehlt – die Rolle des Partners. Sie beschließt:

- Die Fragen entsprechend anzupassen
- Nun auch 2 Partner zu interviewen
- Das Design zu öffnen

Fragen:

Welches qualitative Paradigma-Merkmal zeigt sich hier? (Nenne das Konzept)

Ist diese Änderung methodisch sauber oder zeigt sie fehlerhafte Planung? Begründe kurz mit Verweis auf ein Kernprinzip.

Wie würde man die neue Stichprobe rechtfertigen? (Welcher Sampling-Typ?)

ÜBUNG 3: Fallanalyse – Gütekriterien und Reflexion (Schwer)

Szenario:

Ein Physiotherapeut führt eine ethnografische Studie durch: „Wie gehen Therapeuten in der Schmerztherapie mit Patienten um, die nicht den Anweisungen folgen?“

Er beobachtet 6 Wochen teilnehmend in einer Praxis, führt 8 Interviews mit Therapeuten durch und transkribiert alles.

Beobachtete Praxis: Der PT merkt im Laufe der Studie, dass die Therapeuten sein Verhalten kennen und sich „vorbildlicher“ verhalten, wenn er beobachtet (Hawthorne-Effekt).

Sein Plan zur Qualitätssicherung:

- Er dokumentiert sein Vorverständnis: „Ich bin selbst PT und glaube, dass einfühlsame Kommunikation hilft. Das könnte meine Interpretation prägen.“
- Er bittet 2 Kollegen (auch PTs), sein Kodierschema zu testen (Intercoder-Reliabilität)
- Er zeigt die vorläufigen Ergebnisse den beobachteten Therapeuten und fragt: „Stimmt das mit eurer Erfahrung überein?“

Fragen:

Welche 3 Gütekriterien aus der Vorlesung nutzt der PT hier explizit? Benenne und erkläre kurz, wie.

Ist der Hawthorne-Effekt ein „Fehler“, der eliminiert werden sollte – oder gehört er zum qualitativen Paradigma? Begründe mit Verweis auf Reflexivität.

Ein Kritiker sagt: „Mit nur 8 Interviews kann man keine verlässlichen Ergebnisse generieren.“ Wie würdest du antworten? (Tipp: Denke an Sättigung und Sampling-Typ)

Bonus (optional): Der PT fragt sich: „Soll ich meine Vorurteile eliminieren?“ Was wäre die qualitative Antwort?

MUSTERLÖSUNGEN

Lösung zu Übung 1:

Aussage	Säule	Begründung
---------	-------	------------

A	3. Reflexivität	Transparenz über die eigene Positionierung ist Kern von Reflexivität
B	1. Interpretativismus	Unterschiedliche Sinnzuschreibungen je nach Kontext/Person → Konstruktion der Realität
C	2. Induktion + 4. Offenheit	Theoriegenerierung aus Daten (Induktion) + Bereitschaft für Unerwartetes (Offenheit)
D	2. Induktion	Definition von Induktion: Theorie entsteht aus Daten, nicht vorab
E	4. Offenheit / Induktion	Könnte auch als Konzept der Sättigung verstanden werden (eher induktiv), aber zeigt auch Offenheit gegenüber dem Material

Häufige Fehler:

- ■ A nur mit Reflexivität verbinden, aber 1. Interpretativismus vergessen
- ■ E mit „Offenheit“ verwechseln (ist eher Konzept der **Sättigung**, ein *Ergebnis* von Induktion)

Lösung zu Übung 2:

1. Welches Paradigma-Merkmal?

Antwort: Induktion und Offenheit

- **Induktion:** Die Theorie wird aus den Daten *generiert*. Mit jeder neuen Information verfeinern sich die Forschungsfragen → iterativer Prozess
- **Offenheit:** Der PT war offen für das unerwartete Material (Partner als relevante Perspektive), statt stur das Originaldesign durchzuziehen

2. Ist das methodisch sauber oder fehlerhaft?

Antwort: Methodisch sauber und sogar geboten.

Begründung:

Das ist nicht „fehlende Planung“, sondern **kontrollierte Anpassung im Sinne des qualitativen**

Paradigmas. Qualitative Forschung ist *emergent* (emergierendes Design). Das bedeutet:

- Design ist *nicht starr*, sondern flexibel
- Neue Erkenntnisse führen zu Sampling-Anpassungen
- Das ist systematisch, nicht willkürlich

Kernprinzip: Induktion mit iterativen Schleifen (Datenerhebung ↔ Analyse ↔ Theorie-Verfeinerung).

3. Wie heißt der neue Sampling-Typ?

Antwort: Purposive Sampling (absichtliche/zielgerichtete Auswahl) oder spezifischer: **Snowballing/Chain Referral Sampling** (wenn Partner von Patienten empfohlen werden) oder **Theoretical Sampling** (wenn neue Fälle gezielt zur Theorieverdichtung ausgewählt werden).

Am wahrscheinlichsten: **Theoretical Sampling**

→ Die Partner werden bewusst ausgewählt, weil sie die theoretische Kategorie „Unterstützungssystem“ verdichten.

Lösung zu Übung 3:

1. Welche 3 Gütekriterien nutzt der PT?

Gütekriterium	Wie der PT es nutzt
Reflexivität / Verfahrensdokumentation	Dokumentation des Vorverständnisses („Ich bin selbst PT ...“) → macht transparent, wie die eigene Position Interpretation prägen könnte
Intercoder-Reliabilität	2 Kollegen kodieren nach gleichem Schema → wenn ihre Ergebnisse ähnlich sind, ist das Vorgehen reproduzierbar und nicht bloß subjektiv
Kommunikative Validierung	Ergebnisse mit den Therapeuten rückgekoppelt → Fragen: „Stimmt das mit eurer Erfahrung überein?“ → Überprüfung, ob Interpretation gültig ist

2. Hawthorne-Effekt: Fehler oder Feature?

Antwort: Feature des qualitativen Paradigmas, keine Störquelle.

Begründung:

Der Hawthorne-Effekt zeigt, dass der Beobachter *Teil des Feldes ist* (Reflexivität).

Sichtweise	Begründung
■ Quantitativ (würde sagen: Fehler)	Der Effekt verfälscht die „objektive“ Realität → Verzerrung
■ Qualitativ (richtig)	Die Reaktion auf Beobachtung ist <i>selbst Daten</i> . Sie zeigt: Wie verhandeln Therapeuten ihre Professionalität? → Erkenntnisgewinn

Konsequenz: Der PT sollte nicht versuchen, den Effekt zu eliminieren, sondern ihn transparent machen und analysieren:

- „Was bedeutet es, dass sich Therapeuten ‚vorbildlicher‘ verhalten, wenn sie beobachtet werden?“
→ Das sagt etwas über Normen, Rollenbewusstsein, Impression Management aus.

3. Antwort auf die Kritik (8 Interviews = zu wenig?)

Antwort: 8 Interviews können ausreichend sein.

Begründung:

Punkt	Erklärung
Theoretische Sättigung	Es zählt nicht die absolute Zahl, sondern: Erreiche ich neue Erkenntnisse oder wiederhole ich nur noch bekannte Aussagen? Nach 8 Interviews mit guter Offenheit kann Sättigung erreicht sein
Purposive Sampling	Die 8 Interviews sind nicht zufällig, sondern absichtlich gewählt (z.B. verschiedene Erfahrungslevel, Geschlechter, Patienten-Typen). Das kompensiert die kleine Zahl
Tiefe statt Breite	Qualitative Forschung zielt auf Tiefe und Detailreichtum, nicht auf statistische Repräsentativität. 8 intensive Interviews können mehr Erkenntnis bringen als 200 oberflächliche
Ethnografische Komponente	Der PT beobachtet auch 6 Wochen lang. Das <i>ergänzt</i> die Interviews und erhöht die Datenqualität (Triangulation)

Fazit: Die Kritik verwechselt qualitatives mit quantitativem Paradigma. Die richtige Frage ist nicht „Sind 8 genug?“, sondern „Ist die theoretische Sättigung erreicht?“

4. Bonus – Soll der PT seine Vorurteile eliminieren?

Antwort: Nein. Er soll sie transparent machen und reflexiv nutzen.

Fehler	Richtige Strategie
■ „Ich versuche, unvoreingenommen zu sein“ (=Selbstbetrug)	■ „Ich dokumentiere: ‚Ich glaube an Empathie. Das könnte mich blind für Gegenbeispiele machen‘“
■ Vorverständnis verstecken	■ Vorverständnis nutzen als <i>Erkenntnismittel</i>
■ „Objektivität durch Distanz“	■ „Nähe zum Gegenstand mit kritischer Selbstprüfung“

Kerngedanke: Der Glaube an Empathie ist *nicht schlecht*, sondern eine **Brille**, durch die der PT **das Feld sieht**. Wichtig ist: Er macht die Brille sichtbar und überprüft, ob das Material auch *andere* Deutungen erlaubt.

HÄUFIGE FEHLER (Zusammenfassung)

Fehler	Richtige Antwort
■ „Kleine Stichproben sind unprofessionell“	■ Purposive Sampling ist gezielt und wissenschaftlich; zählt nicht die Zahl, sondern Sättigung
■ „Der PT sollte objektiv sein“	■ Der PT sollte reflexiv sein; Vorverständnis transparent machen
■ „Design-Änderungen zeigen schlechte Planung“	■ Emergentes Design ist Kern qualitativer Forschung (Induktion)
■ „Hawthorne-Effekt ist Fehler, der eliminiert werden muss“	■ Er ist Teil der Realität und selbst Erkenntnis (Reflexivität)
■ „Intercoder-Reliabilität nur bei Quantitativ“	■ Auch qualitativ: Mehrere Kodierer → gleiche Kategorien? (Regelgeleitetheit)
■ „Subjektivität verfälscht Ergebnisse“	■ Unreflektierte Subjektivität ist ein Problem; reflektierte ist die Stärke

1. Die Grundunterscheidung

Zwei Forschungslogiken, nicht zwei Lager:

Merkmal	Quantitativ	Qualitativ
Logik	deduktiv (Theorie → Daten)	induktiv (Daten → Theorie)
Ziel	testen, messen, verallgemeinern	verstehen, erkunden, beschreiben
Daten	Zahlen, Skalen	Texte, Aussagen, Beobachtungen
Stichprobe	groß, repräsentativ	klein, zweckgerichtet
Gütekriterien	Validität, Reliabilität, Objektivität	Glaubwürdigkeit, Transferierbarkeit, Reflexivität
Ergebnis	replizierbar, generalisierbar	situationsbezogen, kontextabhängig

Metapher: Quantitativ ist wie ein Thermometer – präzise, aber es misst nur Temperatur. Qualitativ ist wie ein Gespräch über Kälteempfinden – reichhaltig, aber nicht skalierbar.

2. Welche Methode für welche Frage?

Die Fragestellung entscheidet – nicht persönliche Vorliebe.

- „**Wie wirksam ist X?**“ → quantitativ (RCT, Messung, p-Wert)
- „**Wie erleben Patient:innen X?**“ → qualitativ (Interview, Inhaltsanalyse)
- „**Warum hat die Intervention nicht gewirkt?**“ → qualitativ als Ergänzung
- „**Welche Faktoren spielen überhaupt eine Rolle?**“ → erst qualitativ (explorativ), dann quantitativ (testend)

■ ■ **Prüfungsfalle:** „Qualitativ = weich = schlechter“ ist falsch. Für manche Fragen ist qualitativ das einzig sinnvolle Vorgehen.

3. Gütekriterien im Vergleich

Qualitative Forschung hat eigene Standards – keine abgeschwächten Versionen der quantitativen:

Quantitativ	Qualitativ (Pendant)
Objektivität	Intersubjektive Nachvollziehbarkeit
Reliabilität	Zuverlässigkeit / Konsistenz
Validität	Glaubwürdigkeit / kommunikative Validierung
Generalisierbarkeit	Transferierbarkeit

4. Mixed Methods – Mehr als Addition

Mixed Methods bedeutet **nicht**: „Wir machen einen Fragebogen und auch ein Interview.“

Definition: Quantitative und qualitative Daten werden **geplant integriert** und **gemeinsam ausgewertet**, um eine Frage zu beantworten, die keine Methode alleine beantworten kann.

Kombinationslogiken

Sequenziell explorativ (qual → quan):

- Erst qualitativ: Was sind die relevanten Konzepte?
- Dann quantitativ: Wie verbreitet sind sie?
- Beispiel: Interviews mit Schlaganfallpatient:innen → Fragebogenentwicklung → Validierungsstudie

Sequenziell erklärend (quan → qual):

- Erst quantitativ: Signifikanter Effekt, aber warum?
- Dann qualitativ: Vertiefung der Erklärung
- Beispiel: RCT zeigt Wirksamkeit nur bei Teilgruppe → Interviews zur Erklärung

Simultan (parallel/triagulierend):

- Beide Methoden gleichzeitig, unabhängig erhoben
- Ergebnisse werden am Ende verglichen / integriert
- Beispiel: Gleichzeitig Schmerzskala messen + Erlebnisbericht erfassen

Warum Mixed Methods in PT/ET besonders relevant?

- Klinische Komplexität: Wirksamkeit **und** Erleben sind beide relevant
- Therapieprozesse sind schwer vollständig zu quantifizieren
- Patientenperspektive ist inhärent qualitativ

5. Typische Prüfungsfragen – Muster erkennen

Zuordnung Fragestellung → Methode:

„Eine Forscherin möchte verstehen, welche Barrieren Physiotherapeut:innen bei der Umsetzung evidenzbasierter Praxis erleben.“ → qualitativ

Design-Logik:

„Zuerst werden Leitfadeninterviews durchgeführt, um relevante Themen zu identifizieren. Darauf basierend wird ein Fragebogen entwickelt und an 200 Personen erhoben.“ → sequenziell explorativ (qual → quan)

Fehleridentifikation:

„Die Studie nutzt Mixed Methods: Es wurde ein Fragebogen und zusätzlich ein Interview gemacht, aber nur die Fragebogendaten wurden ausgewertet.“ → kein Mixed Methods – fehlende Integration

6. Kompakte Merkliste

- Quantitativ: deduktiv, testen, Zahlen, replizierbar
- Qualitativ: induktiv, erkunden, Texte, kontextsensibel
- Mixed Methods: geplante Integration beider Zugänge
- Reihenfolge (qual→quan vs. quan→qual) verändert die Erkenntnislogik
- Kein Paradigmenkrieg: Fragestellung entscheidet

Erklär-es-zurück-Frage

Eine Kollegin sagt: „Unsere Studie ist Mixed Methods – wir haben den DASH-Fragebogen ausgefüllt und danach noch kurz mit den Patient:innen gesprochen.“

Erkläre ihr, warum das noch kein Mixed Methods ist, und beschreibe, was fehlen würde, damit es eines wird. Nenne außerdem, welche Kombinationslogik hier sinnvoll wäre und warum.

Übungen

3 Übungsaufgaben – Kapitel 6: Quantitativ–Qualitativ–Mixed Methods

■ ÜBUNG 1 (Einstieg) – Zuordnung + Kurzbegründung

Aufgabe

Vier Forschungsfragen. Ordne jeder **quantitative (Q)** oder **qualitative (Q')** Methode zu und begründe in **einem Satz**.

#	Frage	MBegründung		
1	Wie erleben Patient:innen mit Fibromyalgie ihre Schmerzen im Alltag?			
2	Ist die Schmerzreduktion nach 12 Wochen Beckenbodentraining signifikant höher als in der Kontrollgruppe?			
3	Welche Faktoren beeinflussen die Compliance in der Heimübungspraxis?			
4	Wieviele Prozent der geriatrischen Patient:innen nutzen die empfohlenen Hilfsmittel korrekt?			

■ Musterlösung

#	Frage	Methode	Begründung
1	Wie erleben Patient:innen mit Fibromyalgie ihre Schmerzen im Alltag?	Qualitativ	Erleben = subjektive, reichhaltige Beschreibung; Induktives Verstehen erforderlich

2	Ist die Schmerzreduktion nach 12 Wochen Beckenbodentraining signifikant höher als in der Kontrollgruppe?	Quantitativ	Vergleich zweier Gruppen, Hypothesentest, numerischer Unterschied – deduktiv
3	Welche Faktoren beeinflussen die Compliance in der Heimübungspraxis?	Qualitativ (explorativ erste Phase)	Explorative Frage; später könnte quantitativ folgen → Sequential Explorativ sinnvoll
4	Wieviel Prozent der geriatrischen Patient:innen nutzen die empfohlenen Hilfsmittel korrekt?	Quantitativ	Prozentualer Anteil, Häufigkeit; Messung an großer Stichprobe

■ Häufiger Fehler

- **Fehler:** Frage 3 als „quantitativ“ einstufen, weil „Faktoren“ gemessen werden könnten
- **Warum falsch:** Das Wort „welche“ signalisiert exploratives Offenlegen → erst qualitativ klären, **was** die Faktoren überhaupt sind; dann quantitativ, **wie stark** sie wirken
- **Richtig merken:** „Welche/Was/Wie erleben“ → Qualitativ | „Wieviel/Wie stark/Unterschied“ → Quantitativ

■ ÜBUNG 2 (Mittel) – Mini-Fall: Methodenwahl begründen

Aufgabe

Szenario:

Eine Physiotherapeutin möchte untersuchen, warum ihr Rückenschmerz-Programm in der Klinik sehr wirksam ist (80 % Verbesserung nach 6 Wochen), aber wenn Patient:innen es zu Hause allein machen, nur 30 % verbessern sich. Sie plant eine Studie.

Aufgabenteile:

a) Welche Methode wäre NICHT sinnvoll und warum nicht?

- Option A: Eine RCT, um zu prüfen, ob das Programm generell wirkt
- Option B: Leitfadeninterviews mit Patient:innen, die zu Hause trainieren, zu ihren Barrieren und Ressourcen

- Option C: Eine quantitative Befragung mit standardisiertem Fragebogen zu Compliance-Hindernissen

b) **Beschreibe eine sinnvolle Mixed-Methods-Struktur für diese Frage. Welche Kombinationslogik (explorativ/erklärend/simultan)?**

c) **Nenne mindestens 2 qualitative und 2 quantitative Gütekriterien, auf die die Forscherin achten sollte.**

■ Musterlösung

a) **Welche Methode NICHT sinnvoll?**

Antwort: Option A (RCT)

- **Begründung:** Die Wirksamkeit des Programms selbst ist bereits nachgewiesen. Die Frage lautet nicht „Wirkt es?“ sondern „Warum wirkt es in der Klinik, aber nicht zu Hause?“
- Eine neue RCT würde Ressourcen verschwenden; sie würde das **Implementierungs-/Adhärenzproblem nicht klären.**
- Option B und C sind beide sinnvoll und könnten kombiniert werden.

b) **Sinnvolle Mixed-Methods-Struktur:**

Empfehlung: Sequenziell explorativ (Qualitativ → Quantitativ)

Phase 1 (Qualitativ):

- Leitfadeninterviews mit ~12–15 Heimübungs-Patient:innen (variiert: gut adhären, schlecht adhären)
- Offene Fragen: „Was hilft/hindert Sie, die Übungen regelmäßig zu machen?“
- **Ziel:** Identifikation von Barrieren/Enabler (z. B. Zeitmangel, Schmerzangst, fehlende Verständnis, Monotonie, soziale Unterstützung)

Phase 2 (Quantitativ):

- Basierend auf Phase 1: Entwicklung eines Compliance-Fragebogens
- Erhebung an größerer Stichprobe (n = 50–100)
- Messung der Häufigkeit und Stärke der identifizierten Barrieren
- **Ziel:** Validierung und Priorisierung der Hindernisse; Basis für Interventionsentwicklung

Phase 3 (optional):

- Angepasstes Heimprogramm basierend auf Barrieren (z. B. Kurzvideos statt Handzettel; wöchentliche Kurznachrichten; Telecoaching)
- Evaluativ: Verbesserte Compliance messbar?

Warum diese Logik?

Man muss erst verstehen (**was sind die Probleme?**), bevor man messen kann (**wie groß sind sie?**).

c) Gütekriterien:

Qualitativ (für Phase 1):

1. **Glaubwürdigkeit (credibility):** Datentriangulation (mehrere Interviewte mit unterschiedlichen Adhärenzmustern); Member Checking (Ergebnisse zurück an Interviewte)
2. **Reflexivität:** Transparenz über Forscherrolle (Therapeutin könnte Bias haben → externe Interviewer oder offengelegte Reflexion)

Quantitativ (für Phase 2):

1. **Reliabilität:** Cronbachs $\alpha \geq 0,70$ für neu entwickelte Skalen
2. **Validität:** Faktorenstruktur überprüfen (Faktorenanalyse); Zusammenhang mit objektiver Compliance (z. B. Tagebuch)

■ Häufiger Fehler

- **Fehler:** „Wir machen einfach beide Methoden parallel: RCT + Interviews zum gleichen Zeitpunkt“
- **Warum problematisch:** Das ist zwar Mixed Methods (simultan), aber nicht für **diese Frage** optimal. Man müsste erst klären, **was** die Barrieren sind, bevor man sie messen kann.
- **Richtig:** Erkenne, dass die **Reihenfolge der Kombinationslogik** von der Forschungsfrage abhängt!

■ ÜBUNG 3 (Schwierig) – Fallanalyse + Kritik

Aufgabe

Vollständiger Mini-Forschungsbericht (gekürzt):

Titel: „Wirksamkeit und Erleben eines innovativen Tanzprogramms für Patient:innen mit Morbus Parkinson“

Design: Mixed Methods

Phase 1: 14 Patient:innen durchlaufen 8 Wochen Tanztherapie. Vor und nach: Berg Balance Scale (BBS), Timed Up and Go (TUG) gemessen.
Nach 8 Wochen: offene Interviews zu Erfahrungen.

Ergebnisse (Quantitativ):

- BBS: Ø 35 → 39 Punkte (Steigerung 4 Punkte; $p = 0,08$)
- TUG: Ø 18 → 16 Sekunden ($p = 0,12$)
- **Schlussfolgerung:** „Das Programm zeigt Tendenzen, ist aber nicht signifikant wirksam.“

Ergebnisse (Qualitativ):

- Interviews: Zentrale Themen: „Selbstvertrauen gewonnen“, „mehr Beweglichkeit“, „Freude und soziale Kontakte“, „weniger Angst vor Stürzen“
- **Zitat:** „Ich traue mich jetzt wieder, mit meiner Partnerin zu tanzen.“
- **Interpretation der Interviewer:** „Das Programm führt zu psychosozialen und funktionellen Verbesserungen über Messungen hinaus.“

Gesamtkonklusion: „Mixed-Methods-Studien zeigen, dass objektivierbare Kennzahlen nicht alles sind. Das Tanzprogramm ist wertvoll und sollte empfohlen werden.“

Aufgabenteil A: Design-Bewertung

Bewerte folgende Aussagen als WAHR oder FALSCH und begründe (je max. 2 Sätze):

#	Aussage	Begründung	
1	Dies ist ein echtes Mixed-Methods-Design, weil quantitative und qualitative Daten kombiniert wurden.		
2	Die Kombination ist sequenziell erklärend (quan → qual).		
3	Ein p-Wert von 0,08 bedeutet, dass die Intervention „nicht wirkt“.		
4	Wenn die qualitative Analyse zeigt „Freude und Vertrauen“, kann man daraus schließen, dass der p-Wert statistisch zu konservativ war.		

Aufgabenteil B: Methodenkritik

Identifiziere **zwei substanzielle Qualitätsprobleme** bei dieser Studie und schlage jeweils **eine Verbesserung** vor:

Problem	Verbesserungsvorschlag
Problem 1:	Maßnahme:
Problem 2:	Maßnahme:

Aufgabenteil C: Integration

Die Forscherin schreibt im Discussion: „Unsere qualitative Analyse zeigt, dass die Patienten profitieren, obwohl die quantitativen Messwerte nicht signifikant sind. Das bedeutet, dass qualitative Daten ‚mehr Wahrheit‘ haben als statistische Tests.“

Reagiere auf diese Aussage: Ist das eine gültige Interpretation von Mixed Methods? Warum / warum nicht? (max. 4 Sätze)

■ Musterlösung

Aufgabenteil A: Design-Bewertung

#	Aussage	W/F	Begründung
1	Dies ist ein echtes Mixed-Methods-Design, weil quantitative und qualitative Daten kombiniert wurden.	FALSCH	Kombinierte Datenerhebung ist nötig, aber nicht hinreichend für Mixed Methods; es fehlte eine geplante Integration und gemeinsame Interpretation . Die Daten wurden additiv (getrennt) interpretiert.
2	Die Kombination ist sequenziell erklärend (quan → qual).	WAHR	Quantitative Messungen zuerst (BBS, TUG) → Interviews danach zur Erklärung des „Warum“. Typische quan → qual Logik.
3	Ein p-Wert von 0,08 bedeutet, dass die Intervention „nicht wirkt“.	FALSCH	p = 0,08 ist nicht signifikant <i>auf dem Niveau $p < 0,05$</i> , aber „nicht signifikant“ $\neq$ „nicht wirksam“. Trend vorhanden; möglicherweise underpowered (n=14 ist klein).

4	Wenn die qualitative Analyse zeigt „Freude und Vertrauen“, kann man daraus schließen, dass der p-Wert statistisch zu konservativ war.	FALSCH	Qualitative Befunde können Quantitative nicht ersetzen oder „über“-stimmen. Sie messen andere Konstrukte (subjektiv-psychosozial vs. objektiv-motorisch). Eine echte Integration hätte beide Perspektiven synergistisch genutzt, z. B. „motorisch unauffällig, aber psychosozial bedeutsam – warum?“.
---	---	---------------	---

Aufgabenteil B: Methodenkritik

Problem	Verbesserungsvorschlag
Problem 1: Fehlende Kontrollgruppe / Single-Arm-Design – Ohne Vergleichsgruppe lässt sich nicht klären, ob Verbesserungen vom Tanzprogramm oder von Maturation/Placebo stammen.	Maßnahme: RCT mit Wartelist-Kontrollgruppe; oder zumindest quasi-experimentelles Design mit historischer Kontrolle.
Problem 2: Kleine Stichprobe (n=14) mit unzureichender statistischer Power – Die p-Werte von 0,08–0,12 deuten auf Underpowerung hin; mit n=14 können klinisch relevante Effekte statistisch nicht nachgewiesen werden.	Maßnahme: Poweranalyse im Voraus; prospektive Fallzahlplanung (z. B. für Effektgröße $d=0,6$: $n \sim 50$); alternativ: Effektstärken (Cohen's d) mit 95% CI statt p-Werte berichten.
<i>(optional 3)</i> Interviewer-Bias: Da die Interviewer auch die Therapeuten waren, besteht Bias-Risiko (Patient:innen geben positive Antworten, um Therapeut zu gefallen).	Maßnahme: Externe, unverbundene Interviewer; oder anonymisierte schriftliche Befragung; Reflexivität dokumentieren.

Aufgabenteil C: Integration und Mixed-Methods-Philosophie

Antwort:

Nein, das ist eine **ungültige Interpretation** von Mixed Methods und ein Kategorienfehler.

Qualitative und quantitative Daten beantworten **unterschiedliche Fragen**:

- **Quantitativ** (BBS, TUG): „Ist die motorische Kontrolle/Gleichgewicht objektiv messbarer besser?“
- **Qualitativ** (Interviews): „Wie erleben und bewerten Patient:innen ihre Veränderung?“

Dass qualitative Befunde „positiv“ und quantitative „nicht signifikant“ sind, ist **nicht widersprüchlich** – es zeigt, dass das Programm **psychosoziale Effekte hat, ohne (oder mit marginalem) Effekt auf standardisierte motorische Tests**. Das ist eine valide Erkenntnis, nicht ein Beweis, dass „Qualitativ besser ist“.

Echte Integration hätte so funktioniert: „Obwohl die motorischen Messwerte nicht signifikant verbessern, berichten Patient:innen von erhöhtem Selbstvertrauen und Aktivität → Hypothese: Das Programm wirkt über psychosoziale Mechanismen. Nächste Studie sollte diese Mechanismen (Selbstwirksamkeit, Angstabbau) als **primäre Outcomes** messen.“

Kurz: **Nicht „qualitativ schlägt quantitativ“, sondern „beide sagen uns etwas anderes – zusammen sind sie informativer.“**

■ Häufigste Fehler in dieser Aufgabe

Fehler: „Die p-Werte sind nicht signifikant, also war die Studie gescheitert – aber die qualitative Analyse rettet sie.“

- **Warum falsch:** Nicht-Signifikanz = Misserfolg, aber gibt keine Berechtigung, nur qualitative Daten als „Wahrheit“ zu nehmen. Die Frage war „Wirkt es motorisch?“ (Antwort: unklar, underpowered). Die qualitative Frage war „Wie wird es erlebt?“ (Antwort: positiv). **Zwei verschiedene Fragen.**

Fehler: „Mixed Methods bedeutet, dass man mehr Daten hat → mehr Gewissheit.“

- **Warum falsch:** Mixed Methods ist kein „mehr ist mehr“. Es ist eine **geplante Strategie**, unterschiedliche Perspektiven zu nutzen. Wenn Daten nicht integriert werden, ist es nur Multi-Method, nicht Mixed Methods.

Fehler: Aussage 4 als WAHR einstufen.

- **Warum falsch:** Man kann qualitative Befunde nicht nutzen, um quantitatives p-Werte „nachträglich“ zu interpretieren. Das ist selektive Interpretation. Wenn $p = 0,08$ und man Qualitatives sieht, dann heißt das: „Interessant, aber brauchen größere N.“ Nicht: „Qualitativ ist da Beweis genug.“

■ Zusammenfassung: Was die Prüfung testet

Kompetenz	ÜbÜbÜbung		
	1	2	3
Fragestellung → Methode zuordnen		✓	✓

Kombinationslogik verstehen (seq. explorativ vs. erklärend)			✓	✓
Gütekriterien differenzieren (qual vs. quan)			✓	
Mixed Methods kritisch beurteilen				✓
Statistische Literacy (p-Wert, Power)				✓
Design-Fehler identifizieren			✓	✓

■ Für die Prüfung merken

- **Grundregel:** Methode folgt aus Frage, nicht umgekehrt
- **Gütekriterien sind nicht identisch**, aber gleichwertig
- **Mixed Methods $\neq$ Fragebogen + Interview**, sondern geplante Integration
- **Kombinationslogik hat Sinn:** Welche Frage zuerst klären?
- **Nicht signifikant $\neq$ nicht wirksam** (vor allem bei kleinen Stichproben)
- **Qualitativ und Quantitativ können beide Recht haben** – auf unterschiedliche Fragen

Überblick: Was sind Gütekriterien?

Gütekriterien sind **Qualitätsstandards**, die beurteilen, ob eine Messung, ein Test oder eine ganze Studie **verlässlich und aussagekräftig** ist. Sie sind das Gerüst, auf dem empirische Forschung steht – ohne sie können Sie keine Aussagen trauen.

Es gibt zwei parallel verlaufende Systeme:

- **Quantitative Gütekriterien:** Validität, Reliabilität, Objektivität
- **Qualitative Gütekriterien:** Credibility, Dependability, Confirmability, Transferability

Quantitative Gütekriterien

1. Reliabilität (Zuverlässigkeit)

Was wird gemessen? Wie **konsistent und reproduzierbar** ist ein Messinstrument?

Metapher: Eine Waage, die immer dieselbe Messung anzeigt – egal, wie oft Sie sich wiegen.

- **Test-Retest-Reliabilität:** Derselbe Test wird zweimal durchgeführt → ähnliche Ergebnisse?
- **Interne Konsistenz** (Cronbachs α): Erfassen alle Items einer Skala dasselbe Konstrukt?
- **Interrater-Reliabilität:** Zwei Beobachter bewerten das gleiche Phänomen → stimmen sie überein?

Prüfungsfalle: Hohe Reliabilität $\neq$ Validität! Eine Waage kann sehr zuverlässig sein – aber wenn sie 5 kg zu schwer anzeigt, ist sie **valide nicht nutzbar**.

2. Validität (Gültigkeit)

Was wird WIRKLICH gemessen? Misst das Instrument tatsächlich das, was es messen soll?

Drei Validitätstypen:

Validitätstyp	Definition	Beispiel
Inhaltsvalidität	Deckt das Instrument alle relevanten Aspekte des Konstrukts ab?	Ein Angst-Fragebogen sollte Physiologie, Kognition UND Verhalten erfassen
Konstruktvalidität	Misst es wirklich das theoretische Konzept?	Misst dieser „Intelligenztest“ wirklich Intelligenz oder nur Schulwissen?
Kriteriumsvalidität	Korreliert es mit äußeren Kriterien (Verhalten, Zukunftsvorhersage)?	Vorhersagt dieser Rückenschmerztest tatsächlich, wer Chronifizierung entwickelt?

Merksatz: Validität antwortet auf "Was?" – Reliabilität antwortet auf "Wie stabil?"

3. Objektivität

Sind die **Messergebnisse unabhängig vom Untersucher?**

- **Durchführungsobjektivität:** Gleiche Anleitung für alle?
 - **Auswertungsobjektivität:** Keine Interpretationsspielräume bei der Auswertung?
 - **Interpretationsobjektivität:** Klare Regeln für die Befundinterpretation?
-

Qualitative Gütekriterien

Qualitative Forschung braucht **andere Standards** – nicht weil sie weniger streng ist, sondern weil sie andere Ziele verfolgt (Verständnis statt Messung).

1. Credibility (Glaubwürdigkeit)

Wurden die Phänomene **korrekt verstanden**?

- **Mitgliedschaftsprüfung:** Wurden Ergebnisse den Teilnehmern vorgelegt?

- Triangulation: Mehrere Datenquellen/Methoden zur Bestätigung?
- Intensive Feldbeobachtung?

2. Dependability (Verlässlichkeit/Nachvollziehbarkeit)

Kann ich den **Forschungsprozess nachvollziehen**?

- **Audit Trail:** Vollständige Dokumentation aller Entscheidungen
- Konsistenzprüfungen über die Zeit hinweg
- Externe Audit durch anderen Forscher

3. Confirmability (Bestätigbarkeit)

Sind die Ergebnisse **objektiv und nicht nur Meinung des Forschers**?

- Reflexivität: Wurden Vorbiases offengelegt?
- Triangulation der Datenquellen
- Dokumentation der Entscheidungskette

4. Transferability (Übertragbarkeit)

Sind die Ergebnisse auf **andere Kontexte übertragbar**?

- Detaillierte Kontextbeschreibung (thick description)
- Leser:innen können selbst Übertragbarkeit beurteilen
- Sampling und Rekrutierung transparent dokumentiert

Schlüsseldifferenz zu Quantitativ: Qualitative Forschung verzichtet auf statistische Generalisierung – stattdessen auf konzeptuelle Übertragbarkeit durch detailreiche Beschreibung.

Häufige Prüfungsfallen

■■ p-Wert < 0,05 ist KEIN Gütemaß

Ein signifikantes Ergebnis sagt nichts über Validität, Reliabilität oder praktische Bedeutsamkeit aus. Eine große Stichprobe macht auch ungültige Messungen „statistisch signifikant“.

■■ Reliabilität und Validität sind nicht austauschbar

Eine perfekt zuverlässige Messung kann völlig das falsche messen.

■■ Qualitative Gütekriterien sind nicht „einfacher“

Ein Audit Trail zu führen ist mindestens so aufwendig wie eine Validierungsstudie – nur anders.

Checkliste für Publikationskritik

Bei der Bewertung von Studien fragen Sie:

- ☐ Ist das Messinstrument validiert?
- ☐ Sind Reliabilitätskoeffizienten berichtet ($\alpha > 0,70$)?
- ☐ Wurde die Stichprobe beschrieben?
- ☐ Gibt es Verzerrungen (Bias)?
- ☐ Passen Design und Gütekriterien zur Forschungsfrage?

Erklär-es-zurück-Frage

Beschreiben Sie einer Kolleg:in:

Ein Beweglichkeitstest kann sehr **reliabel** sein, aber trotzdem klinisch **nicht valide**. Geben Sie ein konkretes Beispiel und erklären Sie, warum das möglich ist.

(Musterlösung: Test misst konsistent Schulterbeweglichkeit → aber nicht das, was im klinischen Kontext zählt [z.B. funktionelle Griffstärke], oder nutzt falsches Körpersegment)

Übungen

3 Übungsaufgaben: Gütekriterien empirischer Forschung

ÜBUNG 1 (Einstieg): Zuordnung & Konzeptverständnis

Aufgabe 1.1 – Zuordnung

Ordnen Sie jedes Szenario dem passenden quantitativen Gütekriterium zu:

Szenario	Kriterium
A) Eine Schmerzskala zeigt bei Test und Retest sehr ähnliche Werte ($r = 0,87$)	1. Objektivität
B) Ein depressionstest korreliert stark mit späteren Therapie-Outcomes	2. Validität
C) Zwei Therapeuten führen die gleiche Bewegungsprüfung unterschiedlich durch	3. Reliabilität
D) Ein Gleichgewichtstest erfasst nur Standsicherheit, nicht motorische Kontrolle	4. Validität
E) Ein standardisiertes Interview mit klaren Anweisungen reduziert Interpretationsspielraum	5. Reliabilität

Lösungsformat: A–3, B–?, C–?, D–?, E–?

Aufgabe 1.2 – Mini-Fall: Diagnostisches Gerät

Eine Klinik kauft ein neues **Ultraschall-Diagnose-Gerät** für die Achillessehnen-Messung.

- Das Gerät zeigt sehr genaue Messwerte ($\pm 0,1$ mm)
- Die Messwerte sind reproduzierbar (wenn derselbe Untersucher zweimal misst)
- **ABER:** Die Messwerte korrelieren NICHT mit klinischen Symptomen oder funktionalen Tests

Frage:

1. Welches Gütekriterium ist hier erfüllt?
 2. Welches ist verletzt?
 3. Warum ist das Gerät trotzdem problematisch?
-

Zeitbudget: 8 Minuten

ÜBUNG 2 (Mittel): Mini-Studie interpretieren

Aufgabe 2.1 – Fallstudie: Qualitative Forschung

Eine qualitative Studie untersucht „**Patientenerfahrungen bei chronischem Rückenschmerz**“.

- 20 Interviews mit Patienten
- Analytiker: 1 Person
- Prozess: Interviews transkribiert, kodiert, Kategorien gebildet
- **Limitation:** „Ergebnisse wurden nicht den Patienten zur Rückmeldung vorgelegt“

Fragen:

Welches qualitative Gütekriterium wird hier vernachlässigt?

- A) Transferability
- B) Credibility
- C) Dependability
- D) Confirmability

Welche konkrete Methode könnte dies verbessern?

Aufgabe 2.2 – Qualitativer vs. Quantitativer Bias

Szenario:

In einer **quantitativen Studie** wird die Effektivität einer Therapie getestet. Der p-Wert ist $p = 0,03$ (signifikant).

Szenario B:

In einer **qualitativen Studie** werden 10 Patienten interviewt. Der Forscher kennt die Patienten seit Jahren persönlich.

Frage für beide Szenarien:

- In welchem Fall ist das **Güterisiko größer** und warum?
 - Nennen Sie für jedes Szenario **ein Gütekriterium**, das gefährdet ist.
-

Zeitbudget: 10 Minuten

ÜBUNG 3 (Schwer): Kritisches Appraisal

Aufgabe 3.1 – Studien-Kritik mit Gütekriterien

Abstrakt einer veröffentlichten Studie:

„Wir entwickelten einen neuen 5-Item-Fragebogen zur Therapie-Adhärenz (TAQ-5). Cronbachs $\alpha = 0,68$. Der Fragebogen wurde 50 Physiotherapeuten vorgelegt zur Inhaltsvalidierung. 89 % stimmten zu, dass alle Items relevant sind. Wir verglichen TAQ-5 mit dem etablierten Adhärenz-Index ($r =$

0,54, $p = 0,12$). Mit diesem Instrument untersuchten wir 200 Patienten; 78 % zeigte hohe Adhärenz und bessere Outcomes ($p < 0,001$)."

Fragen (komplexes Denken):

3.1.1 – Reliabilität:

- Ist Cronbachs $\alpha = 0,68$ akzeptabel?
- Warum ist das für eine neue Skala relevant (vs. für etablierte Tests)?

3.1.2 – Validität im Detail:

- Die Inhaltsvalidität wurde durch **Expertenconsensus** geprüft (89 %).
- **Pro:** Was spricht dafür?
- **Contra:** Was ist das Problem?
- Die Korrelation mit dem etablierten Test ist $r = 0,54$, $p = 0,12$.
- Interpretieren Sie: Ist das ein gutes Zeichen für Kriteriumsvalidität? Warum (nicht)?

3.1.3 – Das $p < 0,001$ bei Outcomes:

- "78 % zeigten hohe Adhärenz und bessere Outcomes ($p < 0,001$)"
- Welches Gütekriterium wird hier **verwechselt/überinterpretiert**?
- Was sagt $p < 0,001$ über die Validität des TAQ-5 aus?

3.1.4 – Gesamtbeurteilung (Synthesefrage):

Darf dieses Instrument in der Klinik eingesetzt werden?

- Nennen Sie **mindestens 2 Gütedefizite**, die beheben werden sollten.
- Was wäre der nächste logische Forschungsschritt?

Zeitbudget: 12 Minuten

MUSTERLÖSUNGEN

Lösung Übung 1

1.1 – Zuordnung (Antwortschlüssel)

Szenario	Kriterium	Begründung
A) Test-Retest $r = 0,87$	3. Reliabilität	Reproduzierbarkeit über Zeit = Kernmerkmal der Reliabilität
B) Korrelation mit Outcomes	2. Validität	Kriteriumsvalidität: Externe Vorhersagekraft

C) Unterschiedliche Durchführung zweier Therapeuten	1. Objektivität	Durchführungsobjektivität verletzt
D) Test erfasst nur Standsicherheit, nicht motorische Kontrolle	2. Validität	Inhaltsvalidität verletzt (unvollständige Operationalisierung)
E) Standardisierte Anweisungen, klare Regeln	1. Objektivität	Auswertungs- und Interpretationsobjektivität gestärkt

Häufige Fehler:

- ■ Confusing C mit Reliabilität (ist aber Objektivität-Mangel)
- ■ D mit Reliabilität verwechseln (ist Validität)

1.2 – Mini-Fall: Das präzise, aber ungültige Gerät

Antworten:

Erfüllte Gütekriterien:

- ■ **Reliabilität** ($\pm 0,1$ mm, reproduzierbar)
- ■ **Objektivität** (mechanisch präzise)

Verletztes Kriterium:

- ■ **Validität** (insbesondere Kriteriumsvalidität)
- Das Gerät misst nicht das, das klinisch relevant ist

Warum problematisch?

- *Merksatz:* **Reliabel** $\neq$ **Valide**
- Das Gerät ist eine hochpräzise, aber **falsche Messung**
- Beispiele für Ursachen:
 - Anatomische Struktur-Messung (Sehne) $\neq$ Funktionales Outcome (Kraft/Schmerz)
 - Messung im Ultraschall $\neq$ Echte klinische Belastbarkeit
 - **Klinische Konsequenz:** Therapeuten ignorieren die Messwerte; Investition nutzlos

Häufiger Fehler:

- "Das Gerät ist nicht reliabel" – **Falsch!** Es ist SEHR reliabel, aber nicht valide.

Lösung Übung 2

2.1 – Qualitative Studie: Fehlende Gütekriterium

Antwort: B) Credibility

Begründung:

- **Credibility (Glaubwürdigkeit)** wird durch **Member Checking** (Rückmeldung an Teilnehmende) gewährleistet
- Die Analytikerin interpretiert die Daten – aber wurden die Patienten gefragt: „*Stimmt meine Interpretation?*“
- Ohne Rückmeldung bleibt offen: Wurden Phänomene korrekt verstanden oder nur so interpretiert, wie der Forscher sie sehen wollte?

Verbesserung:

- Transcripts und vorläufige Kategorien mit 8–10 Patienten durchbesprechen
- Oder: **Externe Audit** durch zweiten Kodierer (→ Confirmability)
- Oder: **Triangulation** (Daten + Fokusgruppen + Beobachtung)

2.2 – Qualitativer vs. Quantitativer Bias

Szenario	Größeres Güterisiko	Gefährdetes Kriterium	Warum?
Quant: $p = 0,03$	Gering	Validität (Design evtl. nicht passend)	Signifikanz $\neq$ Validität. Ein signifikantes Ergebnis kann aus einer schlecht designten Studie kommen – sagt aber nichts über reale Effekte. → Problem: Sampling Bias, Confounding
Qual: Forscher kennt Patienten seit Jahren	GRÖßER	Credibility, Confirmability	Beziehungs-Bias: Forscher hat Vorerwartungen; Patienten antworten, wie Forscher „hören will“; Interpretation geprägt durch langjährige Beziehung

Merksatz für Prüfung:

In **qualitativer Forschung** sind **persönliche Nähe und Subjektivität** die Hauptrisiken.

In **quantitativer Forschung** sind **Design-Fehler und Confounding** die Risiken.

Häufiger Fehler:

- "Die qualitative Studie ist weniger rigorös, also größeres Risiko" – Das ist zu oberflächlich. **Beide Designs haben spezifische Güterisiken.**

Lösung Übung 3

3.1.1 – Reliabilität: Cronbachs $\alpha = 0,68$

Ist es akzeptabel?

- **Kurzantwort:** Grenzwertig/gering – **Kritik angebracht**
- **Kontext-Abhängig:**
- Etablierte Tests: Oft $\alpha > 0,80$ erwartet
- **Neue Skalen:** $\alpha > 0,70$ mindestens akzeptiert (Psychometrie-Standards)
- **Kurze Skalen (5 Items):** $\alpha < 0,70$ kann normal sein (weniger Items = mathematisch niedrigeres α)

Kritische Einschätzung für TAQ-5:

- ✓ Mit nur 5 Items ist $\alpha = 0,68$ nicht katastrophal
- ■ **ABER:** Es zeigt, dass die Items nicht homogen sind (Konsistenzproblem)
- ■■ **Implikation:** Die Skala misst möglicherweise mehrere Faktoren, nicht nur "Adhärenz"

Empfehlung:

→ **Weitere interne Konsistenz-Tests nötig** (z.B. Test-Retest-Reliabilität oder Item-Total-Korrelationen) BEVOR Studie mit Patienten

3.1.2 – Validität: zwei Perspektiven

A) Inhaltsvalidität via Expertenconsensus (89%)

PRO:

- ■ Expert-Panel ist saubere Methode zur Inhaltsvalidierung
- ■ 89 % Zustimmung deutet auf Konsens hin

CONTRA (Kritische Sicht):

- ■ **Nur Therapeuten-Perspektive** – Wurden Patienten gefragt? (Content Validity Index sollte auch Patient Voices einbeziehen)
- ■ 89 % ist nicht 100 % – **11 % Disagree ist nicht unbedeutend** bei nur 5 Items (könnte 1 Item betreffen)
- ■ "Relevant sein" ist nicht dasselbe wie "alle Aspekte von Adhärenz abdecken" (Breite der Inhaltsvalidität unklar)

Fazit: Inhaltsvalidität teilweise gezeigt, aber **unvollständig dokumentiert**

B) Kriteriumsvalidität: $r = 0,54$, $p = 0,12$

Interpretation:

- $r = 0,54$ = moderate Korrelation (schwächer als ideal $> 0,70$)

- $p = 0,12$ = NICHT signifikant ($\alpha = 0,05$)
- **Schlussfolgerung:** Die Korrelation könnte Zufall sein (12 % Fehlerwahrscheinlichkeit)

Ist das ein gutes Zeichen? ■ NEIN – gravierendes Problem:

Problem	Interpretation
$r < 0,70$	TAQ-5 korreliert schwach mit etabliertem Test
$p = 0,12$ (n.s.)	Correlation könnte zufällig sein; keine echte Beziehung nachgewiesen
Konsequenz	TAQ-5 misst NICHT dasselbe wie etablierter Test – Kriteriumsvalidität nicht gezeigt

Klinische Implikation:

→ Sind beide Tests valide, oder einer ungültig? Unklar! Mehr Validierungsstudien nötig.

Häufiger Fehler:

■ " $r = 0,54$ ist okay" – In Validierungskontexten ist $r > 0,70$ erwartet; $< 0,70$ ist Grund zur Sorge.

3.1.3 – Das $p < 0,001$ bei Outcomes (Verwechslung)

Zitat kritisch analysieren:

"78 % zeigten hohe Adhärenz und bessere Outcomes ($p < 0,001$)"

Was wird hier verwechselt?

Konzept	Was es bedeutet	Bezug zu TAQ-5-Validität
$p < 0,001$ (Signifikanz)	Unterschied zwischen Gruppen ist wahrscheinlich nicht Zufall	Sagt NICHTS über die Güte von TAQ-5
Validität des TAQ-5	Misst TAQ-5 wirklich Adhärenz?	Bleibt ungeklärt!

Das Problem:

- ■ Die Outcomes sind signifikant besser → das ist eine **separate, gute Beobachtung**
- ■ **ABER:** $p < 0,001$ wird hier als "Beweis, dass TAQ-5 valide ist" gelesen
- ■ Logischer Fehler: Signifikante Outcomes mit TAQ-5 $\neq$ TAQ-5 ist valide

Konkretes Beispiel des Fehlers:

- Szenario: TAQ-5 ist ungültig (misst nur Motivation, nicht echte Adhärenz)
- Trotzdem: Hochmotivierte Patienten haben bessere Outcomes

- Resultat: $p < 0,001$ ist signifikant – **aber TAQ-5 ist immer noch nicht valide**

Merksatz: Signifikanz $\neq$ Validität

Ein Prädiktor kann statistisch sehr signifikant sein ($p < 0,001$), aber aus völlig falschen Gründen funktionieren.

3.1.4 – Gesamtbeurteilung & Nächste Schritte

Darf dieses Instrument in der Klinik eingesetzt werden?

Antwort: NEIN – Nicht ohne weiterer Validierung

Mindestens 2 Gütedefizite, die beheben sollten:

Defizit	Priorität	Warum kritisch?	Lösungsansatz
1. Interne Konsistenz schwach ($\alpha = 0,68$)	■ HOCH	Skala ist nicht homogen; Items hängen nicht zusammen → misst mehrere Dinge statt Adhärenz	Test-Retest machen; Item-Total-Analyse; ggf. Items revidieren
2. Kriteriumsvalidität nicht gezeigt ($r = 0,54$, n.s.)	■ HOCH	TAQ-5 korreliert nicht ausreichend mit etabliertem Test → unklar ob TAQ-5 wirklich Adhärenz misst	Größere Stichprobe; Multi-Trait-Multi-Method (MTMM) Analyse
3. Inhaltsvalidität unvollständig	■ MITTEL	Nur Therapeuten befragt, nicht Patienten	Patientenfokusgruppe; revidierte CVI
4. Keine Prognosevalidität	■ MITTEL	Outcomes sind signifikant, aber das ist nicht dasselbe wie Validität des Instruments	Follow-up: Predicts TAQ-5 Langzeit-Adhärenz/Compliance?

Nächster logischer Forschungsschritt:

Phase 1 (Sofort):

- Item-Analyse und interne Konsistenz verbessern ($\alpha \rightarrow 0,75$)
- Test-Retest-Reliabilität prüfen ($n = 30\text{--}50$ Patienten, 2–4 Wochen Abstand)

Phase 2 (Parallel):

- **Konstruktvalidierung:** Faktorenanalyse (sind wirklich 5 unidimensionale Items oder 2–3 Faktoren?)

- **Kriteriumsvalidierung:** Größere Stichprobe ($n \geq 200$), Korrelation mit Therapie-Compliance beobachten (objektive Messungen: Anzahl besuchter Sitzungen, Übungsfrequenz)

Phase 3:

- Validierung in verschiedenen Patientengruppen (externe Validität)

Häufige Fehler in dieser Aufgabe:

- " $p < 0,001$ bedeutet die Studie ist gut validiert"
- Signifikanz ist orthogonal zu Validität
- " $\alpha = 0,68$ ist ausreichend"
- Im Validierungskontext zu schwach
- "89 % Expert-Zustimmung beweist Inhaltsvalidität"
- Ist nur einer von mehreren Indikatoren; unvollständig

HÄUFIGE FEHLER (Zusammenfassung)

Fehler	Warum falsch	Richtige Denke
"Hohe Reliabilität = hohe Validität"	Unabhängige Eigenschaften	Zuverlässig + falsch = immer noch falsch
" $p < 0,05$ zeigt, dass Instrument valide ist"	Signifikanz $\neq$ Validität	Validität ist über Korrelationen, Konstrukt, Inhalte gezeigt – nicht über p-Werte
"Qualitative Studien sind weniger rigoros"	Andere, nicht niedrigere Standards	Beide haben parallele aber unterschiedliche Gütekriterien
"Cronbachs $\alpha = 0,65$ ist okay"	Abhängig von Kontext (neue vs. etablierte Skala)	Für neue Instrumente: $\alpha \geq 0,70$ Standard; kurze Skalen Ausnahmen
"Expertenconsensus = Inhaltsvalidität vollständig"	Consensus ist nur eine Methode	Muss kombiniert mit: Literaturreview, Patienten-Input, Funktionale Validierung
"Große Stichprobe = bessere Validität"	Confusing statistischer Power mit Construct Validity	Große n mit ungültigem Design = "signifikante Ungültigkeit"

"Test-Retest r = 0,70 ist schlecht"	Abhängig von Konstrukt (Traits vs. States)	Für stabile Traits (Persönlichkeit) ist r = 0,70 akzeptabel; für messbare Outcomes schwach
-------------------------------------	--	--

Zusammenfassung: Lernziele nach den Übungen

Nach Bearbeitung sollten Sie können:

- **Übung 1:** Reliabilität, Validität und Objektivität voneinander unterscheiden
- **Übung 2:** Qualitative und quantitative Güterisiken erkennen
- **Übung 3:** Wissenschaftliche Publikationen kritisch appraisieren und Gütedefizite identifizieren sowie nachfolgende Forschungsschritte vorschlagen

Kernprinzipien qualitativer Forschung

1. Offenheit (nicht = planlos)

Qualitative Forschung arbeitet mit zwei Seiten der Offenheit:

Aspekt	Was bedeutet es?
Offenheit der Forschenden	Bereitschaft, Überraschungen zu akzeptieren; keine Festlegung auf erste Eindrücke
Offenheit des Gegenstands	Der Untersuchungsgegenstand bleibt zunächst vorläufig → neue Pfade können sich öffnen

Wichtig: Offenheit ≠ Beliebigkeit. Qualitative Forschung ist immer **theoriegeleitet**. Die Forschenden bringen Vorwissen mit, explizieren es aber transparent und lassen sich vom Material leiten.

2. Iterativität (der Prozess ist eine Spirale, nicht ein Pfeil)

Der qualitative Forschungsprozess läuft **parallel und zirkulär ab**:

- Datenerhebung und Datenanalyse laufen **gleichzeitig**, nicht sequenziell
- Nach jeder Erhebung: Reflexion, Modifikation, neue Fragen
- Forschungsfrage kann sich **vertiefen oder verschieben** (aber nicht beliebig)
- Stichprobe wächst durch **theoretische Sättigung** – wenn keine neuen Informationen mehr hinzukommen, ist die Stichprobengröße angemessen
- **Nicht planlos**, sondern nach Regeln strukturiert

Beispiel aus der Praxis: Studierende interviewt 5 Therapeuten → analysiert → findet Lücke in bestimmtem Thema → interviewt weitere 3 Personen gezielt → Lücke geschlossen.

3. Kontextualität (Realität ist nicht isolierbar)

Phänomene werden **immer im natürlichen Kontext** erforscht:

- Menschen verhalten sich anders in ihrer natürlichen Umgebung als im Labor
- Soziale, kulturelle, historische Kontexte prägen Wahrnehmung und Handlung
- Verschiedene Personen erleben **dieselbe Situation unterschiedlich**

Nicht verwechseln: Natürlicher Kontext ≠ „unkontrolliert“. Die Forschenden halten fest, wo/wann/unter welchen Bedingungen erhoben wurde – Transparenz ist hier das Kontrollinstrument.

Qualitativ vs. Quantitativ: Der fundamentale Unterschied

Merkmal	Qualitativ	Quantitativ
Ziel	Verstehen von Phänomenen im Kontext (Warum? Wie?)	Messen und Vergleichen (Wie oft? Wie stark?)
Material	Worte, Texte, Bilder, Videos (nicht-numerisch)	Zahlen, Messwerte
Design	Emergent, flexibel, kontextgesteuert	Linear, vorstrukturiert
Analyse-Rhythmus	Parallel zur Erhebung	Nach Abschluss der Erhebung
Fallzahl	Klein, bewusst gewählt; theoretische Sättigung	Große, randomisierte Stichproben
Tiefe vs. Breite	Tiefe, Reichtum an Details	Breite, Repräsentativität

Interpretativismus: Die philosophische Grundlage

Qualitative Forschung ruht auf einem interpretativen Verständnis von Wissenschaft:

Vier Säulen:

Kontextualität als Leitgedanke

Phänomene sind nur im Kontext ihrer Entstehung verstehbar

Perspektiven der Beteiligten

Es gibt nicht *die* Realität, sondern multiple, legitime Perspektiven → Unterschiedlichkeit ist Erkenntnisquelle, nicht Störfaktor

Reflexivität der Forschenden

Der/die Forschende ist Teil der Untersuchung (durch Themenwahl, Interpretation, Beziehung zu

Teilnehmenden). Das ist keine Verfälschung, sondern eine **unvermeidliche und notwendige Realität**. → Transparenz über die eigene Position ist der Standard

Verstehen als Erkenntnisprinzip

Ziel ist nicht objektive Messung, sondern: *Wie sinn-voll handeln Menschen?* → Rekonstruktion von Bedeutungszuschreibungen

Die fünf Prinzipien als Regelwerk

Qualitative Forschung folgt **fünf Basisprinzipien** (nicht: zehn Richtlinien, die man flexibel auslegt):

1. **Offenheit** – gegenüber Material und Phänomen
2. **Theoriegeleitetes Vorgehen** – Anschluss an existierendes Wissen
3. **Regelgeleitetes Vorgehen** – systematische, nachvollziehbare Analyseschritte
4. **Verstehen** – Rekonstruktion, warum Menschen so handeln
5. **Reflexivität** – transparente Darlegung des Vorverständnisses und der Rolle der Forschenden

Prüfungsklassiker

Aussage: „Qualitative Forschung ist offen, also kann ich ohne theoretisches Vorwissen anfangen.“

Richtig ist: Offenheit bezieht sich auf das Material, nicht auf fehlende Theoriekenntnis.

Theoriegeleitetes Vorgehen ist explizit gefordert.

Aussage: „Der natürliche Kontext heißt, dass alles unkontrolliert ablaufen kann.“

Richtig ist: Natürlicher Kontext ist zentral, aber die Forschenden dokumentieren und reflektieren ihre Rolle und die Bedingungen systematisch.

Erklär-es-zurück-Frage

Erkläre einer Kollegin, die quantitativ forscht, warum es ein Problem wäre, wenn qualitative Forschung *wirklich* ohne Theoriewissen begänne – und warum „Offenheit“ das nicht bedeutet.

Übungen

3 Übungsaufgaben: Grundlagen qualitativer Forschung

■ ÜBUNG 1 (Einstieg — Begriffssicherung)

Format: Zuordnung + Begründung

Aufgabe:

Ordne die folgenden vier Aussagen den Begriffen **Offenheit**, **Iterativität**, **Kontextualität** oder **Theoriegeleitetheit** zu. Eine Aussage passt zu zwei Begriffen.

Aussage	ZuBegründung (Stichwort)	
A) Die Forscherin führt ein Interview, transkribiert es parallel und stellt dabei fest, dass eine neue Frage wichtig ist. Sie plant daraufhin gezielt weitere Interviews.		
B) Ein Patient antwortet in der Praxis anders als in einem separaten Interview-Labor – je nachdem, wer in der Nähe ist.		
C) Der Forschende bringt psychologisches Vorwissen über Bindungsstile mit, lässt sich aber von überraschenden Mustern im Material leiten.		
D) Nachdem 15 Interviews geführt wurden, berichten neue Teilnehmende nichts Neues mehr zum Phänomen – die Datenerhebung endet.		

Musterlösung:

Aussage	Zuordnung	Begründung (Stichwort)
A) Die Forscherin führt ein Interview, transkribiert es parallel und stellt dabei fest, dass eine neue Frage wichtig ist. Sie plant daraufhin gezielt weitere Interviews.	Iterativität	Parallel-Analyse-und-Erhebung; zirkulärer Forschungsprozess; Anpassung der Stichprobe nach Reflexion
B) Ein Patient antwortet in der Praxis anders als in einem separaten Interview-Labor – je nachdem, wer in der Nähe ist.	Kontextualität	Natürlicher Kontext prägt Antworten; Soziale Situation ist Teil des Phänomens, nicht Störvariable

C) Der Forschende bringt psychologisches Vorwissen über Bindungsstile mit, lässt sich aber von überraschenden Mustern im Material leiten.	Theoriegeleitetheit UND Offenheit	Theoriewissen + Bereitschaft, überrascht zu werden; kein Dogmatismus
D) Nachdem 15 Interviews geführt wurden, berichten neue Teilnehmende nichts Neues mehr zum Phänomen – die Datenerhebung endet.	Iterativität	Theoretische Sättigung als Abbruchkriterium; nicht-fixe Stichprobengröße

Häufiger Fehler:

- ■ „Offenheit = keine Theorie mitbringen“ → führt zu falscher Zuordnung bei C
- ■ Aussage B als „fehlende Kontrolle“ interpretieren statt Kontextualität zu erkennen
- ■ Aussage D nur mit „kleine Stichprobe“ verwechseln, nicht mit iterativem Prozess

■ ÜBUNG 2 (Mittleres Niveau — Mini-Fall + Analyse)

Format: Fallbeschreibung + Fehleridentifikation

Aufgabe:

Ein Master-Student plant eine qualitative Studie:

„Wie erleben Pflegende die Zusammenarbeit mit Palliativ-Spezialisten?“

Der Student beschreibt seinen Plan:

„Ich werde völlig offen ins Feld gehen – ohne Vorkenntnisse, um unbeeinflusst zu bleiben. Ich führe 3 strukturierte Interviews in einem separaten Büro-Raum der Klinik (einheitliche Bedingungen), transkribiere alles und analysiere danach. Das sichert Objektivität. Am Ende habe ich dann genaue Zahlen der Häufigkeiten.“

Aufgabe: Identifiziere **vier Punkte**, die gegen die Prinzipien qualitativer Forschung verstoßen, und erkläre jeweils **warum** und **was stattdessen richtig wäre**.

Punkt	Fel	War	Was
	problem	wäre	richtig?
1.			
2.			

3.			
4.			

Musterlösung:

Punkt	Fehler	Warum problematisch?	Was wäre richtig?
1. Vorkenntnisse ablehnen	„Offen ins Feld gehen – ohne Vorkenntnisse“	Theoriegeleitetheit ist ein Basisprinzip. Ohne Vorwissen fehlt der konzeptuelle Rahmen, um Material überhaupt sinn-voll auszuwählen und einzuordnen. Stattdessen: Mangel an Sensibilität.	Literatur zu Palliativcare + Interprofessionalität einarbeiten, dann aber flexibel bleiben für Überraschungen.
2. Kontextualität ignorieren	Alle Interviews im separaten Büro („einheitliche Bedingungen“)	Qualitative Forschung fordert natürliche Kontexte! Die Stationsstation, die Zusammenarbeit <i>live</i> oder mindestens deren natürliches Umfeld sind Teil des Phänomens. Ein Büro verfälscht genau das, was man verstehen will.	Interviews in der Praxis durchführen (Station, Pausenraum) oder zumindest reflektieren, wie die künstliche Umgebung die Antworten beeinflusst.
3. Analyse-Rhythmus fehlerhaft	„Transkribiere alles DANACH, analysiere danach“ (sequenziell)	Verletzung der Iterativität. Man verpasst die Möglichkeit, während der Erhebung Muster zu erkennen, gezielt nachzufragen oder die Stichprobe gezielt zu erweitern (theoretische Sättigung).	Parallel analysieren: Nach Interview 1 reflektieren, Notizen/Codes setzen → Fragen für Interview 2 anpassen → und so weiter.

4. Quantifizierung angestrebt	„Am Ende habe ich dann genaue Zahlen der Häufigkeiten“	Qualitative Forschung ist nicht dazu da, Häufigkeiten zu zählen (das ist Aufgabe quantitativer Designs). Das verfehlt die Tiefe und Essenz von Verstehensprozessen. Außerdem: Mit n=3 keine repräsentativen Zahlen möglich.	Ergebnisse sind: Rekonstruierte Sinn-Muster, z.B. „Pflegerinnen erleben Zusammenarbeit als entlastend, wenn ...“ oder „Konflikte entstehen durch ...“ – mit Belegen aus dem Material, nicht mit Prozentzahlen.
-------------------------------	--	---	--

Häufige Fehler bei dieser Aufgabe:

- ■ Fehler 1 als „es ist ok, theorieloses Arbeiten“ zu rechtfertigen
- ■ Fehler 2 nur als „zu künstlich“ zu kritisieren, ohne Kontextualität zu nennen
- ■ Fehler 3 nicht als Iterativitäts-Verstoß zu erkennen
- ■ Fehler 4 zu ignorieren oder zu denken, dass Häufigkeiten am Ende dazukommen

■ ÜBUNG 3 (Vertiefung — Interpretations- und Reflexivitätsaufgabe)

Format: Kasuistik + Reflektive Frage + Regelwerk anwenden

Aufgabe:

Eine Doktorandin forscht zu: „*Wie treffen Ärztinnen Entscheidungen zu Therapieabbruch bei älteren Patientinnen?*“*

Sie führt Interviews mit fünf Ärztinnen. Im Verlauf merkt sie: **Alle fünf geben sehr rationale, protokoll-orientierte Begründungen.** Sie erwartet aber, dass auch Emotionen, Wertekonflikte, biografische Faktoren eine Rolle spielen.

Die Doktorandin überlegt, ob sie die Interviews als „**unergiebig**“ verwerfen und stattdessen Ärzte (nicht Ärztinnen) interviewen soll – vielleicht gibt es bei ihnen mehr Varianz.

Frage A (Verständnis):

Welches der fünf Basisprinzipien fordert die Doktorandin hier heraus — und **warum** ist das kritisch?

Frage B (Interpretation des Materials):

Welche Alternative zu „Interviews verwerfen“ schlägt ein reflexives Verständnis vor? Gib zwei konkrete nächste Schritte.

Frage C (Transfer):

Was könnte die homogene Antwort (alle rational) selbst schon bedeuten — als *Erkenntnisgewinn*?

Musterlösung:

Frage A: Welches Prinzip ist in Frage?

Antwort: Reflexivität und Offenheit gegenüber dem Material.

Warum kritisch?

Die Doktorandin interpretiert Homogenität als Fehler und will die Stichprobe wechseln. Das ist problematisch, weil:

1. Sie nimmt an, dass die „erwartete“ Varianz (Emotionen, Konflikte) die „richtige“ ist — das ist **Dogmatismus**, nicht Offenheit.
2. Sie reflektiert nicht, **ob** und **wie** ihre Erwartung (als Forscherin!) die Dateninterpretation leitet.
3. Sie ignoriert, dass die **Homogenität selbst ein bedeutsames Phänomen** sein könnte.
4. Ein Wechsel zu einer anderen Gruppe (Ärzte statt Ärztinnen) ist spekulativ — ein reflexiver Schritt wäre erst, zu verstehen, warum diese Gruppe sich so verhält.

Besser: Ihre Rolle als Forscherin transparent machen („Ich erwartet mehr Varianz. Das könnte meine Lesart sein, nicht das Material.“) und das Material in dieser Spannung ernst nehmen.

Frage B: Zwei konkrete nächste Schritte (Reflexivität + Iterativität)

Schritt 1: Offene Nachfragen im bereits gesammelten Material prüfen

- Transkripte re-analysieren: Wo geben Ärztinnen rationale Gründe an? *Danach* fragen: „Und wie erleben Sie das emotional?“ oder „Hat das immer so rational angefühlt?“ oder „Erinnern Sie sich an einen Fall, der Sie besonders berührt hat?“
- Vielleicht sind die Antworten *zu glatt* (Soziale Erwünschtheit, Rolle als Professionelle) – das würde Kontext erklären, nicht Material-Mangel.

Schritt 2: Gezielt weitere Interviews mit Sensibilität für „Emotionalität hinter der Rationalität“

- Interviews 6–8 führen mit verfeinerter Interviewführung (offene Erzählaufforderungen statt Ja/Nein-Fragen)
 - **Oder:** Andere Erhebungsmethoden testen: Fokus-Gruppen? Beobachtung in Fallkonferenzen?
 - Stop, wenn theoretische Sättigung erreicht (auch wenn das mit nur n=7 sein kann)
-

Frage C: Was könnte die Homogenität selbst bedeuten? (Transfer)

Erkenntnisgewinn statt Fehler:

Die Tatsache, dass alle fünf Ärztinnen sich **sehr rational** darstellen, könnte bedeuten:

Professionalisierte Sprachlosigkeit: Im Kontext von Therapieabbruch haben sich Ärztinnen *gelernt* einer rationalen Narrative zu bedienen – weil Emotionalität als unprofessionell gilt oder die existenzielle Belastung zu groß ist, um sie auszusprechen.

Gender-Effekt: Ärztinnen könnten *strategisch* rational sprechen, um in einem männlich-dominierten Feld als kompetent wahrgenommen zu werden.

Kontext-Effekt: Das Untersuchungs-Setting (Forscherin, Aufnahme, Analyse später) macht ehrliche emotionale Offenbarung schwer.

Das wäre ein wichtiges Ergebnis für die Forschungsfrage! „Wie Ärztinnen Entscheidungen treffen“ ≠ nur *rationale* Gründe, sondern auch: **Wie wird Rationalität konstruiert? Welche Affekte werden verborgen?**

→ Das ist eine **tieferer Antwort** als erwartet – nicht weniger wertvoll, sondern **differenzierter und realistischer**.

Häufige Fehler bei dieser Aufgabe:

- ■ Reflexivität nur als „Vorwissen transparenter machen“ zu verstehen (ist Teil, aber nicht das ganze Problem hier)
- ■ Zu schnell zur Alternative zu wechseln, statt das Material erst auszuschöpfen
- ■ Homogenität als Fehler zu interpretieren, nicht als potenzielle Erkenntnisquelle
- ■ Nicht zu sehen, dass die Doktorandin ihre Erwartung nicht hinterfragt (=Mangel an Reflexivität)

■ Überblick: Was wird geprüft?

Übung	Schwerpunkt	Format	Kompetenzen
1	Begriffe und ihre Definition sicher unterscheiden	Zuordnung	Wissen, Verständnis
2	Prinzipien auf Fehler anwenden; Abweichungen erkennen und begründen	Fallanalyse	Analyse, Anwendung

3	Reflexivität als Haltung verstehen; Material ernst nehmen trotz Überraschung	Kasuistik + offene Fragen	Reflexion, Synthese, Transfer
---	--	---------------------------	--------------------------------------

■ ■ Top 5 Prüfungsfallen zu Kapitel 1

1. „**Offenheit**“ = **Theorie-Beliebigkeit** → Nein! Theoriegeleitung ist verbindlich.
2. „**Natürlicher Kontext**“ = **unkontrolliert** → Nein! Dokumentation und Reflexion sind die Kontrolle.
3. **Kleine Fallzahl** = **schlechte Forschung** → Nein! Theoretische Sättigung kann mit n=5 erreicht sein.
4. **Homogenität im Material** = **Fehler** → Nein! Kann ein bedeutsames Phänomen selbst sein.
5. **Qualitativ** = **keine Systematik** → Falsch! Fünf Prinzipien = festes Regelwerk.

1. Die Forschungsfrage strukturieren: SPIDER-Schema

Eine **Forschungsfrage** ist der Kompass einer Studie. Das **SPIDER-Schema** ist ein Gerüst, das die wesentlichen Komponenten sichtbar macht:

Komponente	Bedeutung	Beispiel
Sample	Wer wird untersucht?	Patienten mit Rückenschmerz (6–12 Wochen)
Phenomenon of Interest	Was ist das Kernthema?	Erfahrung mit Telerehabilitation
Design	Welche Methode?	Qualitatives Interview
Evaluation	Was wird gemessen/erforscht?	Zufriedenheit, Barrieren, Effektivität
Research type	Art der Forschung?	Qualitativ / Quantitativ

Wichtig: Nicht alle Komponenten müssen gleich detailliert sein. „Evaluation“ kann sowohl ein **Outcome** (z.B. Schmerzreduktion) als auch eine **kritische Bewertung** (z.B. Akzeptanz) bedeuten.

Beispiel:

Wie erleben physiotherapeutische Patientinnen eine hybrid durchgeführte Behandlung (Präsenz + digital) bezüglich ihrer Behandlungszufriedenheit und wahrgenommener Barrieren?

2. Qualitative Forschungsansätze und ihre Ziele

Qualitative Methoden dienen der **Theoriegenerierung** (induktiv) und dem **Sinnverstehen**. Drei zentrale Ansätze:

Ethnographie

- **Fokus:** Kultur, Normen, Interaktionen einer Gruppe
- **Ziel:** Wie funktioniert die soziale Welt einer Community (z.B. Therapeutenteam, Patient:innengruppe)?
- **Methode:** Teilnehmende Beobachtung + Interviews über längeren Zeitraum
- **Frage:** *Welche informalen Regeln lenken die Zusammenarbeit im Praxisteam?*

Phänomenologie

- **Fokus:** Subjektive Erfahrung, Lebenswelt des Individuums
- **Ziel:** *Wie erleben Menschen ein Phänomen aus ihrer Perspektive?*
- **Methode:** Tiefeninterviews, Fokusgruppen
- **Frage:** *Wie erleben Patienten Schmerz im Alltag während einer Rehabilitation?*

Grounded Theory (GT)

- **Fokus:** Soziale Prozesse, Handlungen, Interaktionen → **Theoriegenerierung**
- **Ziel:** Welche Prozesse laufen ab? Welche Kategorien erklären das Phänomen?
- **Methode:** Datensammlung + parallele Kodierung (offenes, axiales, selektives Kodieren)
- **Besonderheit:** Theorie wächst schrittweise aus den Daten
- **Frage:** *Welche Prozesse ermöglichen es älteren Menschen, sich an neue Mobilitätshilfen anzupassen?*

3. Die theoretische Linse: Wie Vorverständnis wirkt

Definition

Eine **theoretische Linse** ist die konzeptionelle Brille, durch die der Forscher Daten erhebt und interpretiert (z.B. systemische Perspektive, biomechanisches Modell, pflegetheoretischer Rahmen).

Wie sie wirkt:

Aspekt	Funktion	Warnung
Aufmerksamkeit lenken	Bestimmt, welche Codes, Themen entstehen	Nicht alle Daten sind gleich sichtbar
Fragen prägen	Welche Interviewfragen gestellt werden	Risziert, nur „bestätigende“ Antworten zu hören
Interpretation rahmen	Wie Aussagen verstanden werden	Kann Daten „verdrehen“, nicht widersprechen

Kritisches Vorverständnis

Die Linse darf **nicht** die Daten verfälschen. Gutes Vorgehen:

- **Vor der Analyse:** Eigene Annahmen dokumentieren (z.B. „Ich glaube, Digital-Therapie ist schwer zugänglich“)
- **Während der Kodierung:** Gegenstimmen aktiv suchen (z.B. „Welche Patienten fanden sie leicht?“)
- **Transparenz:** Im Bericht offenlegen, welche Linse verwendet wurde

Analogie: Eine farbige Brille ändert, was man sieht — aber nicht, was real ist. Wer sich bewusst macht, dass sie Rot trägt, kann Farben besser deuten.

4. Häufige Verwechslungen (Prüfungsfallen)

Fehler	Richtig	Merkhilfe
Ethnographie = Alle Beobachtungsstudien	Ethnographie = Kultur + Beobachtung über Zeit	Ethno = Volk/Kultur
Phänomenologie testet eine Hypothese	Phänomenologie generiert Verständnis	Phänomen = Erleben, nicht Testen
GT = einfaches Kodieren von Interviews	GT = zirkulärer Prozess (Daten → Codes → Theorie → neue Daten)	Grounded = in Daten verwurzelt
Theoretische Linse = starr anwenden	Linse = kritisch hinterfragen während der Analyse	Reflexivität ist zentral

5. Prüfungstypische Aufgabe

Zuordnung:

Sie lesen einen Forschungsartikel. Der Autor hat Ergotherapeuten bei ihrer Arbeit mit demenz-erkrankten Patientinnen beobachtet und dokumentiert, wie Routinen, Pausen und Umgebung die Patienteninteraktion prägen. Welcher Ansatz liegt vor?

- A) Phänomenologie
- B) Ethnographie
- C) Grounded Theory

Lösung: B — Der Fokus liegt auf **Kultur und Interaktion einer Gruppe** (Therapeuten + Patienten), nicht auf einzelner Erfahrung (A) oder Prozessgenerierung (C).

Erklär-es-zurück-Frage

Erklär mir in 2–3 Sätzen, wie sich eine ethnographische von einer phänomenologischen Studie unterscheidet — worin liegt der entscheidende Unterschied im Fokus?

Übungen

3 Übungsaufgaben: Kapitel 3 — Forschungsfrage & Design

(Steigende Schwierigkeit | Mit Musterlösung & häufigen Fehlern)

ÜBUNG 1: Zuordnung (Einstiegsebene)

Aufgabe 1.1: SPIDER-Komponenten richtig sortieren

Szenario:

Sie planen eine Studie und haben folgende Aussagen gesammelt:

- (a) „Patienten mit chronischem Kopfschmerz (20–60 Jahre)“
- (b) „Welche psychosozialen Faktoren beeinflussen die Adhärenz zum Hometraining?“
- (c) „Qualitatives halbstrukturiertes Interview“
- (d) „Phänomenologie“
- (e) „Therapieprogramm-Compliance und wahrgenommene Unterstützung“

Aufgabe: Ordnen Sie (a)–(e) den SPIDER-Komponenten zu. Eine Komponente bleibt übrig.

S	P	D	E	R
?	?	?	?	?

Markieren Sie die übrige Aussage:

Aussage _____ passt hier nicht in die Systematik.

MUSTERLÖSUNG 1.1:

S	P	D	E	R
(a) Patienten mit chronischem Kopfschmerz	(b) Welche psychosozialen Faktoren...	(c) Halbstrukturiertes Interview	(e) Adhärenz & Unterstützung	(d) Phänomenologie

Übrige Aussage: Keine — alle fünf Komponenten sind belegt.

Explanation:

- **S** = Sample (Wer?) → Patientenpopulation
- **P** = Phenomenon of Interest (Was ist das Thema?) → Die Forschungsfrage selbst (Einflussfaktoren)
- **D** = Design (Wie?) → Methodisches Vorgehen

- **E** = Evaluation (Was wird gemessen/erforscht?) → Die Outcomes/Konzepte
 - **R** = Research type → Art der Forschung (qualitativ mit phänomenologischem Ansatz)
-

Häufiger Fehler 1:

■ „(d) Phänomenologie passt zu R, aber (e) Adhärenz ist eine Evaluation“

Warum falsch? (e) ist tatsächlich die Evaluation — das ist korrekt. (d) Phänomenologie ist auch **R** = Forschungstyp. Beide passen gleichzeitig (eine qualitative Phänomenologie erforscht die Evaluation „Adhärenz“). Es gibt **mehrere Antworten**, die überlagern können — das ist normal!

ÜBUNG 2: Mini-Fall mit Interpretation (Mittelstufe)

Aufgabe 2.1: Theoretische Linse erkennen & kritisieren

Szenario:

Eine Physiotherapeutin führt eine qualitative Studie durch. Sie möchte verstehen, warum Patienten ein digitales Trainingsmodul zur Rückenschmerzbehandlung nicht nutzen. Sie hat folgende Vorstellung:

„Die meisten älteren Patienten haben wahrscheinlich Angst vor Technik oder sind zu faul. Deshalb werde ich in den Interviews gezielt fragen: ‚Welche Angst vor dem Computer haben Sie?‘ und ‚Was hat Sie vom Trainieren abgehalten?‘“

Aufgaben:

Identifizieren Sie: Welche theoretische Linse trägt die Therapeutin?

Risiko benennen: Welcher Fehler könnte bei dieser Herangehensweise entstehen? (Geben Sie ein konkretes Beispiel.)

Verbesserung: Schreiben Sie 2 offenere Interviewfragen auf, die nicht die Antwort vorab festlegen.

MUSTERLÖSUNG 2.1:

1. Theoretische Linse:

- **Defizitorientiertes Modell:** Die Therapeutin sieht Nicht-Nutzung als **Patientenproblem** (Angst, Trägheit), nicht als mögliches Systemversagen.
- **Implizite Annahmen:** „Ältere Menschen ≠ Technik-kompetent“ → **Altersstereotyp**

2. Risiko (Verfälschung durch Leading Questions):

- **Problem:** Durch die Frage „Welche Angst haben Sie?“ suggeriert sie, dass Angst existiert.
- **Konkretes Beispiel:**
- Patient denkt: „Eigentlich bin ich nicht ängstlich, aber der Therapeutin zuliebe sage ich ja...“
- **Ergebnis:** Die Daten bestätigen die Vorerwartung (Bestätigungsfehler), obwohl der *echte* Grund vielleicht war: Zeitmangel, unklar Anleitung, oder fehlende Relevanz.

3. Offenere Interviewfragen:

■ „Können Sie mir erzählen, wie Sie die Erfahrung mit dem digitalen Modul gemacht haben — von Anfang an?“

■ „Was hat für Sie beim Trainieren geklappt, und wo sind Sie auf Schwierigkeiten gestoßen?“

(Beide fragen **offen nach Erlebtem**, nicht nach vermuteten Gründen.)

Häufiger Fehler 2:

■ „Die Linse ist ‚Psychologie‘, weil sie von Angst spricht.“

Warum falsch? Eine theoretische Linse ist nicht einfach das **Thema** (Psychologie), sondern die **konzeptionelle Brille, mit der der Forscher die Realität deutet**. Hier ist es ein **defizitorientiertes / individualisierendes Modell** (das Problem liegt beim Individuum), das einer **systemischen Linse** (Usability, Kontext, Anpassung?) entgegensteht.

ÜBUNG 3: Integration & kritisches Denken (Schwer)

Aufgabe 3.1: Forschungsdesign wählen & rechtfertigen

Komplexes Szenario:

Ein Physiotherapeut möchte folgende Forschungsfrage bearbeiten:

„Wie entwickeln sich die Selbstmanagement-Strategien von Patienten mit chronischem Schmerz über die ersten 12 Wochen einer multimodalen Therapie — und welche sozialen/persönlichen Faktoren fördern oder behindern diese Entwicklung?“

Aufgaben:

A) **Welcher qualitative Ansatz passt BESTE zu dieser Frage? (Nennen Sie einen.)**

- Ethnographie | Phänomenologie | Grounded Theory

B) **Begründung:** Schreiben Sie 2–3 Sätze, WARUM dieser Ansatz passt und die anderen nicht.

C) **SPIDER-Check:** Füllen Sie mindestens 4 der 5 Komponenten aus, basierend auf der Forschungsfrage oben.

D) **Kritisches Vorverständnis:** Der Therapeut denkt insgeheim: „Ich glaube, dass nur hochgebildete Patienten gutes Selbstmanagement entwickeln.“

- Wie könnte diese Annahme die Dateninterpretation verfälschen?

- Nenne 1 konkrete Strategie, um diese Verzerrung zu reduzieren.

MUSTERLÖSUNG 3.1:

A) **Beste Antwort: Grounded Theory (GT)**

B) **Begründung:**

■ **Grounded Theory passt, weil:**

- Die Frage explizit nach einem **Prozess** fragt („wie entwickeln sich...“), nicht nur nach einer einzelnen Erfahrung.
- GT ist für **Theoriegenerierung aus Prozessen** gemacht (Kategorien entstehen → Wechselwirkungen → Kernkategorie).
- Die Frage nach förderlichen/hemmenden Faktoren ist eine klassische GT-Frage (Bedingungen → Handlungen → Konsequenzen).

■ **Phänomenologie passt weniger, weil:**

- Sie würde das **Erleben eines Moments** erforschen, nicht die **Entwicklung über Zeit**.

■ **Ethnographie passt nicht, weil:**

- Sie fokussiert auf Kultur & Interaktionen einer **Gruppe**, nicht auf individuelle Prozessentwicklung.

C) SPIDER-Komponenten:

Komponente	Ausfüllung
S (Sample)	Patienten mit chronischem Schmerz in multimodaler Behandlung (mindestens 4 Wochen absolviert)
P (Phenomenon of Interest)	Entwicklung von Selbstmanagement-Strategien
D (Design)	Serielle qualitative Interviews (z.B. Woche 1, 6, 12) + optional Tagebücher
E (Evaluation)	Selbstmanagement-Strategien, soziale Faktoren, persönliche Faktoren (Motivation, Glaube, Ressourcen)
R (Research Type)	Qualitativ (Grounded Theory)

D) Kritisches Vorverständnis — Verfälschung & Strategie:

Wie die Annahme verfälschen könnte:

- Der Therapeut könnte beim Kodieren **selektiv wahrnehmen**: Er hört bei einem Akademiker „Ich plane mein Training“ und kodiert es als „gezieltes Selbstmanagement“.
- Beim gleichen Verhalten eines Patienten mit Schulabschluss hört er „Ich mache, was der Therapeut sagt“ und kodiert es als „Abhängigkeit“, obwohl die **Handlung identisch** ist.
- **Ergebnis**: Theorie wird zu „Bildung → Selbstmanagement“, obwohl es vielleicht Zufall war.

Konkrete Reduktionsstrategie:

■ **Memo schreiben (vor Kodierung):**

Der Therapeut schreibt auf: „*Meine Annahme ist, dass Bildung wichtig ist. Ich werde gezielt nach*“

gegenbeispiele suchen: Patienten OHNE hohe Bildung, die gutes Selbstmanagement zeigen. Ich kodiere das gleich sorgfältig."

■ Oder: Axialen Kodierung (während GT):

Bei jedem Code zur Strategie explizit fragen: „Was sind die Bedingungen — ist Bildung wirklich der Unterschied oder könnten es Motivation, Zeit, Unterstützung sein?“ → **Gegenstimmen aktiv suchen**.

Häufiger Fehler 3:

■ „Alle drei Ansätze würden funktionieren, weil sie alle qualitativ sind.“

Warum falsch? Qualitativ ist nur die **Forschungsart**, nicht das **Design**. Jeder Ansatz hat einen anderen **Fokus**:

- **GT** → Prozesstheorie generieren ✓ (passt)
- **Phänomenologie** → einzelnes Erleben verstehen ✗ (zu eng)
- **Ethnographie** → Kulturelle Normen verstehen ✗ (zu fokussiert auf Gruppe, nicht Prozess)

Auch häufig: ■ „Bildung ist der Bias, also muss ich hochgebildete Patienten ausschließen.“

Warum falsch? Das ist **Vermeidung**, nicht **Transparenz**. Besser: Alle einschließen, aber die Annahme dokumentieren und kritisch überprüfen.

Zusammenfassung für die Prüfung

Konzept	Merkhilfe	Prüfungs-Häufig
SPIDER	S-P-D-E-R = 5 Fragen systematisch klären	■■■■ Zuordnungsaufgaben
GT vs. Phäno vs. Ethno	GT = Prozess+Theorie	Phäno = Erleben
Theoretische Linse	Vorerwartung → Verfälschungsrisiko → Transparenz/Gegenstimmen	■■ Interpretation
Leading Questions	Offene Fragen statt Suggestion	■ Fehler erkennen

Erklär-es-zurück-Testfrage (für Selbstkontrolle)

Stellen Sie sich vor, Sie lesen diese Aussage in einem Forschungsbericht:

„Wir haben ethnographisch untersucht, wie Patienten ihre Schmerzerfahrung im Alltag erleben.“

Finden Sie den Fehler und erklären Sie kurz:

1. Was ist konzeptionell falsch?
2. Welcher Ansatz würde passen?
3. Was könnte der Forscher stattdessen mit Ethnographie untersuchen?

Lösung findest du, wenn du scrollst ■

Lösung Erklär-es-zurück-Frage **1. Konzeptioneller Fehler:** Die Aussage vermischt zwei Ansätze. **Erleben (subjektive Perspektive)** ist **Phänomenologie**, nicht Ethnographie. **2. Passender Ansatz:** **Phänomenologie** — um zu verstehen, wie Patienten Schmerz *erfahren*. **3. Was Ethnographie stattdessen untersuchen könnte:** „Wir haben ethnographisch untersucht, wie Schmerzpatienten in der Reha-Gruppe **Normen, Rituale und gegenseitige Unterstützung** entwickeln.“ → Fokus auf **Kultur der Gruppe**, nicht auf individuelle Erfahrung.

Lernmodul: Grounded Theory vs. Qualitative Inhaltsanalyse

1. Die zwei Welten der qualitativen Analyse

Stellen Sie sich zwei Detektive vor:

- **QIA-Detektiv:** Sortiert alle Hinweise systematisch in Ordnern ab (Kategorien), prüft jede Ablage nach Regeln.
- **GT-Detektiv:** Entwickelt während der Ermittlung selbst eine Theorie über den Fall – je mehr Indizien, desto klarer das Bild.

Grounded Theory (GT)

- **Ziel: Theoriegenerierung** über soziale/psychologische Prozesse
- **Material:** Interview-Transkripte, Beobachtungen
- **Produktweise:** Induktiv – **aus den Daten heraus** wächst eine neue Erklärungstheorie
- **Kern:** Theoretische Sättigung steuert Stichprobengröße (nicht vorher festgelegt!)
- **Timing:** Analyse läuft **parallel zur Erhebung** – neue Erkenntnisse steuern neue Interviews
- **Beispiel:** Therapistinnen *berichten von Frustration mit chronischen Patientinnen* → GT entwickelt Theorie der „Bewältigungskrisen in Langzeitbehandlung“

Qualitative Inhaltsanalyse (QIA)

- **Ziel: Systematische Kategorisierung** von Kommunikationsinhalten
- **Material:** Texte, Interviews, Protokolle
- **Produktweise:** Regelgeleitet – Kategorien strukturieren das Material nach transparenten Kriterien

- **Kern:** Kategoriebildung kann **induktiv** (aus Material) oder **deduktiv** (vorab aus Theorie) erfolgen
- **Timing:** Analyse erfolgt **nach Abschluss** der Erhebung
- **Beispiel:** 30 Patientinnen-Interviews werden durchsucht: Welche Typen von Bewältigungsstrategien* werden genannt? Kategorien: aktiv, passiv, sozial, medizinisch.

2. Die zentrale Unterscheidung (Prüfungsfalle!)

Merkmal	GT	QIA
Theoriegenerierung	✓ Neue Theorie entsteht	✗ Keine neue Theorie
Datengesteuerte Stichprobe	✓ Sättigung stoppt Erhebung	✗ Stichprobe vorher definiert
Parallele Analyse	✓ Während Erhebung	✗ Nach Erhebung
Prozessorientiert	✓ „Wie funktioniert das?“)	✗ „Was wird gesagt?“
Regelwerk für Kategorien	Flexibel emergent	Streng standardisiert

3. Der iterative Charakter – das Herzstück

Iteration = Wiederholung mit Verbesserung. Die Analyse ist kein linearer Weg, sondern eine Spirale:

Daten erfassen → vorläufig kodieren → reflektieren ↓ Neue Interviews → Kodierung anpassen → tiefere Kategorien ↓ Sättigung erreicht? → Theorie/Kategoriestruktur verfestigt sich

Bei GT: Diese Spirale ist **essentiell**. Sie treibt die Theorieentwicklung voran.

Bei QIA: Diese Spirale ist **Qualitätssicherung**. Sie sichert die Konsistenz der Kategorienanwendung.

4. Transkription & Kategoriebildung – die zentralen Schritte

Transkription (für beide Methoden)

- **Wort-für-Wort-Umschrift** von Audio/Video in Text
- **Keine Interpretationsstufe** – nur technische Transformation
- **Entscheidung:** Wie detailliert? (Pausen, Lachen, Betonung?)

- **Begründung:** Nur auf Textbasis können Codes vergeben, Kategorien gebildet werden

Kategoriebildung – zwei Wege

Induktiv (Bottom-Up):

- Forscherin *liest Material mehrfach*, notiert „was springt mir ins Auge?“
- Kategorien entstehen aus den Daten selbst
- Flexibel, explorativ
- GT klassisch, QIA möglich*

Deduktiv (Top-Down):

- Kategorien werden **vorab aus bestehender Theorie** abgeleitet
- Material wird durchsucht und sortiert nach diesen Kategorien
- Strukturiert, vergleichend
- **QIA oft, GT selten**

Hybrid (kombiniert):

- Erste induktive Phase → dann deduktive Überprüfung mit Kodierregeln
- **Am häufigsten in der Praxis**

5. Transparenzbedarf: Das Non-Negotiable

Unabhängig von Methode und Kategoriebildungsweg:

✓ Dokumentieren Sie:

- Welcher Weg wurde gewählt? (induktiv/deduktiv/hybrid)
- Nach welchen Regeln wurden Codes zugeordnet?
- Wie wurden Kategorien abgegrenzt?
- Wer hat kodiert? (Intercoder-Reliabilität geprüft?)
- Wie wurde theoretische Sättigung erreicht? (GT)

x Nicht sagen: „Wir haben die Interviews analysiert“ → zu vage!

6. Häufige Verwechslungen (Prüfung!)

Falsch	Richtig
„QIA entwickelt Theorien“	QIA kategorisiert systematisch; GT entwickelt Theorien
„GT ist fertig nach 10 Interviews“	GT: Mindestens bis theoretische Sättigung (oft 20–50)
„Kategorien sind objektiv gegeben“	Kategorien sind Forschungskonstrukte – transparent machen!

„Analyse beginnt nach allen Interviews“	GT: Analyse parallel zur Erhebung (Timing!)
---	---

7. Kopfrechnen-Beispiel (Prüfungsstil)

Szenario: Sie haben 25 Patientinnen-Interviews geführt.

- GT-Forscherin: **Nach 18 Interviews keine neuen Codes mehr → Sättigung erreicht → STOP (auch wenn 7 Interviews noch möglich wären)**

- QIA-Forscherin*: Alle 25 werden kategorisiert nach 6 vorab definierten Kategorien → Häufigkeitstabelle erstellt

Frage: Warum unterschiedliche N?

Antwort: GT-Stichprobe ist **qualitätsgesteuert** (Sättigung); QIA-Stichprobe **vorher definiert**.

Erklär-es-zurück-Frage

Erklären Sie einer Kollegin in 2–3 Sätzen, warum die Analyse bei GT während der Datenerhebung läuft, bei QIA aber nach* der Erhebung – und welche praktische Konsequenz das für die Fallzahl hat.

Übungen

3 Übungsaufgaben: Grounded Theory vs. Qualitative Inhaltsanalyse

ÜBUNG 1: Zuordnung & Begriffssicherung ■ (Leicht)

Aufgabe

Ordnen Sie jede Aussage entweder **GT (Grounded Theory)** oder **QIA (Qualitative Inhaltsanalyse)** zu. Begründen Sie kurz (1 Satz).

Aussage	Begründung / QIA?	
A) „Nach 22 Interviews traten keine neuen Codes mehr auf. Wir beendeten die Datenerhebung.“		
B) „Wir definierten vorher 5 Kategorien und ordneten alle 30 Interviews nach diesem Schema.“		
C) „Während der Interviews reflektierten wir, passten unsere Leitfragen an und vertieften neue Themenbereiche.“		
D) „Das Ziel war, einen sozialen Prozess in der Pflegekommunikation zu erklären – nicht nur zu beschreiben.“		
E) „Wir kodierten unabhängig voneinander und überprüften die Interdecoder-Übereinstimmung.“		

Musterlösung

Aussage	GT / QIA?	Begründung
A)	GT	Theoretische Sättigung steuert Stichprobengröße – Erhebung stoppt, wenn neue Interviews keine neuen Codes generieren.
B)	QIA	Vorab definierte Kategorien + feste Stichprobe (30) = charakteristisch für QIA; deduktiver Zugang.

C)	GT	Parallele Analyse während Erhebung mit iterativer Anpassung ist GT-spezifisch – „zirkulärer“ Prozess.
D)	GT	Theoriegenerierung über Prozesse ist Kern der GT; QIA kategorisiert „was wird gesagt“, nicht „wie funktioniert Prozess?“.
E)	QIA	Systematische Kodierreliabilität ist ein QIA-Gütekriterium; GT ist weniger standardisiert (emergent).

■ ■ Häufiger Fehler

Fehler: „E könnte auch GT sein, weil Qualität wichtig ist.“

Korrekt: Intercoder-Reliabilität ist ein **standardisiertes Qualitätskriterium**, das QIA auszeichnet. GT betont eher *theoretische Kohärenz* statt statistischer Übereinstimmung.

ÜBUNG 2: Mini-Fall mit Entscheidung ■ ■ (Mittel)

Aufgabe

Szenario: Sie sollen eine Studie zur Erfahrung von Burnout bei Pflegekräften durchführen.

Zwei Kolleg*innen schlagen unterschiedliche Wege vor:

Kolleg*in A:

„Ich führe 50 strukturierte Interviews durch. Danach kodiere ich alle Antworten systematisch nach 7 vordefinierten Kategorien: emotionale Erschöpfung, Depersonalisierung, Leistungsreduktion, Bewältigungsressourcen, familiäre Belastung, Berufsidentität, Veränderungswunsch. Dann erstelle ich eine Häufigkeitstabelle.“

Kolleg*in B:

„Ich starte mit 10–12 offenen Interviews. Danach kodiere ich erste Transkripte und stelle fest, dass sich neue Codes bilden. Ich führe weitere Interviews zu diesen neuen Aspekten durch, analysiere parallel und höre auf, wenn keine neuen Kategorien mehr entstehen. So entwickle ich eine Theorie über den Prozess, wie Burnout sich entwickelt und wie Pflegekräfte damit umgehen.“

Fragen:

1. Welcher Ansatz ist GT, welcher QIA? (Nennen Sie für jeden 2–3 charakteristische Merkmale aus dem Szenario.)
2. Angenommen, Kollegin B stoppt nach 28 Interviews. Kollegin A hat genau 50. **Warum ist diese**

Differenz nicht willkürlich?

3. Welcher Ansatz würde besser funktionieren, wenn die **Forschungsfrage** lautet: „Welche Faktoren prägen den zeitlichen Ablauf von Burnout?“

Musterlösung

1. Ansatzidentifikation:

Merkmal	Kolleg*in A (QIA)	Kolleg*in B (GT)
Stichprobengröße	Vorher festgelegt (50)	Datengesteuert (bis Sättigung)
Kategoriebildung	Vorab aus Theorie (7 Kategorien)	Während Analyse emergent
Timing Analyse	Nach Erhebung	Parallel zur Erhebung
Ziel	Kategorisierung von Inhalten	Theoriegenerierung über Prozess

2. Differenz 28 vs. 50:

Die Differenz ist **nicht willkürlich**. Kollegin B stoppt bei *theoretischer Sättigung* – dem Punkt, an dem neue Interviews keine neuen Codes/Kategorien mehr erzeugen. Das ist ein Qualitätskriterium, nicht Zufall. Kollegin A muss alle 50 kodieren, weil diese Zahl **vorher definiert** wurde (unabhängig davon, ob nach 25 schon alles klar wäre).

3. Passender Ansatz für die Forschungsfrage:

Kolleg*in B (GT) ist besser. Die Frage zielt auf **zeitliche Prozesse** ab („zeitlicher Ablauf“) – das ist klassisches GT-Territorium. QIA würde nur **beschreiben**, welche Faktoren genannt werden, nicht wie sie zeitlich zusammenhängen.

■ Häufige Fehler

Fehler 1: „Kollegin A hat mehr Daten, also bessere Qualität.“

Korrekt: Mehr Daten ≠ bessere Qualität. GT-Qualität kommt aus theoretischer Sättigung, QIA aus systematischer Kategorienanwendung.*

Fehler 2: „Kollegin B könnte auch QIA sein – die parallele Analyse ist nur cleverer.“

Korrekt: Parallele Analyse ist nicht nur eine Optimierung, sie ist essentiell für GT. Sie steuert, welche Interviews als nächstes sinnvoll sind.*

Fehler 3: „Die 7 Kategorien von A sind auch induktiv entstanden.“

Korrekt: Im Szenario wird klar: Sie wurden aus Theorie (vermutlich Maslach-Modell) **vorab definiert** → deduktiv.

ÜBUNG 3: Interpretationskomplex ■■■ (Schwer)

Aufgabe

Kontext: Sie lesen einen Methodenbericht einer qualitativ-psychologischen Studie zu Trauerprozessen. Folgende Passage wird Ihnen vorgelegt:

„Wir führten 35 Leitfaden-Interviews mit Personen durch, die einen nahestehenden Menschen verloren hatten. Der Leitfaden umfasste 8 Fragen zu Zeitpunkt des Verlusts, Trauererfahrung, Bewältigungsstile und Unterstützung. Nach transkription aller 35 Interviews kodierten zwei unabhängige Kodierinnen das Material. Dabei bildete sich ein initiales Kategoriensystem aus 12 Codes. In einer zweiten Kodierunde überprüften wir die Konsistenz dieses Systems anhand einer Stichprobe von 10 Transkripten. Der InterCoder-Übereinstimmungswert lag bei Cohen's Kappa = 0,78. Basierend auf diesem System kodierten beide Kodierinnen dann die restlichen 25 Interviews. Abschließend wurden die Häufigkeiten der Codes in einer Tabelle zusammengefasst.“

Fragen:

A) Methodische Klassifikation:

- Ist das GT oder QIA? **Nennen Sie 4 Indikatoren aus dem Text**, die für Ihre Antwort sprechen.

B) Transparenzbewertung – 3er-Skala:

Bewerten Sie, wie **transparent und nachvollziehbar** die Analyse dokumentiert ist:

- ■■■ Sehr transparent
- ■■ Lückenhafte Dokumentation
- ■ Nicht nachvollziehbar

Begründen Sie und nennen Sie **eine fehlende Information**.

C) Kritische Frage zur Begrifflichkeit:

Die Forscherinnen sagen: „Das Kategoriensystem **bildete sich** in der zweiten Kodierunde*.“

Ist das eine präzise Beschreibung? Warum / warum nicht?

D) Hätte GT hier besser gepasst?

Angenommen, die Forschungsfrage wäre gewesen: „*Welcher psychologische Prozess läuft ab, wenn Menschen um nahestehende Personen trauern?*“

Würde GT besser passen? Erklären Sie, warum/warum nicht.

Musterlösung

A) Methodische Klassifikation → QIA

4 Indikatoren:

1. **Festgelegte Stichprobengröße:** N = 35 **vorher definiert**, nicht datengesteuert gestoppt
2. **Leitfaden-basiert:** Strukturierter Leitfaden mit 8 Fragen → typisch QIA (GT nutzt offenere Interviews)
3. **Analyse nach Erhebung:** Alle 35 Interviews wurden transkribiert, **dann** erste Kodierung → sequentiell, nicht parallel

4. Intercoder-Reliabilität als Gütemaß: Cohen's Kappa-Wert = standardisiertes QIA-Qualitätskriterium

B) Transparenzbewertung → ■■ (Lückenhafte Dokumentation)

Begründung:

Der Bericht nennt die **Struktur**, aber es fehlen konkrete Inhalte:

- ✓ Kodierungsprozess ist klar (zwei Kodierinnen, zwei Runden)
- ✓ Reliabilität ist quantifiziert (Kappa = 0,78)
- ✗ Fehlend 1: Welche 12 Codes wurden gebildet? (Beispiele oder Kodierregeln)
- ✗ Fehlend 2: Wie wurde das initiale Kategoriensystem aus dem Material generiert? (Induktiv aus erster Lesestelle? Kombiniert mit theoretischem Vorwissen?)
- ✗ Fehlend 3: Wie wurden Kategorien abgegrenzt*? (Wenn zwei Codes ähnlich waren, nach welcher Regel wurde unterschieden?)

Beispiel für fehlende Information:

„Die Codes entstanden durch offene Kodierung der ersten 5 Transkripte, bei der wir alle Sinneinheiten markierten, die sich auf Trauerprozess, emotionale Reaktionen oder Bewältigung bezogen. Das System wurde dann mit Kodierregeln dokumentiert (z. B. ‚Code: Verleugnung = Aussagen, in denen Trauer negiert oder zeitlich verschoben wird‘). Diese Regeln überprüften wir in der Konsistenzrunde.“

C) „Bildete sich“ – Begrifflichkeitskritik

Ist es präzise? → Nein, zu vage.

Warum:

- „Sich bilden“ impliziert **Emergenz** – dass die Kategorien quasi von selbst aus den Daten wuchsen
- Das ist **GT-Sprache** – aber in dieser Studie wurden sie **deduktiv angewendet** (Leitfaden vorab + strukturiert)
- Präziser wäre: „Wir kodierten die ersten 5 Transkripte offen und generierten induktiv 12 Codes. Diese wurden als Kodierregeln standardisiert und dann konsistenzgeprüft“

Lernpunkt: Der Prozess der Kategoriebildung (induktiv/deduktiv/hybrid) muss **explizit benannt** werden, nicht mit weicher Sprache überdeckt.

D) Hätte GT besser gepasst?

Antwort: Ja, definitiv. Hier ist, warum:

Die Forschungsfrage „Welcher psychologische Prozess läuft ab?“ zielt auf **Prozessverständnis** ab. Das ist GT-Kernterritorium.

Aspekt	Aktuelle QIA-Studie	Bessere GT-Variante

Was wird untersucht	Welche Bewältigungsstile, Gefühle, Unterstützungstypen werden genannt ?	Wie entfaltet sich Trauer zeitlich? Welche Wendepunkte gibt es?
Frage-Typ	„Was?“ (beschreibend)	„Wie funktioniert?“ (erklärend)
Stichprobe	N = 35 fest geplant	N offen; gesteuert durch Sättigung
Timing	Nach allen Interviews analysieren	Parallel analysieren; neue Interviews gezielt zu Prozess-Vertiefungen
Output	Häufigkeitstabelle: 30% aktive Bewältigung, 40% soziale Unterstützung...	Theorie: z. B. „Trauerprozess verläuft über 3 Phasen mit je spezifischen psychologischen Übergängen“

Konkrete Verbesserung mit GT:

- Erstes Interview könnte offenbaren: „Nach 2 Wochen war ich numb, dann kam die Wut, dann die Akzeptanz.“
- Das würde vermutlich neue Interviews gezielt zu **zeitlichen Grenzen** zwischen Phasen führen
- Nach 20–25 Interviews könnte eine präzise Prozesstheorie entstehen
- Mit QIA würde man diese Dynamik **nur kategorisieren**, nicht erklären

Fazit: GT passt zur Forschungsfrage besser. QIA hätte gepasst, wenn die Frage lautete: „Welche Bewältigungsstrategien nutzen trauernde Menschen?“

■ Häufige Fehler in dieser Übung

Fehler 1: „Cohen's Kappa = 0,78 ist ein GT-Merkmal.“

Korrekt: Nein, das ist eindeutig **QIA**. GT setzt eher auf theoretische Kohärenz, nicht auf statistische Übereinstimmung.

Fehler 2: „GT hätte geklappt, aber QIA ist auch in Ordnung.“

Korrekt: Beide sind möglich, aber **GT passt zur Forschungsfrage besser**. Eine gute Methodenwahl orientiert sich an der Forschungsfrage – nicht nur am Material.

Fehler 3: „Das Kategoriensystem entstand induktiv, weil es aus den ersten Interviews kam.“

Korrekt: Das ist noch nicht spezifisch genug. **Induktiv** bedeutet: Kategorien entstehen *nur* aus Material ohne vorab festgelegte Theorie. Hier ist unklar, ob der Leitfaden (Struktur) schon implizit kategorisierend war.

Fehler 4: „Man könnte auch sagen, dass beide Kodierinnen GT betrieben, nur mit strukturiertem Leitfaden.“

Korrekt*: Nein. Der strukturierte Leitfaden + Intercoder-Reliabilität + feste N deuten stark auf QIA hin. GT nutzt tendenziell offenere Leitfäden und keine Reliabilitätsmetriken.

Schnell-Checkliste für Prüfung

GT oder QIA?	Schnell-Erkennungsmerkmale
GT	Sättigung + parallele Analyse + Theoriegenerierung + offene Leitfäden + Prozessorientiert
QIA	Vorher definierte N + Kategorien vorher/deduktiv + Analyse nach Erhebung + Leitfaden strukturiert + Cohen's Kappa
Hybrid	Induktive Kategoriebildung (erste Phase) + dann Kodierregeln standardisiert (zweite Phase)

„Erklär es zurück“-Lösung (aus Lernmodul)

„GT analysiert während der Datenerhebung, weil neue Interviews neue Codes generieren können, die wiederum die nächsten Interviews inhaltlich steuern. Deshalb wird die Stichprobengröße nicht vorher definiert, sondern stoppt bei theoretischer Sättigung – typisch: 15–50 Interviews. QIA hingegen analysiert nach der Erhebung, weil Kategorien vorab festgelegt sind; alle Interviews werden nach demselben System kodiert. Die Stichprobengröße muss daher vorher geplant werden – typisch: 20–100, je nach Fragestellung. Konsequenz: GT-Stichproben sind variabel & sättigungsgesteuert; QIA-Stichproben sind fix & theoriegeleitet.“