

Empirische Sozialforschung (ESF) Woche 2 — Quantitativ (Lesen)

Nur Stoff. Übungen: siehe FLORA_ESF_WOCHE2_UEBUNGEN.md oder PDF
02b_Woche2_Uebungen.pdf.

Kapitel 2: Forschungsdesigns verstehen und unterscheiden

Kurz erklärt

Eine Forschungsfrage bestimmt, welches Design sinnvoll ist. Wer wissen will, ob eine Therapie wirkt, braucht ein anderes Design als jemand, der wissen will, wie häufig ein Problem vorkommt. Das Grundprinzip: Je mehr eine Studie kontrolliert, wen welche Behandlung bekommt, desto klarer lassen sich Ursache und Wirkung trennen. Beobachtungsstudien schauen zu, was in der Realität passiert. Interventionsstudien greifen aktiv ein. Die Zeitachse entscheidet, ob man eine Momentaufnahme macht oder Personen über Zeit verfolgt. Das Studiendesign ist keine formale Formalität, sondern bestimmt, welche Schlussfolgerungen überhaupt zulässig sind.

Physiotherapie (PT)-Beispiel

Eine Physiotherapeutin fragt: "Hilft manuelle Therapie bei chronischem Nackenschmerz besser als Standardbehandlung?"

- Sie könnte Patientenakten aus den letzten fünf Jahren auswerten (retrospektive Beobachtungsstudie, aber viele Störvariablen).
- Sie könnte neue Patienten ein Jahr lang beobachten, ohne einzugreifen (prospektive Kohortenstudie).
- Am stärksten wäre: Neue Patienten werden per Zufallsprinzip entweder der manuellen Therapie oder der Standardbehandlung zugeteilt, Ergebnis nach 12 Wochen gemessen (Randomisierte kontrollierte Studie (RCT)).

Nur im letzten Design ist die Zuteilung kontrolliert. Deshalb erlaubt nur der RCT eine klare Kausalaussage.

Für die Prüfung

Überblick: Studiendesigns im Vergleich

Design	Eingriff?	Zeitachse	Startpunkt	Typische Frage
Querschnittsstudie	nein	einmalig	Momentaufnahme	Wie häufig ist X in der Bevölkerung?
Langsschnittstudie	nein oder ja	über Zeit	variabel	Wie verändert sich X über Zeit?
Kohortenstudie	nein	prospektiv oder retrospektiv	Risikofaktor	Führt Exposition X zu Outcome Y?
Fall-Kontroll-Studie	nein	retrospektiv	Outcome	Welche Risikofaktoren haben Erkrankte im Vergleich?
RCT	ja	prospektiv	Randomisierung	Wirkt Intervention X besser als Y?
Nicht-randomisierte Interventionsstudie (CCT)	ja	prospektiv	Gruppenbildung ohne Zufall	Wirkt X, wenn Randomisierung nicht möglich ist?

Querschnittsstudie

- Einmalige Datenerhebung zu einem Zeitpunkt
- Kein Eingriff, keine Zuteilung
- Misst Prävalenz (Häufigkeit zum Messzeitpunkt)
- Kein Kausalschluss möglich
- Beispiel: Befragung von 200 PT-Patienten heute zu Schmerzniveau und Lebensqualität

Langsschnittstudie

- Dieselben Personen werden zu mehreren Zeitpunkten untersucht
- Kann prospektiv (vorwärts, Daten werden neu erhoben) oder retrospektiv (rückwärts, bereits vorhandene Daten) sein
- Nicht jede Langsschnittstudie ist eine Interventionsstudie
- Unterschied prospektiv/retrospektiv betrifft die Datenerhebung, nicht allein die Zeitrichtung

Kohortenstudie

- Personen werden nach Exposition eingeteilt (z.B. trainieren vs. trainieren nicht)
- Beobachtung, wer danach ein Outcome entwickelt
- Kein Eingriff durch Forscher
- Prospektiv: Exposition bekannt, Outcome wird abgewartet
- Retrospektiv: Exposition und Outcome liegen beide in der Vergangenheit, Daten werden rückwirkend ausgewertet
- Ergebnis: relatives Risiko
- Prüfungsfalle: Kohortenstudie beginnt beim Risikofaktor, nicht beim Outcome

Fall-Kontroll-Studie

- Startpunkt ist das Outcome (z.B. Patienten mit Schulterimpingement vs. Personen ohne)
- Forscher schaut rückwärts: Welche Exposition hatten die Fälle im Vergleich zu den Kontrollen?
- Immer retrospektiv
- Geeignet für seltene Erkrankungen
- Ergebnis: Odds Ratio
- Prüfungsfalle: Fall-Kontroll beginnt beim Outcome, Kohortenstudie beginnt beim Risikofaktor

RCT (Randomized Controlled Trial)

- Aktiver Eingriff durch Forscher
 - Zuteilung zu Gruppen erfolgt per Zufall (Randomisierung)
 - Kontrollgruppe erhält Placebo, Standardbehandlung oder keine Behandlung
 - Randomisierung ist der entscheidende Unterschied zur Kohortenstudie
 - Ziel: Kausalaussage ("Intervention X verursacht Verbesserung Y")
 - Höchster Evidenzstandard für Wirksamkeitsfragen
 - Warum? Zufallszuteilung verteilt bekannte und unbekannte Störvariablen gleichmäßig auf beide Gruppen
-

Warum ist der RCT der höchste Evidenzstandard?

Weil nur die Randomisierung systematische Unterschiede zwischen den Gruppen vor der Intervention ausschliesst. Bei Beobachtungsstudien konnten sich Gruppen von Anfang an in wichtigen Eigenschaften unterscheiden (Confounding). Das macht Kausalschlüsse unsicher. Der RCT eliminiert dieses Problem strukturell, nicht durch statistische Korrekturen.

Einordnung nach Forschungsfrage

Forschungsfrage	Passendes Design
Wie wirksam ist Intervention X?	RCT
Wie häufig kommt Problem X vor?	Querschnittsstudie
Welche Risikofaktoren führen zu Outcome X?	Kohortenstudie
Welche Vorgeschichte haben Personen mit Erkrankung X?	Fall-Kontroll-Studie
Wie verändert sich Zustand X über Jahre?	Langsschnittstudie
Randomisierung ethisch oder praktisch unmöglich, Wirksamkeit trotzdem prüfen	CCT (nicht-randomisiert)

Vertiefung

Beobachtungsstudie vs. Interventionsstudie

- Beobachtungsstudie: Forscher greift nicht ein, beobachtet nur (Querschnitt, Kohorten, Fall-Kontroll)
- Interventionsstudie: Forscher teilt Behandlung zu und greift ein (RCT, CCT)

Prospektiv vs. retrospektiv

- Prospektiv: Daten werden ab jetzt neu erhoben, Outcome liegt in der Zukunft
- Retrospektiv: Daten existieren bereits, Forscher schaut in die Vergangenheit
- Wichtig: Prospektiv/retrospektiv beschreibt die Datenerhebung. Eine Langsschnittstudie kann beides sein.

Confounding

- Storgrosse, die sowohl mit der Exposition als auch mit dem Outcome zusammenhangt
- Problem in allen Beobachtungsstudien
- Randomisierung lost dieses Problem, Beobachtungsstudien können es nur statistisch kontrollieren

Prüfungsfallen zusammengefasst

- RCT vs. Kohortenstudie: RCT = zufallsbasierte Zuteilung zur Intervention. Kohortenstudie = natürliche Exposition, kein Eingriff
 - Fall-Kontroll vs. Kohortenstudie: Fall-Kontroll startet beim Outcome und schaut zurück. Kohortenstudie startet beim Risikofaktor und schaut vorwärts
 - Prospektiv vs. retrospektiv: Bezieht sich auf die Datenerhebung, nicht auf den Studientyp als solchen. Auch eine Kohortenstudie kann retrospektiv sein
-

Kapitel 3: Variablen, Operationalisierung und Skalenniveaus

Kurz erklärt

In der empirischen Forschung wird ein interessierendes Merkmal — zum Beispiel Schmerz oder Bewegungsausmaß — als Variable bezeichnet. Eine Variable hat mindestens zwei mögliche Ausprägungen, zum Beispiel „kein Schmerz“ bis „stärkster vorstellbarer Schmerz“. Damit eine Variable gemessen werden kann, braucht man eine Operationalisierung: Man legt fest, wie genau das Merkmal erfasst wird, zum Beispiel durch einen Fragebogen, ein Goniometer oder eine Skala. Das Skalenniveau beschreibt, welche mathematischen Eigenschaften die gemessenen Werte haben — also ob man sie nur benennen, rangordnen oder auch rechnerisch vergleichen darf. Das Skalenniveau bestimmt direkt, welche statistischen Verfahren zulässig sind: Ein Mittelwert aus Schulnoten ist rechnerisch möglich, aber inhaltlich nicht sinnvoll, weil die Abstände zwischen den Noten nicht gleich groß sind. Die richtige Zuordnung von Skalenniveau und Verfahren ist daher kein formales Detail, sondern eine inhaltliche Voraussetzung für korrekte Schlussfolgerungen.

Physiotherapie (PT)-Beispiel

Ein Physiotherapeut untersucht, ob manuelle Therapie die Schmerzintensität bei Patienten mit Nackenschmerzen reduziert.

Merkmal: Schmerzintensität

Operationalisierung: Numerische Rating-Skala (NRS) von 0 bis 10, wobei 0 = kein Schmerz und 10 = stärkster vorstellbarer Schmerz

Variable: Schmerzintensität auf der NRS (0–10)

Ausprägungen: ganze Zahlen von 0 bis 10

Skalenniveau: ordinal — die Rangfolge ist klar (5 ist mehr als 3), aber ob der Unterschied zwischen 2 und 4 genauso groß ist wie zwischen 6 und 8, lässt sich nicht belegen. Abstände sind nicht garantiert gleich.

Konsequenz: Der Median ist das geeignete Lagemaß, nicht der Mittelwert. In der Praxis werden NRS-Werte häufig gemittelt — das ist eine vereinfachende Konvention, die methodisch diskutiert wird und in der Prüfung als Fehlerquelle gilt.

Daneben erhebt der Therapeut das aktive Bewegungsausmaß der Halswirbelsäule in Grad (Goniometer). Diese Variable ist verhältnisskaliert: Es gibt einen absoluten Nullpunkt (0 Grad = keine Bewegung), gleiche Abstände sind garantiert, und Aussagen wie „doppelt so viel Bewegungsausmaß“ sind zulässig.

Für die Prüfung

Variablen: Grundbegriffe

Begriff	Definition	Beispiel
Merkmal (Variable)	Eigenschaft, die untersucht wird	Schmerzintensität
Merkmalsausprägung	Konkreter Wert der Variable	NRS-Wert = 7
Operationalisierung	Festlegung, wie das Merkmal gemessen wird	NRS 0–10
Konstante	Wert, der sich nicht verändert	Alle Probanden sind weiblich
UV (unabhängige Variable)	Einflussvariable, Ursache	Therapieform
AV (abhängige Variable)	Outcome-Variable, Wirkung	Schmerzintensität nach Therapie
Kovariablen	Weitere Einflussgröße neben der UV	Alter, Chronizität
Störvariable	Kovariablen, die nicht kontrolliert wurde	Schlafqualität

Skalenniveaus: vollständige Übersicht

Skalenniveau	Eigenschaften	Erlaubte Aussagen	PT-Beispiele
Nominalskala	Kategorien ohne Rangfolge	Gleich / verschieden	Diagnose, Geschlecht, Behandlungsform
Binare Variable	Sonderfall: nur 2 Kategorien	Gleich / verschieden	Ja/Nein, operiert/nicht operiert
Ordinalskala	Kategorien mit Rangfolge, Abstände unbekannt	Groesser / kleiner, aber keine Abstandsangaben	NRS, Schulnoten, Likert-Skala, Kellgren-Lawrence-Score
Intervallskala	Rangfolge + gleiche Abstände, kein absoluter Nullpunkt	Differenzen sinnvoll, Verhältnisse nicht	Celsius, Fahrenheit
Verhältnisskala	Rangfolge + gleiche Abstände + absoluter Nullpunkt	Alle arithmetischen Operationen, Verhältnisse	Körpergröße (cm), Gewicht (kg), ROM in Grad, Zeit in Sekunden

Zulässige statistische Verfahren nach Skalenniveau

Skalenniveau	Lageparameter	Streuungsmaß	Nicht zulässig
Nominal	Modus	—	Mittelwert, Median
Ordinal	Median	Interquartilsbereich (IQR)	Mittelwert, Standardabweichung
Intervall / Verhältnis	Mittelwert	Standardabweichung (SD)	—

Regel: Jedes höhere Skalenniveau schließt die Verfahren der niedrigeren Niveaus ein. Man kann eine Variable von einem höheren auf ein niedrigeres Niveau transformieren (z. B. Alter metrisch zu Alterskategorien ordinal) — dabei entsteht Informationsverlust. Der umgekehrte Weg ist nicht möglich.

Prüfungsfallen: konkret**Ordinalskala und Mittelwert:**

Schmerzskalen (NRS, Visuelle Analogskala (VAS)), Likert-Skalen und Schulnoten sind ordinal. Der Abstand zwischen Wert 3 und 4 muss nicht gleich sein wie zwischen 7 und 8. Ein berechneter Mittelwert (z. B. „mittlerer NRS-Wert = 4,3“) ist statistisch nicht korrekt begründet — der Median wäre das richtige Lagemaß.

Intervallskala ohne echten Nullpunkt:

0 Grad Celsius bedeutet nicht „keine Temperatur“. Der Nullpunkt ist willkürlich gewählt. Deshalb ist die Aussage „20 Grad sind doppelt so warm wie 10 Grad“ falsch. Verhältnisaussagen sind nur bei Verhältnisskalen zulässig.

Binäre Variablen:

Zwei-Kategorien-Variablen (operiert/nicht operiert, gesteuert/nicht gesteuert) sind ein Sonderfall des Nominals. Sie werden oft als dichotom bezeichnet. Rechnerisch können sie als 0/1 kodiert werden, bleiben aber nominal.

Transformation:

Höher skalierte Variablen können in niedriger skalierte umgewandelt werden (Alter -> Altersgruppe). Das ist möglich, aber mit Informationsverlust verbunden. Niedriger skalierte Variablen können nicht nachträglich „aufgewertet“ werden.

Vertiefung

Qualitative vs. quantitative Variablen

- Qualitative Variablen: Zugehoerigkeit zu einer Kategorie, keine Rangordnung moeglich (Nominal). Beispiel: Nationalitaet, Haarfarbe.
- Quantitative Variablen: Zugehoerigkeit nach Groesse, Rangordnung moeglich (Ordinal, Intervall, Verhaeltnis). Beispiel: Alter, NRS-Wert.

Stetig vs. diskret

- Stetig: Theoretisch beliebig genaue Messung moeglich, unendlich viele Zwischenwerte. Beispiel: Koerpergroesse in cm, Zeit in Sekunden.
- Diskret: Nur bestimmte (meist ganze) Werte moeglich, abzaehlbar. Beispiel: Anzahl der Therapiesitzungen, Sturzereignisse.
- Dichotom: Sonderfall mit genau 2 Auspraegungen.

Operationalisierung in der PT-Praxis: zwei Typen von Messgroessen

- Konkrete Groessen: direkt messbar. Beispiele: Koerpergewicht, Finger-Boden-Abstand in cm, Gelenkwinkel in Grad.
- Abstrakte Konstrukte: nicht direkt beobachtbar, benoetigen validierte Messinstrumente. Beispiele: Lebensqualitaet, motorische Kontrolle, Schmerzkatastrophisierung. Diese werden haeufig ueber Fragebogen mit Likert-Skalen erfasst — die resultierenden Werte sind ordinal, auch wenn Summenscores gebildet werden.

Merksatz zur Verhaeltnisskala:

Absoluter Nullpunkt = vollstaendige Abwesenheit der Eigenschaft. 0 kg bedeutet kein Gewicht. 0 Grad Bewegungsausmaß bedeutet keine Bewegung. 0 Grad Celsius bedeutet nicht „keine Temperatur“ — deshalb ist Celsius Intervall, nicht Verhaeltnis.

Kapitel 4: Deskriptive Statistik: Daten zusammenfassen und darstellen

Kurz erklärt

Deskriptive Statistik beschreibt Daten, ohne Schlussfolgerungen auf eine größere Population zu ziehen. Man fasst eine Datenmenge so zusammen, dass sie übersichtlich und lesbar wird. Dafür verwendet man Lagemaße (wo liegt das Zentrum der Daten?) und Streuungsmaße (wie weit streuen die Werte um dieses Zentrum?). Welches Maß man wählt, hängt vom Skalenniveau der Variable und davon ab, ob die Daten symmetrisch oder schief verteilt sind. Lagemaß und passendes Streuungsmaß werden immer gemeinsam angegeben — ein Wert allein ist wenig aussagekräftig.

Physiotherapie (PT)-Beispiel

Eine Physiotherapiepraxis erfasst bei 9 Patienten mit akutem Rückenschmerz die Schmerzintensität auf einer Skala von 0 bis 10:

Werte: 3, 4, 4, 5, 5, 5, 6, 7, 9

Mittelwert (MW): $\text{Summe} = 48$, geteilt durch 9 = ca. 5,3

Median (Md): Werte der Größe nach sortiert (hier bereits sortiert), mittlerer Wert (Position 5) = 5

Nun kommt ein chronischer Patient dazu mit Wert 10. Neuer Datensatz ($n=10$): 3, 4, 4, 5, 5, 5, 6, 7, 9, 10.

MW: $\text{Summe} = 58$, geteilt durch 10 = 5,8 — der MW steigt spürbar.

Md: Mittelwert aus Position 5 und 6 = $(5+5)/2 = 5$ — der Median bleibt stabil.

Fazit: Bei einer kleinen Stichprobe mit einem Ausreißer (chronischer Patient, Wert 10) beschreibt der Median das typische Schmerzniveau der Gruppe besser als der Mittelwert.

Für die Streuung: $\text{Range} = 10 - 3 = 7$. Der IQR (Q3 minus Q1) würde den Bereich der mittleren 50 Prozent der Werte abbilden und ist weniger empfindlich gegenüber diesem Ausreißer.

Für die Prüfung

Lagemaße: Übersicht und Anwendung

Maß	Berechnung	Skalenniveau	Wann verwenden
Mittelwert (MW)	Summe aller Werte / Anzahl der Werte	Metrisch	Symmetrische Verteilung, keine Ausreißer
Median (Md)	Mittlerer Wert nach Sortierung	Mindestens ordinal	Schiefe Verteilung, Ausreißer vorhanden
Modus	Häufigster Wert	Nominal und höher	Kategoriale Daten, grobe Orientierung

Wichtig: Bei gerader Anzahl von Werten wird der Median als Mittelwert der beiden mittleren Werte berechnet.

Streuungsmaße: Übersicht und Anwendung

Maß	Berechnung	Wann verwenden	Empfindlich gegen Ausreißer?
Standardabweichung (SD)	Wurzel der Varianz	Metrisch, symmetrische Verteilung, zusammen mit MW	Ja
Interquartilsbereich (IQR)	Q3 minus Q1	Schiefe Verteilung, zusammen mit Median	Nein
Range (Spannweite)	Maximum minus Minimum	Nur ergänzend, nie allein	Ja, stark
Varianz	Durchschnittliche quadrierte Abweichung vom MW	Grundlage für SD, selten allein berichtet	Ja

Zuordnung: Geschwisterpaare

Diese Kombinationen gehören zusammen und werden gemeinsam angegeben:

- Symmetrische Verteilung (Normalverteilung): MW und SD
- Schiefe Verteilung oder Ausreißer: Median und IQR
- Range niemals allein als einziges Streuungsmaß

Häufigkeitsverteilungen

- Absolute Häufigkeit: Anzahl, wie oft ein Wert vorkommt
- Relative Häufigkeit: Absolute Häufigkeit geteilt durch n (Stichprobengröße)
- Prozentuale Häufigkeit: Relative Häufigkeit mal 100
- Kumulierte Häufigkeit: Sukzessive Addition der relativen oder prozentualen Häufigkeiten — Aussage: wie viele Werte liegen bis zu einer bestimmten Kategorie vor

Normalverteilung: Merkmale und Beurteilung

Merkmale einer Normalverteilung:

- Symmetrisch, glockenförmig

- MW, Median und Modus fallen zusammen
- Die meisten Werte liegen in der Mitte, wenige an den Rändern

Visuelle Beurteilung:

- Histogramm: Zeigt die Form der Verteilung. Symmetrische Glockenform spricht für Normalverteilung.
- Q-Q-Plot: Punkte liegen auf einer Geraden bei Normalverteilung.
- Boxplot: Geeignet bei schiefen Verteilungen, macht Ausreißer sichtbar.

Abweichungen von der Normalverteilung:

- Schiefe (Skewness): Verteilung ist nach links oder rechts verzerrt. Typisch bei klinischen Daten, z.B. Schmerzdauer mit wenigen sehr langen Verläufen.
- Kurtosis: Verteilung ist entweder zu spitz (leptokurtisch) oder zu flach (platykurtisch) im Vergleich zur Normalverteilung.

Statistische Prüfung bei kleinen Stichproben (n unter 50): Shapiro-Wilk-Test. Bei größeren Stichproben: Kolmogorov-Smirnov-Test. Beide prüfen, ob die Daten signifikant von der Normalverteilung abweichen.

Skalenniveau und Wahl des Verfahrens

Skalenniveau	Geeigneter Lageparameter	Geeignetes Streuungsmaß
Nominal	Modus	Keine sinnvolle Angabe
Ordinal	Median	IQR, Range
Metrisch (symmetrisch)	MW	SD
Metrisch (schief / Ausreißer)	Median	IQR

Grafische Darstellungen

- Histogramm: Metrische Daten, zeigt Häufigkeitsverteilung und Form (Normalverteilung erkennbar)
 - Balkendiagramm: Nominale oder ordinale Daten
 - Boxplot: Zeigt Median, IQR, Range und Ausreißer — geeignet bei schiefen Verteilungen und Gruppenvergleichen
-

Vertiefung

Prüfungsfallen konkret

MW versus Median bei Ausreißern

Bei einer Stichprobe mit wenigen extremen Werten (z.B. Schmerzdauer: die meisten Patienten haben akuten Schmerz, wenige chronische Fälle mit sehr langen Dauern) wird der MW nach oben verzerrt. Der Median bleibt stabil, weil er nur die Position, nicht den Abstand der Werte berücksichtigt. Prüfungsrelevant: Wenn eine Verteilung als schief beschrieben wird oder Ausreißer erwähnt werden, ist Median und IQR die richtige Antwort.

SD ohne MW sinnlos

Die SD beschreibt die durchschnittliche Abweichung der Messwerte vom MW. Ohne MW fehlt der Bezugspunkt. Beide Maße werden bei symmetrischen, metrischen Daten zusammen angegeben.

Normalverteilung vorausgesetzt, aber nicht geprüft

Das visuelle Betrachten eines Histogramms allein reicht nicht aus, um Normalverteilung zu bestätigen. Bei kleinen Stichproben (n unter 50) ist die visuelle Beurteilung unsicher. Zusätzlich sollte der Shapiro-Wilk-Test eingesetzt werden. Viele statistische Tests (z.B. Pearson-Korrelation, t-Test) setzen Normalverteilung voraus — wird diese nicht geprüft, sind die Ergebnisse möglicherweise nicht interpretierbar.

Kurzregel für die Prüfung

Frage: Welcher Lageparameter und welches Streuungsmaß sind geeignet?

Schritt 1: Skalenniveau bestimmen.

Schritt 2: Verteilungsform prüfen (symmetrisch oder schief, Ausreißer?).

Schritt 3: Paar wählen — MW plus SD bei Normalverteilung, Median plus IQR bei Abweichung.

Schritt 4: Darstellungsform wählen — Histogramm bei symmetrischen Daten, Boxplot bei schiefen Verteilungen.

Kapitel 5: Bivariate Deskriptive Statistik: Zusammenhänge beschreiben

Kurz erklärt

Die bivariate deskriptive Statistik beschreibt die Beziehung zwischen zwei Variablen. Im Unterschied zur univariaten Statistik, die eine Variable isoliert betrachtet, fragt man hier: Hängen zwei Merkmale zusammen, und wenn ja, wie stark und in welche Richtung? Dafür gibt es verschiedene Koeffizienten, deren Wahl vom Skalenniveau der Variablen abhängt. Ein zentrales Ergebnis einer Korrelationsanalyse ist immer nur eine Beschreibung des Zusammenhangs, keine Aussage über Ursache und Wirkung. Für den Zusammenhang zwischen zwei dichotomen Variablen in epidemiologischen Designs werden statt Korrelationskoeffizienten Risikomaße wie RR und OR verwendet.

Physiotherapie (PT)-Beispiel

Ein Physiotherapeut möchte wissen, ob ein Zusammenhang zwischen Schmerzintensität (numerische Ratingskala 0-10, ordinal) und Bewegungsausmaß der Halswirbelsäule in Grad (metrisch, verhältnisskaliert) besteht. Da die Schmerzskala ordinal ist und keine Normalverteilung angenommen werden kann, wird Spearmans Rangkorrelation (r_s) berechnet. Das Streudiagramm zeigt: Je höher die Schmerzintensität, desto geringer das Bewegungsausmaß. Das Ergebnis $r_s = -0,71$ beschreibt einen starken negativen (gegensinnigen) Zusammenhang. Kausalität lässt sich daraus nicht ableiten: Es ist unklar, ob der Schmerz die Bewegung einschränkt, ob eingeschränkte Bewegung Schmerz verursacht, oder ob ein dritter Faktor wie Muskelverspannung beide Variablen beeinflusst.

Für die Prüfung

Korrelationskoeffizienten: Zuordnung nach Voraussetzungen

Koeffizient	Skalenniveau	Verteilung	Zusammenhangstyp
Pearson-r	mindestens intervallskaliert (metrisch)	Normalverteilung beider Variablen	linear
Spearman-rs	mindestens ordinal	keine Normalverteilung nötig	monoton (nicht zwingend linear)

Monoton bedeutet: Die eine Variable steigt tendenziell, wenn die andere steigt (oder fällt), aber nicht unbedingt proportional.

Voraussetzungen Pearson-r (alle vier müssen erfüllt sein)

- Mindestens intervallskalierte Variablen
- Linearer Zusammenhang (prüfen: Streudiagramm)
- Normalverteilung beider Variablen
- Keine Ausreißer

Interpretation des Korrelationskoeffizienten (Pearson und Spearman)

Betrag des Koeffizienten	Interpretation
0,00 - 0,10	kein Zusammenhang
0,10 - 0,30	schwacher Zusammenhang
0,30 - 0,50	mittlerer Zusammenhang
0,50 - 1,00	starker Zusammenhang
+1,00	perfekter positiver Zusammenhang
-1,00	perfekter negativer Zusammenhang

Vorzeichen = Richtung. Betrag = Stärke.

Streudiagramm: Funktion und Ablesen

- x-Achse: Variable A, y-Achse: Variable B
- Jeder Punkt = eine Person/Beobachtung

- Punktwolke von links unten nach rechts oben: positiver Zusammenhang
- Punktwolke von links oben nach rechts unten: negativer Zusammenhang
- Kreisförmige Punktwolke ohne erkennbare Richtung: kein Zusammenhang
- Dient auch zur Prüfung der Voraussetzung "linearer Zusammenhang" vor der Pearson-Korrelation

Korrelation und Kausalität: mögliche Alternativerklärungen

Wenn $r = 0,8$ zwischen Werbespots und Süßigkeitenkauf gefunden wird, sind folgende Erklärungen möglich:

- Werbespots verursachen Kauf (Kausalität A auf B)
- Kaufverhalten erhöht Werbeausgaben (Kausalität B auf A, Umkehrung)
- Drittvariable (z. B. verfügbares Einkommen) beeinflusst beide
- Zufälliger Zusammenhang in der Stichprobe

Eine Korrelation allein kann keine dieser Erklärungen ausschließen.

RR und OR: Unterschied und Zuordnung

Merkmal	RR (Relatives Risiko)	OR (Odds Ratio)
Deutsch	Risikoverhältnis	Chancenverhältnis
Studiendesign	prospektiv, Kohortenstudie	retrospektiv, Fall-Kontroll-Studie
Was wird verglichen	Wahrscheinlichkeit des Ereignisses in Gruppe A vs. B	Chance des Ereignisses in Gruppe A vs. B
Wert = 1	kein Effekt	keine Assoziation
Wert > 1	Exposition erhöht Risiko (Risikofaktor)	Exposition erhöht Chance des Ereignisses
Wert < 1	Exposition senkt Risiko (protektiv)	Exposition senkt Chance des Ereignisses

Risiko = Anzahl Ereignisse / Gesamtzahl der Gruppe.

Chance (Odds) = Anzahl Ereignisse / Anzahl Nicht-Ereignisse.

RR berechnen: Schritte

1. Risiko in exponierter Gruppe: Ereignisse exponiert / Gesamtzahl exponiert
2. Risiko in nicht-exponierter Gruppe: Ereignisse nicht-exponiert / Gesamtzahl nicht-exponiert
3. RR = Risiko exponiert / Risiko nicht-exponiert

OR berechnen: Schritte

1. Odds in exponierter Gruppe: Ereignisse exponiert / Nicht-Ereignisse exponiert
2. Odds in nicht-exponierter Gruppe: Ereignisse nicht-exponiert / Nicht-Ereignisse nicht-exponiert
3. OR = Odds exponiert / Odds nicht-exponiert

Kurzformel aus 2x2-Tabelle (Felder a, b, c, d im Schema Ereignis+/- x Exposition+/-): $OR = (a \times d) / (b \times c)$

Vertiefung

Kovarianz als Grundlage der Pearson-Korrelation

- Kovarianz: misst, ob Abweichungen zweier Variablen vom jeweiligen Mittelwert gleichsinnig oder gegensinnig auftreten
- Problem: nicht standardisiert, daher abhängig von der Maßeinheit, keine einheitliche Interpretation
- Pearson-r: Kovarianz geteilt durch das Produkt beider Standardabweichungen, dadurch standardisiert auf den Bereich -1 bis +1

Spearman-rs: Prinzip

- Rohdaten werden in Ränge umgewandelt (kleinster Wert = Rang 1)
- Anschließend wird auf den Rängen eine Korrelation berechnet
- Bei Rangbindungen (gleiche Werte) werden mittlere Ränge vergeben
- Robuster gegenüber Ausreißern und Nicht-Normalverteilung als Pearson-r

Wann welches Verfahren

- Beide Variablen metrisch, normalverteilt, kein Ausreißer, linearer Zusammenhang erkennbar: Pearson-r
- Eine oder beide Variablen ordinal, oder Normalverteilung verletzt, oder Ausreißer vorhanden: Spearman-rs
- Beide Variablen nominal/dichotom, Studiendesign epidemiologisch: RR oder OR

Prüfungsfallen kompakt

- Pearson-r auf ordinale Daten: nicht zulässig. Schmerzskalas (NRS, Visuelle Analogskala (VAS)) gelten in der Prüfung als ordinal, sofern nicht anders angegeben.
- $r = 0$ bedeutet: kein linearer Zusammenhang. Es kann trotzdem ein nicht-linearer Zusammenhang bestehen.
- RR und OR liefern bei seltenen Ereignissen ähnliche Werte, bei häufigen Ereignissen weichen sie deutlich ab. OR überschätzt dann das relative Risiko.
- OR wird bei Fall-Kontroll-Studien verwendet, weil die Gruppengrößen (Fälle vs. Kontrollen) vom Forscher festgelegt werden und kein echtes Ausgangsrisiko berechnet werden kann.

Kapitel 7: Induktive Statistik und Hypothesentestung

Kurz erklärt

Die deskriptive Statistik beschreibt nur die vorliegende Stichprobe. Die induktive Statistik geht einen Schritt weiter: Sie fragt, ob ein in der Stichprobe beobachteter Effekt auch in der Grundgesamtheit gilt. Da man nie die gesamte Population messen kann, bleibt immer eine Unsicherheit. Diese Unsicherheit wird durch zwei Kenngrößen ausgedrückt: den p-Wert (Signifikanzwahrscheinlichkeit) und das Konfidenzintervall. Das Vorgehen folgt einer festen Logik: Man formuliert ein Hypothesenpaar, legt vor der Auswertung ein Signifikanzniveau fest, berechnet eine Prüfgröße und trifft dann eine Entscheidung. Diese Entscheidung kann falsch sein, auch wenn alles korrekt durchgeführt wurde.

Physiotherapie (PT)-Beispiel

Eine Physiotherapeutin untersucht, ob manuelle Therapie bei Patienten mit Nackenschmerzen das Bewegungsausmaß der Halswirbelsäule stärker verbessert als ein Heimübungsprogramm.

Forschungsfrage: Gibt es einen Unterschied im Bewegungsausmaß (in Grad) nach 6 Wochen zwischen der Gruppe mit manueller Therapie und der Gruppe mit Heimübungen?

Hypothesenpaar:

- H0: Manuelle Therapie und Heimübungen führen nach 6 Wochen zu keinem Unterschied im Bewegungsausmaß der HWS.
- H1: Manuelle Therapie führt nach 6 Wochen zu einem größeren Bewegungsausmaß als Heimübungen.

Signifikanzniveau: $\alpha = 0,05$ (wird vor der Auswertung festgelegt).

Ergebnis: $p = 0,03$. Da $p < 0,05$, wird H0 abgelehnt. Die Studie zeigt einen statistisch signifikanten Unterschied.

Klinische Relevanz: Der mittlere Unterschied zwischen den Gruppen beträgt 3 Grad. Ob 3 Grad klinisch bedeutsam sind, hängt vom minimalen klinisch relevanten Unterschied (MCID) für dieses Messinstrument ab. Statistisch signifikant bedeutet nicht automatisch klinisch relevant.

Für die Prüfung

Das Hypothesenpaar

Begriff	Inhalt
H0 (Nullhypothese)	Kein Unterschied, kein Zusammenhang, kein Effekt in der Population
H1 (Alternativhypothese)	Effekt, Unterschied oder Zusammenhang in der Population vorhanden
Komplementarität	H0 und H1 schliessen alle Möglichkeiten lückenlos ab
Gerichtet	H1 gibt eine Richtung an (z. B. Gruppe A > Gruppe B)
Ungerichtet	H1 gibt nur an, dass ein Unterschied besteht, ohne Richtung

Der p-Wert: Bedeutung und häufige Fehler

Korrekte Definition: Der p-Wert gibt an, wie wahrscheinlich es ist, die beobachteten Daten (oder noch extremere) zu erhalten, wenn H0 in der Grundgesamtheit wahr wäre. Formal: $P(\text{Daten} \mid H_0 \text{ wahr})$.

Entscheidungsregel:

- $p < \text{Signifikanzniveau}$ (alpha, meist 0,05): H0 wird abgelehnt, H1 wird angenommen.
- $p \geq \text{Signifikanzniveau}$: H0 wird beibehalten (nicht bewiesen, nur nicht abgelehnt).

Drei Fehler, die in der Prüfung abgefragt werden:

1. p-Wert ist NICHT die Wahrscheinlichkeit, dass H0 wahr ist. $p = 0,03$ bedeutet nicht, dass H0 nur mit 3 % Wahrscheinlichkeit stimmt.
2. $p < 0,05$ bedeutet NICHT, dass der Effekt klinisch relevant ist.
3. $p \geq 0,05$ bedeutet NICHT, dass kein Effekt existiert. Es bedeutet nur, dass die vorliegenden Daten keinen ausreichenden Beleg für H1 liefern.

Signifikanzniveau und Fehlerarten

Begriff	Definition	Beispiel
Signifikanzniveau (alpha)	Vorab festgelegte Schwelle, ab der H_0 abgelehnt wird. Üblicherweise 0,05.	Vor der Studie festlegen, nicht danach anpassen.
Alpha-Fehler (Typ-I-Fehler)	H_0 wird abgelehnt, obwohl sie in der Population wahr ist.	Man schliesst auf einen Effekt, der nicht existiert.
Beta-Fehler (Typ-II-Fehler)	H_0 wird beibehalten, obwohl H_1 in der Population gilt.	Man übersieht einen real existierenden Effekt.
Teststärke (Power)	Wahrscheinlichkeit, einen tatsächlich vorhandenen Effekt auch zu entdecken. 1 minus Beta.	Grosse Stichproben erhöhen die Power.

Merkhilfe für die Prüfung:

- Alpha-Fehler: falscher Alarm (man handelt, obwohl nichts da ist).
- Beta-Fehler: verpasster Treffer (man handelt nicht, obwohl etwas da wäre).

Zusammenhang zwischen alpha und beta

- Senkt man alpha (z. B. auf 0,01), wird der Alpha-Fehler seltener, aber der Beta-Fehler häufiger.
- Beide Fehler gleichzeitig zu minimieren ist nur durch Vergrösserung der Stichprobe möglich.

Konfidenzintervall (KI)

Korrekte Interpretation des 95%-KI: Wenn man das gleiche Verfahren sehr oft an verschiedenen Stichproben aus derselben Population anwenden würde, würden 95 % der so berechneten Intervalle den wahren Populationsparameter enthalten.

Falsche Interpretation: Das KI bedeutet NICHT, dass der wahre Wert mit 95 % Wahrscheinlichkeit in diesem konkreten Intervall liegt. Das ist eine bayesianische Aussage, nicht die frequentistische Interpretation.

Praktische Nutzung:

- KI, das den Nullwert einschliesst (z. B. Differenz 0 bei einem Gruppenvergleich): kein signifikanter Befund.
- KI, das den Nullwert nicht einschliesst: entspricht einem signifikanten Befund bei gleichem alpha.
- Breites KI: grosse Unsicherheit, meist kleine Stichprobe.
- Enges KI: kleine Unsicherheit, meist grosse Stichprobe.

Statistisch signifikant vs. klinisch relevant

Merkmal	Statistisch signifikant	Klinisch relevant
Frage	Ist der Effekt grösser als Zufall?	Ist der Effekt gross genug, um für Patienten bedeutsam zu sein?
Abhängig von	Stichprobengrösse, Variabilität	MCID (minimaler klinisch relevanter Unterschied), Patientenkontext
Beispiel	n = 1000, Unterschied 2 mm ROM, p = 0,02	2 mm ROM ist klinisch nicht bedeutsam
Schlussfolgerung	Kein automatischer Rückschluss möglich	Erfordert inhaltliches Urteil

Vertiefung

Ablauf eines Hypothesentests (Schritte in Reihenfolge)

1. Forschungsfrage formulieren.
2. Hypothesenpaar bilden: H_0 und H_1 (komplementär, vor der Datenerhebung).
3. Signifikanzniveau α festlegen (vor der Auswertung, üblicherweise 0,05).
4. Daten erheben.
5. Geeignetes Testverfahren wählen (abhängig von Skalenniveau, Verteilung, Anzahl der Gruppen).
6. Prüfgrösse berechnen, p-Wert ablesen.
7. Entscheidung: $p < \alpha \rightarrow H_0$ ablehnen / $p \geq \alpha \rightarrow H_0$ beibehalten.
8. Inhaltliche Interpretation: Effektgrösse, klinische Relevanz.

Einflussfaktoren auf den p-Wert

- Effektgrösse: je grösser der Effekt, desto kleiner der p-Wert.
- Stichprobengrösse: je mehr Personen, desto kleiner der p-Wert, auch bei kleinen Effekten.
- Streuung der Daten: je grösser die Streuung, desto grösser der p-Wert.

Prüfungsfallen auf einen Blick

- $p = 0,04$ beweist nicht, dass H_0 falsch ist. Es ist eine Entscheidungsregel unter Unsicherheit.
- Ein nicht-signifikantes Ergebnis ist kein Beweis für die H_0 . Abwesenheit von Evidenz ist nicht Evidenz für Abwesenheit.
- Das Signifikanzniveau wird VOR der Datenerhebung festgelegt, nicht danach.
- KI und p-Wert liefern konsistente Aussagen: Wenn das 95%-KI den Nullwert nicht einschliesst, ist $p < 0,05$.

Kapitel 8: Kritische Appraisal und Interpretation von Forschungsergebnissen

Kurz erklärt

Eine Studie zu lesen bedeutet nicht, ihr zu vertrauen. Kritisches Appraisal ist das strukturierte Prüfen einer Studie auf methodische Qualität, bevor man ihre Ergebnisse in der Praxis anwendet. Dafür gibt es Checklisten wie PEDro (für RCTs in der Physiotherapie) oder CONSORT (für die Berichterstattung von RCTs), die systematisch abfragen, ob zentrale Qualitätsmerkmale erfüllt sind. Die Evidenzhierarchie zeigt, welche Studiendesigns grundsätzlich stärkere Aussagekraft haben — aber ein hohes Design-Level allein garantiert keine Qualität. Ein schlecht durchgeführter Randomisierte kontrollierte Studie (RCT) kann weniger aussagekräftig sein als eine sorgfältige Kohortenstudie. Am Ende zählt nicht nur, ob ein Ergebnis statistisch signifikant ist, sondern ob es klinisch relevant und auf die eigene Patientengruppe übertragbar ist.

Physiotherapie (PT)-Beispiel

Eine RCT untersucht manuelle Therapie bei chronischem Kreuzschmerz: $p = 0.03$ zugunsten der Interventionsgruppe. Auf den ersten Blick sieht das überzeugend aus. Beim kritischen Lesen zeigt sich: $n = 18$ pro Gruppe, Dropout 35 %, keine verblindete Outcome-Erhebung, und der Unterschied im Schmerzwert beträgt 0,4 Punkte auf einer 10er-Skala. Der minimale klinisch relevante Unterschied (MCID) liegt bei dieser Skala bei 2 Punkten. Das Ergebnis ist statistisch signifikant, aber klinisch nicht relevant. Zusätzlich schränkt der hohe Dropout die interne Validität ein. Diese Studie rechtfertigt keine Änderung der Behandlungspraxis.

Für die Prüfung

Evidenzhierarchie (von hoch nach niedrig)

Ebene	Studiendesign
1	Systematische Reviews und Meta-Analysen von RCTs
2	Einzelne RCTs
3	Nicht-randomisierte kontrollierte Studien
4	Kohortenstudien
5	Fall-Kontroll-Studien
6	Fallserien, Fallberichte
7	Expertenmeinung, Konsensus

Prüfungsfalle: Level 1 oder 2 bedeutet nicht automatisch hohe Qualität. Entscheidend sind immer: Stichprobengrösse, Bias-Risiko, Dropout, Heterogenität.

Checklisten: PEDro vs. CONSORT

Merkmal	PEDro	CONSORT
Verwendungszweck	Bewertung der methodischen Qualität von RCTs	Leitlinie zur Berichterstattung von RCTs
Anwendung durch	Leser, Reviewer	Autoren beim Verfassen
Typische Items	Randomisierung, Verblindung, ITT-Analyse, Dropout-Bericht	Flowchart, Stichprobenkalkulation, Randomisierungsverfahren
Kontext PT	Direkt relevant, da auf klinische Studien zugeschnitten	Allgemein medizinisch

Kritische Lesefragen: Bias, Confounding, Generalisierbarkeit**Bias (systematischer Fehler):**

- Selektionsbias: Gruppen sind vor Interventionsbeginn nicht vergleichbar
- Performance-Bias: Unterschiedliche Behandlung der Gruppen ausser der Intervention selbst
- Detection-Bias: Outcome-Erhebung nicht verblindet
- Attrition-Bias: Unterschiedliche oder hohe Dropout-Raten (Faustregel: über 20 % kritisch, über 30 % meist nicht mehr akzeptabel)
- Reporting-Bias: Nur signifikante Ergebnisse werden berichtet

Confounding:

- Eine dritte Variable beeinflusst sowohl die unabhängige als auch die abhängige Variable
- Beispiel: Studie zu Trainingseffekten, aber die Interventionsgruppe ist im Schnitt 10 Jahre jünger
- Kontrolle durch: Randomisierung, Matching, statistische Adjustierung

Generalisierbarkeit (externe Validität):

- Frage: Ist die Stichprobe repräsentativ für meine Patientengruppe?
 - Prüfpunkte: Ein- und Ausschlusskriterien, Setting (Klinik vs. Praxis), Alter, Schweregrad, Komorbiditäten
 - Hohe interne Validität (sauberes Design) geht oft auf Kosten der externen Validität (strenge Einschlusskriterien, die die Realität nicht abbilden)
-

Klinische Relevanz beurteilen

Kriterium	Frage
Statistisch signifikant	Ist $p < 0.05$ (oder Konfidenzintervall ohne 0/1)?
Klinisch relevant	Überschreitet der Effekt den MCID?
Stichprobengrösse	Ausreichend gepowert, oder nur zufälliger Befund?
Baseline-Unterschiede	Waren Gruppen vor der Intervention vergleichbar?
Dropout	Wie viele Teilnehmende fehlen im Endresultat?
Intention-to-treat	Wurden alle Randomisierten in der Auswertung behalten?

Vertiefung

Heterogenität in Meta-Analysen

- **I²-Statistik** misst den Anteil der Varianz zwischen Studien, der nicht durch Zufall erklärt wird
 - I² unter 25 %: geringe Heterogenität — Pooling sinnvoll
 - I² 25–50 %: moderate Heterogenität — mit Vorsicht interpretieren
 - I² über 50 %: hohe Heterogenität — gepoolter Effekt ist inhaltlich fraglich
 - Ursachen hoher Heterogenität: unterschiedliche Populationen, verschiedene Interventionsformen, unterschiedliche Outcomemessung, verschiedene Follow-up-Zeiträume
 - **Prüfungsfalle:** Ein niedriger p-Wert (Signifikanzwahrscheinlichkeit) im gepoolten Effekt einer Meta-Analyse mit I² > 50 % ist kein zuverlässiges Ergebnis
-

Intention-to-treat (ITT) vs. Per-Protocol-Analyse

Ansatz	Beschreibung	Problem bei Weglassen
ITT	Alle randomisierten Personen werden ausgewertet, unabhängig von Compliance und Dropout	Ohne ITT wird Attrition-Bias unterschätzt
Per Protocol	Nur Personen, die die Intervention vollständig abgeschlossen haben	Systematische Verzerrung: Non-Completer oft kränker oder weniger motiviert

Interne vs. externe Validität

- **Interne Validität:** Ist der gemessene Effekt tatsächlich auf die Intervention zurückzuführen, und nicht auf Störvariablen?
- **Externe Validität:** Lässt sich das Ergebnis auf andere Populationen, Settings oder Zeitpunkte übertragen?
- Beide stehen häufig in einem Spannungsverhältnis: Je strenger kontrolliert eine Studie ist, desto weiter entfernt sie sich von der klinischen Realität

Zusammenfassung: Was macht ein Ergebnis klinisch verwertbar?

- Studiendesign passend zur Forschungsfrage
- Ausreichende Stichprobengrösse mit Power-Berechnung
- Verblindung, Randomisierung, ITT-Analyse dokumentiert
- Dropout unter 20 %, begründet und symmetrisch
- Effektgrösse oberhalb des MCID
- Patientengruppe vergleichbar mit der eigenen klinischen Population
- Ergebnis repliziert oder durch weitere Studien gestützt