

Empirische Sozialforschung (ESF) Woche 2 — Übungen

Erst selbst versuchen, dann Musterlösung lesen. Bei „Erklär's zurück“-Fragen: Sage fragen oder laut erklären.

Übungen — Forschungsdesigns verstehen und unterscheiden

Übung 1 (Grundniveau)

Aufgabe: Designmerkmale zuordnen

Ordnen Sie die folgenden Aussagen dem jeweils passenden Studiendesign zu. Jedes Design wird genau einmal verwendet.

Designs: Querschnittsstudie, Kohortenstudie, Fall-Kontroll-Studie, Randomisierte kontrollierte Studie (RCT)

- a) Forscher teilen 80 Patienten per Zufallsprinzip zwei Behandlungsgruppen zu und messen das Ergebnis nach 8 Wochen.
- b) Eine Gruppe von Beschäftigten mit Bildschirmarbeit und eine Gruppe ohne Bildschirmarbeit werden zwei Jahre lang beobachtet, um zu prüfen, ob Bildschirmarbeit zu Nackenschmerzen führt. Kein Eingriff erfolgt.
- c) 300 Personen werden einmalig befragt, wie stark ihre Rückenschmerzen sind und wie viel sie sich bewegen.
- d) Patienten mit einer frischen Schulterverletzung werden mit gesunden Kontrollpersonen verglichen. Forscher schauen zurück, welche Belastungen die Verletzten in der Vergangenheit hatten.

Musterlösung Übung 1

- a) RCT — Zufallszuteilung zur Intervention, aktiver Eingriff, prospektiv.
- b) Kohortenstudie — Einteilung nach Exposition (Bildschirmarbeit ja/nein), kein Eingriff, Beobachtung des Outcomes über Zeit.
- c) Querschnittsstudie — einmalige Datenerhebung, kein Eingriff, misst Prävalenz und Zusammenhänge zum selben Zeitpunkt.
- d) Fall-Kontroll-Studie — Startpunkt ist das Outcome (Verletzung vorhanden oder nicht), Blick zurück auf frühere Exposition.

Häufiger Fehler: Kohortenstudie und Fall-Kontroll-Studie werden verwechselt. Merkhilfe: Die Kohortenstudie beginnt beim Risikofaktor und schaut vorwärts. Die Fall-Kontroll-Studie beginnt beim Outcome und schaut rückwärts.

Übung 2 (Mittleres Niveau)

Aufgabe: Mini-Fall beurteilen

Lesen Sie die folgende Fallbeschreibung und beantworten Sie die Fragen.

Eine Physiotherapeutin möchte wissen, ob Patienten, die zusätzlich zur manuellen Therapie ein Heimübungsprogramm erhalten, nach 6 Wochen weniger Schmerzen haben als Patienten, die nur manuelle Therapie erhalten. Sie entscheidet selbst, wer welche Behandlung bekommt: Patienten mit guter Compliance bekommen das Zusatzprogramm, die anderen nicht.

- a) Handelt es sich um eine Beobachtungsstudie oder eine Interventionsstudie? Begründen Sie kurz.
- b) Warum ist dieses Design kein RCT?
- c) Welche Schlussfolgerungen sind auf Basis dieses Designs zulässig, welche nicht? Nennen Sie je eine.
- d) Nennen Sie einen konkreten Confounder, der das Ergebnis verfälschen könnte.

Musterlösung Übung 2

- a) Interventionsstudie — die Forscherin greift aktiv ein und teilt unterschiedliche Behandlungen zu. Es gibt zwei Behandlungsgruppen mit gezielter Zuweisung.
- b) Weil die Zuteilung nicht per Zufall erfolgt, sondern die Forscherin selbst entscheidet (nach Compliance). Das ist eine nicht-randomisierte Interventionsstudie (CCT). Der entscheidende Unterschied zum RCT ist die fehlende Randomisierung.
- c) Zulässig: Eine Aussage über Unterschiede im Schmerzverlauf zwischen den beiden Gruppen unter diesen Bedingungen. Nicht zulässig: Eine Kausalaussage ("Das Heimübungsprogramm verursacht die Verbesserung"), weil die Gruppen sich von Anfang an systematisch unterscheiden können.
- d) Compliance als Confounder: Patienten mit hoher Compliance sind möglicherweise generell motivierter, führen auch andere gesundheitsfördernde Verhaltensweisen aus und hätten vielleicht auch ohne Zusatzprogramm bessere Ergebnisse erzielt. Compliance hängt sowohl mit der Exposition (Zusatzprogramm) als auch mit dem Outcome (Schmerzreduktion) zusammen.

Häufiger Fehler: Viele schreiben, das Design sei eine Kohortenstudie, weil keine Randomisierung stattfindet. Der Unterschied: In der Kohortenstudie greift der Forscher nicht ein — hier weist die Physiotherapeutin aktiv Behandlungen zu. Das macht es zu einer CCT, nicht zu einer Kohortenstudie.

Übung 3 (Prüfungsniveau)

Aufgabe: Interpretation und Designentscheidung

Lesen Sie die drei Szenarien und beantworten Sie jeweils die gestellte Frage.

Szenario A

Eine Forschergruppe veröffentlicht eine Studie: "Patienten, die regelmäßig Yoga praktizieren, haben seltener chronische Rückenschmerzen als Patienten ohne Yogapraxis." Die Studie ist eine Kohortenstudie.

a) Darf man auf Basis dieser Studie schlussfolgern, dass Yoga chronische Rückenschmerzen verhindert? Begründen Sie.

Szenario B

Ein Forschungsteam will untersuchen, ob starkes Rauchen in der Jugend mit dem Auftreten von Lungenerkrankungen im Erwachsenenalter zusammenhängt. Randomisierung ist ethisch unmöglich.

b) Welches Design würden Sie empfehlen? Nennen Sie das Design und erklären Sie in zwei Sätzen, warum es hier geeignet ist.

Szenario C

In einer Studie wurden 150 Patienten mit diagnostiziertem Karpaltunnelsyndrom und 150 Personen ohne diese Diagnose verglichen. Die Forscher fragten beide Gruppen rückwirkend nach ihrer beruflichen Tätigkeit in den letzten 10 Jahren.

c) Wie heißt dieses Design? Nennen Sie einen methodischen Vorteil und einen Nachteil dieses Designs.

d) Kopfrechenaufgabe (ohne Taschenrechner): Von den 150 Personen mit Karpaltunnelsyndrom geben 90 an, früher überwiegend manuelle Arbeit geleistet zu haben. Von den 150 Kontrollpersonen geben 60 dasselbe an. Wie viel Prozent der Fälle und wie viel Prozent der Kontrollen waren manuell tätig? (Ganze Zahlen, keine weiteren Kennwerte nötig.)

Musterlösung Übung 3

Szenario A

a) Nein. Eine Kohortenstudie erlaubt keinen Kausalschluss. Personen, die Yoga praktizieren, unterscheiden sich möglicherweise in vielen weiteren Eigenschaften von Nicht-Yogapraktizierenden (z.B. allgemeiner Gesundheitsbewusstsein, körperliche Aktivität, Stresslevel). Diese Störvariablen könnten den Zusammenhang erklären, ohne dass Yoga selbst die Ursache ist. Zulässig ist nur die Aussage, dass ein Zusammenhang zwischen Yogapraxis und selteneren Rückenschmerzen beobachtet wurde.

Szenario B

b) Kohortenstudie (prospektiv oder retrospektiv). Sie ist geeignet, weil Forscher die Exposition (Rauchverhalten in der Jugend) dokumentieren und dann beobachten, wer im Erwachsenenalter Lungenerkrankungen entwickelt, ohne selbst einzugreifen. Da man Jugendliche ethisch nicht zum Rauchen zuweisen kann, ist ein RCT ausgeschlossen — die Kohortenstudie ist in solchen Situationen der stärkste vertretbare Ansatz.

Szenario C

c) Fall-Kontroll-Studie. Der Startpunkt ist das Outcome (Karpaltunnelsyndrom vorhanden oder nicht), und der Blick geht rückwärts auf frühere Expositionen.

Vorteil: Besonders geeignet für seltene Erkrankungen, da man direkt Personen mit dem Outcome sucht und keine lange Wartezeit bis zum Outcome nötig ist.

Nachteil: Retrospektive Datenerhebung bedeutet Abhängigkeit von Erinnerungen der Befragten (Recall Bias). Personen mit einer Erkrankung erinnern sich möglicherweise anders an frühere Belastungen als gesunde Kontrollpersonen.

d) Fälle: 90 von 150 = 60 Prozent. Kontrollen: 60 von 150 = 40 Prozent.

Rechenweg: $90 \div 150 = 9 \div 15 = 3 \div 5 = 60$. Ebenso $60 \div 150 = 6 \div 15 = 2 \div 5 = 40$.

Häufiger Fehler bei Szenario A: Studierende schreiben, der Zusammenhang sei "nicht aussagekräftig" oder "bedeutungslos". Das ist falsch. Der Zusammenhang ist real beobachtet und kann relevant sein — er erlaubt nur keine Kausalinterpretation. Der Fehler liegt nicht im Befund, sondern in der Interpretation.

Häufiger Fehler bei Szenario C: Die Fall-Kontroll-Studie wird als prospektiv eingeordnet, weil eine Befragung stattfindet. Entscheidend ist aber der Ausgangspunkt: Das Outcome ist bereits vorhanden, der Blick geht zurück. Das macht sie immer retrospektiv.

Übungen — Variablen, Operationalisierung und Skalenniveaus

Übung 1 — Grundlagen (leicht)

Ein Physiotherapeut dokumentiert folgende Merkmale seiner Patienten:

1. Diagnose (z. B. Lumbalgie, Zervikalsyndrom, Schulterimpingement)
2. Schmerzintensität auf der NRS (0–10)
3. Körpergröße in cm
4. Sturzrisiko: ja / nein
5. Anzahl der bisherigen Therapiesitzungen

a) Ordnen Sie jedem Merkmal das korrekte Skalenniveau zu: nominal, ordinal, intervall, verhältnis.

b) Welches Lagemaß (Modus, Median, Mittelwert) ist jeweils das geeignete?

c) Welches der fünf Merkmale ist eine diskrete quantitative Variable?

Musterlösung Übung 1

a)

1. Diagnose — **Nominalskala** (Kategorien ohne Rangfolge)
2. NRS — **Ordinalskala** (Rangfolge klar, Abstände nicht garantiert gleich)
3. Körpergröße in cm — **Verhältnisskala** (absoluter Nullpunkt, gleiche Abstände)
4. Sturzrisiko ja/nein — **Nominalskala**, Sonderfall dichotom/binär
5. Anzahl Therapiesitzungen — **Verhältnisskala** (0 Sitzungen = keine Sitzung, ganzzahlig und diskret)

b)

1. Diagnose — Modus
2. NRS — Median
3. Körpergröße — Mittelwert
4. Sturzrisiko — Modus
5. Anzahl Sitzungen — Mittelwert (Verhältnisskala erlaubt Mittelwert; Hinweis: das Ergebnis kann nicht-ganzzahlig sein, ist aber inhaltlich zulässig)

c) Anzahl der Therapiesitzungen — nur ganze Zahlen möglich, abzählbar, daher diskret.

Häufiger Fehler: Die NRS wird wegen ihrer Zahlenform (0–10) spontan als metrisch eingestuft. Entscheidend ist aber, ob gleiche Abstände garantiert sind — das ist bei der NRS nicht der Fall. Daher: ordinal, Median.

Übung 2 — Operationalisierung und Zuordnung (mittel)

Eine Forschungsgruppe plant eine Studie zur Wirksamkeit von Gangtraining bei Patienten nach Hüft-TEP. Sie möchten folgende Konstrukte erfassen:

- Gehgeschwindigkeit
- Lebensqualität
- Schmerzempfindung
- Sturzangst

a) Handelt es sich bei „Lebensqualität“ und „Sturzangst“ um konkrete oder abstrakte Konstrukte? Begründen Sie kurz.

b) Nennen Sie für „Gehgeschwindigkeit“ eine Operationalisierung und das resultierende Skalenniveau.

c) Lebensqualität wird mit einem validierten Fragebogen erfasst, der einen Summenscore von 0–100 ergibt. Eine Forscherin berechnet den Mittelwert aller Summenscores. Ist das methodisch korrekt? Begründen Sie.

d) Ordnen Sie zu: Welches der vier Konstrukte ist die abhängige Variable (AV), wenn das Gangtraining die Intervention ist?

Musterlösung Übung 2

a) Lebensqualität und Sturzangst sind **abstrakte Konstrukte**. Sie sind nicht direkt beobachtbar und können nicht mit einem physischen Messgerät erfasst werden. Sie benötigen validierte Messinstrumente (z. B. Fragebögen), um operationalisiert zu werden.

b) Operationalisierung: Zeit in Sekunden für einen 10-Meter-Gehtest. Skalenniveau: **Verhältnisskala** (0 Sekunden = keine Gehzeit; gleiche Abstände; Verhältnisaussagen zulässig).

c) Das ist methodisch diskutiert und streng genommen nicht korrekt. Ein Summenscore aus Likert-Items ist **ordinal**, weil nicht garantiert ist, dass gleiche Abstände auf der Skala auch gleiche inhaltliche Unterschiede bedeuten. Der korrekte Lageparameter wäre der **Median**. In der Praxis wird der Mittelwert aus Fragebogen-Summenscores häufig verwendet — das ist eine Konvention, die in der Prüfung als methodische Einschränkung benannt werden sollte.

d) Alle vier Konstrukte kommen prinzipiell als AV in Frage. Wenn die Fragestellung lautet „Verbessert Gangtraining die Gehgeschwindigkeit / Lebensqualität / Schmerzempfindung / Sturzangst?“, dann sind alle vier potenzielle **abhängige Variablen**. Das Gangtraining ist die **unabhängige Variable (UV)**. In

einer Studie mit primärem Endpunkt würde üblicherweise eines davon als primäre AV definiert, z. B. Gehgeschwindigkeit.

Häufiger Fehler: Summenscores aus Fragebögen werden wegen ihrer Bandbreite (0–100) als metrisch behandelt. Das Skalenniveau ergibt sich aber aus den Eigenschaften der Messung, nicht aus der Größe des Wertebereichs.

Übung 3 — Mini-Fall mit Interpretation (schwer)

Lesen Sie folgende Studienplanung und beantworten Sie die Fragen.

Eine Physiotherapeutin untersucht, ob Kräftigungsübungen die Kniefunktion bei Patienten mit Gonarthrose verbessern. Sie erhebt folgende Daten:

- Kellgren-Lawrence-Score (Arthrosegrad Grad I–IV)
- KOOS-Fragebogen (Knee Injury and Osteoarthritis Outcome Score, Summenscore 0–100)
- Maximale isometrische Quadrizepskraft in Newton
- Therapieform: Kräftigungsgruppe vs. Kontrollgruppe

a) Bestimmen Sie das Skalenniveau aller vier Variablen.

b) Welche Variable ist die UV, welche sind AVs?

c) Die Therapeutin berechnet für den Kellgren-Lawrence-Score den Mittelwert. Warum ist das problematisch? Welches Maß wäre korrekt?

d) Kopfrechnen: Fünf Patienten haben folgende Quadrizepskraftwerte (in Newton): 180, 210, 195, 220, 195. Berechnen Sie den Mittelwert.

e) Die Therapeutin möchte aus der metrischen Variable „Quadrizepskraft“ eine ordinale Variable machen, indem sie drei Kategorien bildet: schwach / mittel / stark. Ist das zulässig? Was geht dabei verloren?

Musterlösung Übung 3

a)

- Kellgren-Lawrence-Score (Grad I–IV): **Ordinalskala** (Rangfolge vorhanden, Abstände zwischen Graden nicht gleich groß)
- KOOS-Summenscore (0–100): **Ordinalskala** (Summenscore aus Likert-Items; in der Praxis oft wie metrisch behandelt, methodisch aber ordinal)

- Quadrizepskraft in Newton: **Verhältnisskala** (absoluter Nullpunkt, gleiche Abstände, Verhältnisaussagen zulässig)
- Therapieform (Kräftigungsgruppe / Kontrollgruppe): **Nominalskala**, dichotom

b) UV: Therapieform (Kräftigung vs. Kontrolle). AVs: Kellgren-Lawrence-Score, KOOS, Quadrizepskraft — alle drei bilden mögliche Outcomes ab.

c) Der Kellgren-Lawrence-Score ist ordinal. Die Abstände zwischen Grad I und II müssen inhaltlich nicht gleich groß sein wie zwischen Grad III und IV. Ein Mittelwert setzt gleiche Abstände voraus und ist daher nicht korrekt begründet. Richtiges Lagemaß: **Median**.

d) Summe: $180 + 210 + 195 + 220 + 195 = 1000$. Mittelwert: $1000 \div 5 = 200$ **Newton**.

e) Zulässig — eine Variable von einem höheren auf ein niedrigeres Skalenniveau zu transformieren ist grundsätzlich möglich. Der Informationsverlust besteht darin, dass die genauen Kraftwerte innerhalb einer Kategorie nicht mehr unterscheidbar sind: Ein Patient mit 180 N und einer mit 205 N fallen in dieselbe Kategorie „schwach“, obwohl ein Unterschied von 25 N vorliegt. Der umgekehrte Weg — aus einer Ordinalvariable eine metrische machen — ist nicht zulässig.

Häufiger Fehler: Bei Aufgabe c) wird argumentiert, der Score reiche von 1 bis 4 und sei daher „fast metrisch“. Das ist kein gültiges Argument. Das Skalenniveau hängt von den Messeigenschaften ab, nicht von der Anzahl der Stufen. Selbst ein Score von 1–10 bleibt ordinal, wenn Abstände nicht garantiert gleich sind.

Übungen — Deskriptive Statistik: Daten zusammenfassen und darstellen

Übung 1 (Grundniveau)

Zuordnung: Lagemaß und Streuungsmaß

In der folgenden Liste sind Situationen beschrieben. Geben Sie jeweils an, welcher Lageparameter und welches Streuungsmaß geeignet ist.

- a) Eine Physiotherapeutin erfasst die Gehstrecke (in Metern) bei 30 Patienten nach Knie-TEP. Das Histogramm zeigt eine symmetrische, glockenförmige Verteilung. Keine Ausreißer.
- b) Eine Praxis erfasst die Therapiedauer (in Wochen) bei Patienten mit chronischem Rückenschmerz. Wenige Patienten haben extrem lange Verläufe von über 60 Wochen. Die Verteilung ist stark rechtsschief.
- c) In einer Befragung wird erfasst, welche Sportart Patienten in der Freizeit bevorzugen (Fußball, Schwimmen, Radfahren, keiner). Die Antwort ist eine nominale Variable.
- d) Eine Therapeutin berichtet nur die Spannweite (Range) der erfassten Schmerzwerte, ohne einen weiteren Kennwert anzugeben.

Begründen Sie jede Antwort in einem Satz.

Übung 2 (Mittleres Niveau)

Mini-Fall: Gruppenvergleich und grafische Darstellung

Eine Studie vergleicht die Schmerz-Reduktion (Skala 0–10, metrisch) nach 8 Wochen Physiotherapie in zwei Gruppen:

- Gruppe A (Einzeltherapie, $n = 20$): Werte gleichmäßig verteilt, $MW = 3,4$, $SD = 0,9$
- Gruppe B (Gruppentherapie, $n = 20$): Mehrere Patienten mit sehr geringer Schmerzreduktion (Werte nahe 0), einige mit sehr hoher Reduktion. Median = 2,5, IQR = 3,1

Beantworten Sie folgende Teilfragen:

- a) Warum wird für Gruppe A der Mittelwert und die Standardabweichung berichtet, für Gruppe B dagegen Median und IQR? Begründen Sie mit Bezug auf die Verteilungsform.
 - b) Welche grafische Darstellung ist für den Vergleich beider Gruppen besonders geeignet, wenn man davon ausgeht, dass Gruppe B eine schiefe Verteilung aufweist? Begründen Sie kurz.
 - c) In der Ergebnistabelle steht für Gruppe B: $MW = 2,8$, $SD = 2,6$. Eine Kommilitonin sagt: "Dann nehmen wir einfach den Mittelwert, ist doch einfacher." Erklären Sie, warum das problematisch ist.
-

Übung 3 (Prüfungsniveau)

Interpretation und Kopfrechnen

Ein Forschungsteam erfasst bei 5 Patienten mit Schulterschmerz die Anzahl der Behandlungsstunden bis zur deutlichen Besserung:

Werte: 4, 6, 6, 8, 26

- a) Berechnen Sie den Mittelwert und den Median. Zeigen Sie den Rechenweg. (Taschenrechner nicht erlaubt.)
- b) Welcher Wert beschreibt das typische Behandlungsvolumen dieser Gruppe besser — Mittelwert oder Median? Begründen Sie anhand Ihrer Ergebnisse.
- c) Welches Streuungsmaß passt zu Ihrer Wahl in b)? Begründen Sie.
- d) Das Forschungsteam möchte prüfen, ob die Daten normalverteilt sind. Die Stichprobengröße beträgt $n = 5$. Welcher Test ist geeignet, und warum ist das visuelle Betrachten eines Histogramms bei dieser Stichprobengröße allein nicht ausreichend?
- e) Der Wert 26 wird nachträglich korrigiert: Tatsächlich handelt es sich um einen Dateneingabefehler, der korrekte Wert ist 8. Neuer Datensatz: 4, 6, 6, 8, 8. Was verändert sich bei Mittelwert und Median? Berechnen Sie den neuen Mittelwert. Was zeigt dieser Vergleich über die Robustheit des Medians?

Musterlösungen

Musterlösung Übung 1

a) Skalenniveau: metrisch, Verteilung: symmetrisch, keine Ausreißer.

Geeignet: **Mittelwert und Standardabweichung.**

Begründung: Bei symmetrischer, metrischer Verteilung ohne Ausreißer repräsentiert der MW das Zentrum der Daten zuverlässig; die SD beschreibt die Streuung um diesen MW.

b) Skalenniveau: metrisch, Verteilung: rechtsschief, Ausreißer vorhanden.

Geeignet: **Median und IQR.**

Begründung: Der MW wird durch die extremen Werte nach oben verzerrt; der Median berücksichtigt nur die Position der Werte und bleibt stabil, der IQR ist ebenfalls unempfindlich gegenüber Ausreißern.

c) Skalenniveau: nominal.

Geeignet: **Modus** (häufigste Kategorie).

Begründung: Nominale Daten lassen keine Rangreihe oder Abstände zu — einzig der Modus ist als Lageparameter sinnvoll; ein Streuungsmaß ist auf Nominalniveau nicht sinnvoll angebar.

d) Die Range allein ist kein ausreichendes Streuungsmaß.

Begründung: Die Range ist extrem empfindlich gegenüber Ausreißern und gibt nur das Maximum minus Minimum an — sie enthält keine Information über die Verteilung der Werte dazwischen. Sie wird nur ergänzend, nie allein berichtet.

Musterlösung Übung 2

a) Gruppe A zeigt eine gleichmäßige (symmetrische) Verteilung ohne ausgeprägte Ausreißer. Unter dieser Bedingung ist der MW ein unverzerrtes Maß für die Mitte der Verteilung, und die SD beschreibt die Streuung sinnvoll um diesen MW. Gruppe B weist eine schiefe Verteilung auf (viele niedrige Werte, einige sehr hohe). Hier würde der MW durch die extremen Werte nach oben verzerrt und das typische Behandlungsergebnis überzeichnen. Der Median bleibt stabil, weil er nur auf Rangpositionen basiert. Der IQR gibt den Bereich der mittleren 50 Prozent der Werte an und ist ebenfalls ausreißerresistent.

b) Geeignet ist der **Boxplot**. Er zeigt für jede Gruppe gleichzeitig Median, IQR, Range und Ausreißer. Gerade bei schiefer Verteilung (Gruppe B) macht der Boxplot die Asymmetrie und eventuelle Extremwerte sichtbar. Ein Histogramm wäre alternativ für eine Gruppe möglich, eignet sich aber weniger gut für den direkten Gruppenvergleich.

c) Die Kommilitonin liegt falsch. Eine SD von 2,6 bei einem MW von 2,8 zeigt, dass die Streuung fast so groß ist wie der MW selbst. Das ist ein deutliches Zeichen für eine schiefe Verteilung oder extreme Ausreißer. Der MW wird durch diese Extremwerte verzerrt und repräsentiert dann nicht mehr das typische Ergebnis der Mehrheit der Patienten. In diesem Fall ist der Median das ehrlichere und aussagekräftigere Lagemaß — der MW wirkt nach außen präziser, als er inhaltlich ist.

Musterlösung Übung 3

a)

Mittelwert:

Summe = $4 + 6 + 6 + 8 + 26 = 50$

MW = $50 / 5 = 10$

Median:

Werte bereits sortiert: 4, 6, **6**, 8, 26

Mittlerer Wert (Position 3) = **6**

b) Der **Median (6)** beschreibt das typische Behandlungsvolumen besser. Der MW von 10 liegt deutlich über den Werten von vier der fünf Patienten und wird durch den Ausreißer (26 Stunden) stark nach oben gezogen. Der Median ist unempfindlich gegenüber diesem Extremwert und spiegelt das Zentrum der Mehrheit der Beobachtungen wider.

c) Passendes Streuungsmaß: **IQR (Interquartilsbereich)**. Da der Median als Lagemaß gewählt wurde und die Verteilung durch einen Ausreißer verzerrt ist, wird der IQR als robustes Streuungsmaß verwendet. Die SD wäre in dieser Situation ebenfalls durch den Ausreißer verzerrt und damit irreführend.

d) Geeignet ist der **Shapiro-Wilk-Test**, der bei kleinen Stichproben (n unter 50) eingesetzt wird, um zu prüfen, ob die Daten signifikant von der Normalverteilung abweichen. Das visuelle Betrachten eines Histogramms ist bei $n = 5$ allein nicht ausreichend, weil mit so wenigen Werten keine stabile Verteilungsform im Histogramm erkennbar ist — zufällige Schwankungen sehen leicht wie systematische Abweichungen aus oder umgekehrt. Eine visuelle Beurteilung ist bei kleinen Stichproben zu unzuverlässig.

e)

Neuer Datensatz: 4, 6, 6, 8, 8

Summe = $4 + 6 + 6 + 8 + 8 = 32$

Neuer MW = $32 / 5 = 6,4$

Median: Werte sortiert: 4, 6, **6**, 8, 8 — Median bleibt **6**, unverändert.

Der Mittelwert hat sich durch die Korrektur eines einzelnen Wertes deutlich verändert (von 10 auf 6,4).

Der Median blieb bei 6 stabil. Das zeigt die **Robustheit des Medians gegenüber Ausreißern**: Er reagiert nicht auf den konkreten Abstand eines Extremwertes vom Zentrum, sondern nur auf die Rangposition der Werte. Der MW hingegen berücksichtigt jeden Wert mit seinem tatsächlichen Abstand vom Mittel und ist daher empfindlich gegenüber Fehlern und Extremwerten.

Häufige Fehler

Übung 1: Schülerinnen und Schüler wählen bei ordinalen Daten den Mittelwert. Das ist nicht korrekt — auf Ordinalniveau sind Abstände zwischen Kategorien nicht definiert, daher ist der Median das geeignete Maß. Ein weiterer häufiger Fehler: Die Range wird als vollständiges Streuungsmaß akzeptiert, ohne zu erkennen, dass sie nur zwei Extrempunkte beschreibt.

Übung 2: Der häufigste Fehler in Teilaufgabe c) ist, die hohe SD als "normales Merkmal großer Streuung" abzutun, ohne zu schlussfolgern, dass sie die Verwendung des Mittelwerts infrage stellt. Eine SD, die fast so groß ist wie der MW, ist ein Warnsignal für Schiefe oder Ausreißer — nicht nur ein Hinweis auf "viel Varianz".

Übung 3: Bei der Berechnung des Mittelwerts wird die 26 vergessen oder die Summe falsch addiert. Zudem wird in b) häufig der Mittelwert gewählt, weil er "genauer wirkt" — ohne zu berücksichtigen, dass rechnerische Genauigkeit und inhaltliche Repräsentativität zwei verschiedene Dinge sind. In d) wird der Kolmogorov-Smirnov-Test genannt — dieser ist jedoch für größere Stichproben vorgesehen. Bei $n = 5$ ist der Shapiro-Wilk-Test korrekt.

Übungen — Bivariate Deskriptive Statistik: Zusammenhänge beschreiben

Aufgabe 1 (Grundniveau)

Ein Forschungsteam erhebt bei 60 Patienten zwei Variablen: Gehgeschwindigkeit in m/s (metrisch, normalverteilt) und Sturzangst auf einer 4-stufigen Ordinalskala (1 = keine Angst, 4 = sehr hohe Angst).

- a) Welcher Korrelationskoeffizient ist für diesen Datensatz geeignet — Pearson-r oder Spearman-rs? Nennen Sie zwei Gründe.
 - b) Das Ergebnis lautet $r_s = -0,44$. Beschreiben Sie den Zusammenhang: Richtung, Stärke und inhaltliche Bedeutung in einem Satz.
 - c) Eine Kollegin sagt: „Das beweist, dass Sturzangst langsamer macht.“ Was ist daran statistisch problematisch?
-

Aufgabe 2 (Mittelniveau)

In einer Kohortenstudie wird untersucht, ob regelmäßiges Rauchen mit dem Auftreten von Rückenschmerzen zusammenhängt. Von 200 Rauchern entwickeln 80 Rückenschmerzen. Von 200 Nichtraucher entwickeln 40 Rückenschmerzen.

- a) Berechnen Sie das Relative Risiko (RR) ohne Taschenrechner. Zeigen Sie den Rechenweg.
 - b) Interpretieren Sie den RR-Wert inhaltlich: Was bedeutet er für Raucher im Vergleich zu Nichtrauchern?
 - c) Warum wird in dieser Studie RR und nicht OR berechnet?
-

Aufgabe 3 (Prüfungsniveau)

Lesen Sie die folgende Studienbeschreibung und beantworten Sie die Fragen.

Eine Studie untersucht den Zusammenhang zwischen täglicher Bildschirmzeit in Stunden (metrisch) und Schlafqualität auf dem Pittsburgh Sleep Quality Index (PSQI, 0–21 Punkte, ordinal). Das Streudiagramm zeigt eine deutlich gebogene, U-förmige Punktwolke. Berechnet wird Pearson-r = -0,09, der als „kein Zusammenhang“ interpretiert wird.

- a) Nennen Sie zwei methodische Fehler, die in der Beschreibung stecken.
- b) Welcher Koeffizient wäre stattdessen zu wählen? Begründen Sie mit Blick auf Skalenniveau und Streudiagrammbefund.
- c) Was bedeutet es, dass Pearson-r nahe 0 ist, obwohl das Streudiagramm eine U-Form zeigt? Erläutern Sie das Prinzip in zwei Sätzen.

d) Formulieren Sie eine plausible Drittvariable, die sowohl Bildschirmzeit als auch Schlafqualität beeinflussen könnte, und erklären Sie kurz, warum das die Interpretation des Zusammenhangs erschwert.

Musterlösung

Aufgabe 1

a) Spearman-rs ist geeignet.

Grund 1: Die Sturzangst ist ordinalskaliert — Pearson-r setzt mindestens Intervallskalierung voraus.

Grund 2: Da eine Variable ordinal ist, kann keine Normalverteilung beider Variablen vorausgesetzt werden — eine Voraussetzung für Pearson-r ist damit verletzt.

b) $r_s = -0,44$ beschreibt einen mittleren negativen Zusammenhang: Patienten mit höherer Sturzangst tendieren dazu, langsamer zu gehen.

c) Aus einer Korrelation lässt sich keine Kausalität ableiten. Es ist ebenso möglich, dass langsames Gehen die Sturzangst erhöht, oder dass eine Drittvariable (z. B. allgemeine körperliche Einschränkung) beide Variablen gleichzeitig beeinflusst.

Aufgabe 2

a)

Risiko Raucher: $80 / 200 = 0,40$

Risiko Nichtraucher: $40 / 200 = 0,20$

$RR = 0,40 / 0,20 = 2,0$

b) Raucher haben ein doppelt so hohes Risiko, Rückenschmerzen zu entwickeln, wie Nichtraucher. Rauchen ist in dieser Studie mit einem erhöhten Risiko assoziiert ($RR > 1$).

c) Es handelt sich um eine Kohortenstudie mit prospektivem Design. Die Ausgangsgruppengrößen sind bekannt und zufällig zugeteilt (bzw. beobachtet), daher lässt sich ein echtes Ausgangsrisiko berechnen. RR setzt genau das voraus. OR würde hier das Risiko überschätzen, da das Ereignis (Rückenschmerzen) mit 40 % bzw. 20 % nicht selten ist.

Aufgabe 3

a)

Fehler 1: Pearson-r ist bei ordinalskalierten Daten (PSQI) nicht zulässig — das Verfahren setzt mindestens Intervallskalierung voraus.

Fehler 2: Das Streudiagramm zeigt eine U-förmige Kurve — damit ist der Zusammenhang nicht linear. Pearson-r misst aber ausschließlich lineare Zusammenhänge und ist daher auch aus diesem Grund unangemessen.

b) Spearman-rs wäre zu wählen: Der PSQI ist ordinal, und Spearman-rs setzt keine Normalverteilung und keinen linearen Zusammenhang voraus — es wird lediglich ein monotoner Zusammenhang geprüft. Auch Spearman-rs kann eine U-Form nicht vollständig abbilden, ist aber zumindest hinsichtlich des Skalenniveaus korrekt.

c) Pearson-r misst nur den linearen Anteil eines Zusammenhangs. Bei einer U-Form heben sich positive und negative Abweichungen gegenseitig auf, sodass der Koeffizient nahe null liegt — obwohl ein systematischer, nicht-linearer Zusammenhang besteht. $r = 0$ schließt also einen Zusammenhang nicht aus, sondern bedeutet nur: kein linearer Zusammenhang erkennbar.

d) Beispiel: Stress oder psychische Belastung. Wer stark gestresst ist, verbringt möglicherweise mehr Zeit am Bildschirm (als Ablenkung oder berufsbedingt) und schläft gleichzeitig schlechter (durch physiologische Aktivierung). Wenn eine Drittvariable beide Messgrößen beeinflusst, kann der beobachtete Zusammenhang zwischen Bildschirmzeit und Schlafqualität zumindest teilweise auf diese Drittvariable zurückzuführen sein — und nicht auf eine direkte Beziehung der beiden Variablen untereinander.

Häufige Fehler

Aufgabe 1:

Der häufigste Fehler ist die Wahl von Pearson-r mit der Begründung, die Gehgeschwindigkeit sei metrisch. Entscheidend ist aber das niedrigste Skalenniveau der beiden Variablen — und das ist hier ordinal. Sobald eine Variable ordinal ist, entfällt Pearson-r.

Aufgabe 2:

Viele Studierende verwechseln RR und OR oder begründen die Wahl nicht mit dem Studiendesign. RR ist an das prospektive Design geknüpft, weil nur dann die Ausgangsrisiken in beiden Gruppen bekannt sind. Ein zweiter häufiger Fehler: Das Ergebnis $RR = 2$ wird als „Rauchen verursacht Rückenschmerzen“ interpretiert — auch hier gilt: Kohortenstudien zeigen Assoziation, nicht Kausalität.

Aufgabe 3:

Der klassische Fehler ist die Schlussfolgerung, $r = 0$ bedeute „kein Zusammenhang“ — ohne die Einschränkung auf lineare Zusammenhänge zu nennen. Wer das Streudiagramm ignoriert und sich allein auf den Koeffizientenwert verlässt, übersieht systematisch nicht-lineare Muster. Das Streudiagramm ist deshalb kein optionaler Schritt, sondern Voraussetzungsprüfung.

Übungen — Induktive Statistik und Hypothesentestung

Übung 1 (Grundniveau)

Zuordnung: Fehlerarten und Entscheidungen

In einer Studie zur Wirksamkeit von Ultraschalltherapie bei Fersensporn werden zwei Gruppen verglichen. Das Signifikanzniveau wurde auf $\alpha = 0,05$ festgelegt.

Ordnen Sie den folgenden Aussagen den jeweils passenden Begriff zu. Jeder Begriff wird genau einmal verwendet.

Begriffe: Alpha-Fehler, Beta-Fehler, Teststärke (Power), Signifikanzniveau

- a) Die Forscherin legt vor der Auswertung fest, dass sie H_0 ablehnt, wenn die Wahrscheinlichkeit der beobachteten Daten unter H_0 kleiner als 5 % ist. Welchen Begriff beschreibt diese Vorab-Festlegung?
 - b) Die Studie findet keinen signifikanten Unterschied ($p = 0,12$). Tatsächlich wirkt Ultraschall in der Population besser als die Kontrollbedingung. Welcher Fehler liegt vor?
 - c) Die Studie findet einen signifikanten Unterschied ($p = 0,03$). Tatsächlich gibt es in der Population keinen Effekt. Welcher Fehler liegt vor?
 - d) Eine zweite, deutlich grösser angelegte Studie kann denselben Effekt mit einer Wahrscheinlichkeit von 85 % entdecken, wenn er tatsächlich existiert. Welcher Begriff bezeichnet diese 85 %?
-

Übung 2 (Mittleres Niveau)

Mini-Fall: Interpretation eines Studienergebnisses

Eine Physiotherapeutin untersucht, ob ein strukturiertes Gangtraining die 6-Minuten-Gehstrecke bei Patienten mit COPD im Vergleich zu einem unstrukturierten Spaziergang verbessert. Sie formuliert folgende Hypothesen:

- H_0 : Gangtraining und unstrukturierter Spaziergang unterscheiden sich nach 8 Wochen nicht in der 6-Minuten-Gehstrecke.
- H_1 : Gangtraining führt nach 8 Wochen zu einer längeren 6-Minuten-Gehstrecke als unstrukturierter Spaziergang.

Das Signifikanzniveau wird auf $\alpha = 0,05$ festgelegt. Das Ergebnis: $p = 0,03$, mittlere Verbesserung in der Gangtraining-Gruppe im Vergleich zur Kontrollgruppe: 18 Meter. Das 95%-Konfidenzintervall für die mittlere Differenz beträgt [3 m; 33 m]. Der MCID für die 6-Minuten-Gehstrecke bei COPD beträgt 25 Meter.

Beantworten Sie folgende Fragen:

- a) Welche Entscheidung trifft die Forscherin bezüglich H_0 ? Begründen Sie.

- b) Ist H_1 gerichtet oder ungerichtet? Was bedeutet das für die Hypothese?
 - c) Schliesst das Konfidenzintervall den Nullwert (0) ein? Was folgt daraus für die Signifikanzaussage?
 - d) Beurteilen Sie das Ergebnis hinsichtlich klinischer Relevanz. Begründen Sie Ihre Antwort mit dem MCID.
 - e) Nennen Sie einen Fehler, den die Forscherin bei der Interpretation machen könnte, und erklären Sie, warum er falsch ist.
-

Übung 3 (Prüfungsniveau)

Kombinierte Aufgabe: Forschungslogik, Kopfrechnen, Interpretation

In einer randomisierten kontrollierten Studie wird die Wirkung von Kinesiotaping auf die Schmerzintensität (NRS 0–10) bei Patienten mit Schulterschmerzen untersucht.

Angaben:

- Gruppe A (Kinesiotaping): $n = 40$, mittlerer NRS-Wert nach 4 Wochen: 3, 5, 4, 4, 4 (5 Messwerte stellvertretend für die Gruppenauswertung; Mittelwert ist zu berechnen)
- Gruppe B (Scheinbehandlung): mittlerer NRS-Wert nach 4 Wochen: 5,2
- $p = 0,048$, $\alpha = 0,05$ (zweiseitig)
- 95%-KI der Differenz: [0,01; 0,79]
- MCID für NRS bei Schulterschmerzen: 1,5 Punkte

Beantworten Sie folgende Fragen:

- a) Berechnen Sie den Mittelwert der fünf Messwerte aus Gruppe A (Kopfrechnen, kein Taschenrechner).
 - b) Formulieren Sie ein geeignetes Hypothesenpaar für diese Studie (H_0 und H_1 , ungerichtet).
 - c) Welche Entscheidung ergibt sich auf Basis des p-Werts? Begründen Sie.
 - d) Das Konfidenzintervall lautet [0,01; 0,79]. Was sagt Ihnen dieses Intervall über die Präzision der Schätzung? Was sagt es über die klinische Relevanz?
 - e) Ein Kommilitone sagt: " $p = 0,048$ bedeutet, dass H_0 nur mit 4,8 % Wahrscheinlichkeit stimmt." Erklären Sie in zwei bis drei Sätzen, warum diese Aussage falsch ist, und formulieren Sie die korrekte Interpretation.
 - f) Nennen Sie zwei Massnahmen, mit denen die Teststärke einer Folgestudie erhöht werden könnte.
-

Musterlösungen

Musterlösung Übung 1

- a) Signifikanzniveau. Es beschreibt die vorab festgelegte Schwelle (hier 5 %), ab der H_0 abgelehnt wird.

- b)** Beta-Fehler (Typ-II-Fehler). H_0 wird beibehalten, obwohl H_1 in der Population gilt. Ein real vorhandener Effekt wird übersehen.
- c)** Alpha-Fehler (Typ-I-Fehler). H_0 wird abgelehnt, obwohl sie in der Population wahr ist. Es wird ein Effekt "gefunden", der nicht existiert.
- d)** Teststärke (Power). Sie gibt an, mit welcher Wahrscheinlichkeit ein tatsächlich vorhandener Effekt in der Studie entdeckt wird. Hier: $1 - \text{Beta} = 0,85$.
-

Musterlösung Übung 2

- a)** H_0 wird abgelehnt, weil $p = 0,03$ kleiner ist als das vorab festgelegte Signifikanzniveau $\alpha = 0,05$. Das Ergebnis gilt als statistisch signifikant.
- b)** H_1 ist gerichtet. Die Hypothese legt eine spezifische Richtung des Effekts fest: Gangtraining führt zu einer *längeren* Gehstrecke als die Kontrollbedingung, nicht nur zu einem irgendwie gearteten Unterschied.
- c)** Das KI [3 m; 33 m] schliesst den Nullwert (0) nicht ein. Das stimmt mit der Signifikanzaussage überein: Wenn das 95%-KI den Nullwert nicht einschliesst, ist das Ergebnis bei $\alpha = 0,05$ signifikant.
- d)** Der beobachtete Unterschied beträgt 18 Meter. Der MCID liegt bei 25 Metern. Da 18 Meter unterhalb des MCID liegen, ist der Unterschied statistisch signifikant, aber klinisch nicht relevant. Patienten würden diesen Unterschied im Alltag wahrscheinlich nicht spürbar wahrnehmen.
- e)** Möglicher Fehler: Die Forscherin schlussfolgert, $p = 0,03$ beweise, dass Gangtraining klinisch wirksam ist. Das ist falsch: Ein statistisch signifikantes Ergebnis belegt nur, dass der beobachtete Effekt unwahrscheinlich allein durch Zufall entstanden ist. Über die klinische Bedeutsamkeit sagt der p -Wert (Signifikanzwahrscheinlichkeit) nichts aus.
-

Musterlösung Übung 3

- a)** Mittelwert: $(3 + 5 + 4 + 4 + 4) / 5 = 20 / 5 = 4,0$
- b)**
- H_0 : Kinesiotaping und Scheinbehandlung unterscheiden sich nach 4 Wochen nicht in der Schmerzintensität (NRS) bei Patienten mit Schulterschmerzen.
 - H_1 : Kinesiotaping und Scheinbehandlung unterscheiden sich nach 4 Wochen in der Schmerzintensität (NRS) bei Patienten mit Schulterschmerzen.
- c)** H_0 wird abgelehnt. $p = 0,048$ ist kleiner als $\alpha = 0,05$. Das Ergebnis ist statistisch signifikant. Die Entscheidung folgt der vorab festgelegten Regel: $p < \alpha \rightarrow H_0$ ablehnen.
- d)**
- Präzision: Das KI [0,01; 0,79] ist sehr breit und liegt durchgehend nahe bei null. Das weist auf eine grosse Unsicherheit in der Schätzung hin, vermutlich bedingt durch eine relativ kleine Stichprobe.
 - Klinische Relevanz: Die gesamte Breite des KI liegt unterhalb des MCID von 1,5 Punkten. Selbst der obere Wert (0,79) entspricht weniger als der Hälfte des MCID. Der Effekt ist statistisch signifikant, aber

klinisch nicht bedeutsam.

e) Die Aussage ist falsch. Der p-Wert gibt nicht die Wahrscheinlichkeit an, dass H_0 wahr ist. Er gibt an, wie wahrscheinlich es ist, die beobachteten Daten (oder noch extremere) zu erhalten, *wenn H_0 wahr wäre*. Formal: $P(\text{Daten} \mid H_0 \text{ wahr})$, nicht $P(H_0 \text{ wahr} \mid \text{Daten})$. $p = 0,048$ bedeutet: Falls kein Effekt in der Population existiert, wären Daten wie diese oder noch auffälligere in 4,8 % der Fälle zu erwarten.

f) Zwei Massnahmen zur Erhöhung der Teststärke:

1. Vergrößerung der Stichprobe (mehr Teilnehmende erhöhen die Chance, einen vorhandenen Effekt zu entdecken).
2. Reduktion der Streuung der Messwerte, z. B. durch präzisere Messinstrumente oder homogenere Stichproben.

Häufige Fehler

Übung 1: Alpha- und Beta-Fehler werden verwechselt. Merkhilfe: Alpha-Fehler = falscher Alarm (H_0 fälschlich abgelehnt), Beta-Fehler = verpasster Treffer (H_0 fälschlich beibehalten). Die Richtung des Fehlers hängt davon ab, *welche* Entscheidung getroffen wird und *was* tatsächlich gilt.

Übung 2: Studierende leiten aus einem statistisch signifikanten Ergebnis direkt klinische Relevanz ab. Der MCID ist das entscheidende Kriterium für klinische Bedeutsamkeit — der p-Wert beantwortet diese Frage nicht.

Übung 3: Der p-Wert wird als Wahrscheinlichkeit der H_0 missverstanden. Das ist der häufigste Interpretationsfehler in der gesamten Statistik. Der p-Wert beschreibt eine bedingte Wahrscheinlichkeit der Daten unter H_0 — keine Aussage über die Wahrheit von H_0 selbst. Zusätzlich wird das Konfidenzintervall knapp ausserhalb des Nullwerts fälschlich als Beleg für einen klinisch bedeutsamen Effekt gewertet, obwohl der gesamte Bereich unterhalb des MCID liegt.

Übungen — Kritisches Appraisal und Interpretation von Forschungsergebnissen

Übung 1 — Grundbegriffe zuordnen (leicht)

Ordnen Sie jeden der folgenden Begriffe der passenden Beschreibung zu.

Begriffe:

1. Selektionsbias
2. MCID
3. Externe Validität
4. Attrition-Bias
5. PEDro

-
- a) Eine Checkliste, die Lesende und Reviewer nutzen, um die methodische Qualität von RCTs in der Physiotherapie zu bewerten.
 - b) Der minimale Unterschied in einem Messwert, der für Patientinnen und Patienten noch als bedeutsam wahrgenommen wird.
 - c) Die Gruppen einer Studie sind zu Beginn der Intervention nicht vergleichbar, weil die Zuteilung nicht zufällig oder nicht verdeckt erfolgte.
 - d) Verzerrung durch unterschiedlich hohe oder systematisch unterschiedliche Dropout-Raten in den Studiengruppen.
 - e) Das Ausmass, in dem sich Studienergebnisse auf andere Populationen, Settings oder Zeitpunkte übertragen lassen.
-

Musterlösung Übung 1

- a) -> 5 (PEDro)
- b) -> 2 (MCID)
- c) -> 1 (Selektionsbias)
- d) -> 4 (Attrition-Bias)
- e) -> 3 (Externe Validität)

Häufiger Fehler: PEDro und CONSORT werden verwechselt. PEDro bewerten Lesende, CONSORT ist eine Leitlinie für Autorinnen und Autoren beim Verfassen eines Randomisierte kontrollierte Studie (RCT)-Berichts. Wer diese Richtung dreht, hat beide Konzepte nicht verstanden.

Übung 2 — Mini-Fall: Ist die Studie verwertbar? (mittel)

Lesen Sie die folgende Studienbeschreibung und beantworten Sie die Fragen.

Studienbeschreibung:

Eine RCT untersucht, ob gezielte Kräftigungsübungen bei Kniearthrose den Schmerz reduzieren. Die Interventionsgruppe erhält 8 Wochen Übungsprogramm, die Kontrollgruppe erhält keine Behandlung. Am Ende zeigt die Interventionsgruppe einen mittleren Schmerzurückgang von 1,1 Punkten auf einer Skala von 0–10 ($p = 0.041$). Der MCID für diese Skala liegt bei 2,0 Punkten. Die Stichprobe umfasst je 14 Personen. Die Outcome-Erhebung erfolgte durch die betreuende Therapeutin ohne Verblindung. Dropout: 8 % in der Interventionsgruppe, 6 % in der Kontrollgruppe.

- a) Ist das Ergebnis statistisch signifikant? Begründen Sie in einem Satz.
 - b) Ist das Ergebnis klinisch relevant? Begründen Sie mit Verweis auf den MCID.
 - c) Nennen Sie zwei konkrete methodische Schwächen dieser Studie.
 - d) Welche Art von Bias entsteht dadurch, dass die betreuende Therapeutin selbst das Outcome erhebt?
-

Musterlösung Übung 2

- a) Ja, das Ergebnis ist statistisch signifikant, da $p = 0.041$ unterhalb des Schwellenwerts von $p < 0.05$ liegt.
- b) Nein, das Ergebnis ist klinisch nicht relevant. Der beobachtete Unterschied von 1,1 Punkten liegt unterhalb des MCID von 2,0 Punkten — der Effekt ist zu gering, um für Patientinnen und Patienten spürbar zu sein.
- c) Zwei methodische Schwächen (Auswahl von zwei der folgenden):
 - Sehr kleine Stichprobe ($n = 14$ pro Gruppe): geringe statistische Power, Zufallsbefund wahrscheinlicher
 - Keine Verblindung der Outcome-Erhebung: Therapeutin kennt die Gruppenzugehörigkeit
 - Kontrollgruppe erhält keinerlei Behandlung: kein Placebo-Arm, Erwartungseffekte können den Unterschied beeinflussen
- d) Detection-Bias: Das Outcome wird von einer nicht verblindeten Person erhoben, die die Gruppenzugehörigkeit kennt und damit — bewusst oder unbewusst — die Bewertung beeinflussen kann.

Häufiger Fehler: Viele schreiben, das Ergebnis sei "gut", weil $p < 0.05$. Statistisch signifikant bedeutet nicht klinisch relevant. Beide Kriterien müssen separat geprüft werden.

Übung 3 — Interpretation und Forschungslogik (schwer)

Lesen Sie die folgende Situation und beantworten Sie alle Teilfragen.

Situation:

Sie lesen eine Meta-Analyse zu Ultraschalltherapie bei Schulterimpingement. Die Analyse fasst 9

RCTs zusammen. Der gepoolte Effekt zeigt $p = 0.02$ zugunsten der Ultraschallgruppe. Das klingt überzeugend — bis Sie in der Tabelle sehen: $I^2 = 73\%$.

Parallel finden Sie eine einzelne Kohortenstudie zum gleichen Thema. Die Kohorte ist gross ($n = 310$), gut dokumentiert, mit vergleichbarer Patientengruppe (Alter, Schweregrad, Setting) zu Ihrer eigenen Praxis. Dropout beträgt 12% , Outcome-Erhebung verblindet.

-
- a) Was bedeutet $I^2 = 73\%$ für die Interpretation der Meta-Analyse? Warum ist der gepoolte p-Wert (Signifikanzwahrscheinlichkeit) hier mit Vorsicht zu genießen?
- b) Nennen Sie zwei mögliche Ursachen für eine hohe Heterogenität in dieser Meta-Analyse.
- c) Bewerten Sie: Wäre es in dieser Situation vertretbar, der Kohortenstudie mehr Gewicht zu geben als der Meta-Analyse? Begründen Sie Ihre Antwort mit dem Konzept der internen und externen Validität.
- d) Eine Kollegin sagt: "Die Meta-Analyse steht auf Evidenzlevel 1, die Kohortenstudie auf Level 4 — also ist die Meta-Analyse automatisch besser." Erklären Sie, warum diese Aussage so nicht korrekt ist.
-

Musterlösung Übung 3

- a) $I^2 = 73\%$ bedeutet, dass 73% der beobachteten Varianz zwischen den Studien nicht durch Zufall erklärt werden kann, sondern auf echte Unterschiede zwischen den Studien zurückgeht. Ab $I^2 > 50\%$ gilt die Heterogenität als hoch. Ein gepoolter Effekt aus so unterschiedlichen Studien ist inhaltlich fragwürdig: Die Studien messen möglicherweise nicht dasselbe Konstrukt unter denselben Bedingungen. Ein statistisch signifikantes p beim gepoolten Effekt verschleiert diese Inkonsistenz.
- b) Zwei mögliche Ursachen für hohe Heterogenität (Auswahl):
- Unterschiedliche Patientenpopulationen (z. B. Akut- vs. Chronikpatienten, verschiedene Altersgruppen)
 - Verschiedene Dosierungen oder Applikationsformen der Ultraschalltherapie
 - Unterschiedliche Outcomemessungen (z. B. verschiedene Schmerzskaleten, verschiedene Erhebungszeitpunkte)
 - Unterschiedliche Kontrollbedingungen (Scheinbehandlung vs. keine Behandlung vs. aktive Kontrolle)
- c) Ja, es kann vertretbar sein. Die Meta-Analyse hat zwar formal eine höhere Evidenzstufe, aber durch die hohe Heterogenität ist ihre interne Validität in Frage gestellt: Der gepoolte Effekt bildet möglicherweise kein reales, einheitliches Phänomen ab. Die Kohortenstudie hingegen weist bei grosser Stichprobe, niedrigem Dropout und verblindeter Outcome-Erhebung eine gute interne Qualität auf. Ausserdem entspricht die Stichprobe der Kohortenstudie der eigenen klinischen Population — die externe Validität ist also hoch. In der klinischen Entscheidung zählt nicht allein das Design-Level, sondern die tatsächliche Qualität und Übertragbarkeit.
- d) Die Aussage greift zu kurz. Die Evidenzhierarchie gibt an, welches Design bei guter Durchführung grundsätzlich stärkere Aussagekraft hat. Sie garantiert aber keine Qualität im Einzelfall. Eine Meta-Analyse mit $I^2 = 73\%$ fasst heterogene Studien zu einem künstlichen Gesamteffekt zusammen, der klinisch nicht interpretierbar ist. Ein Design auf Ebene 1 kann durch hohe Heterogenität, unklare Einschlusskriterien oder mangelnde Transparenz weniger verwertbar sein als eine sorgfältig

durchgeführte Kohortenstudie. Entscheidend sind immer: Bias-Risiko, Stichprobengröße, Transparenz und Übertragbarkeit — nicht allein die Designkategorie.

Häufiger Fehler: Viele Studierenden akzeptieren Meta-Analysen unkritisch, weil sie auf Evidenzlevel 1 stehen. Die I^2 -Statistik wird dabei entweder nicht beachtet oder falsch interpretiert. Hohe Heterogenität ist kein Randproblem — sie macht den gepoolten Effekt unter Umständen sinnlos.