

Physiopraxis — Empirischer Forschungsprozess (2-teilig)

Gleiches fiktives Randomisierte kontrollierte Studie (RCT) (Schulterschmerz / Rotatorenmanschette).
Optional — Woche 1/2 haben Vorrang.

Teil 1 — Von der Beobachtung zur Forschungsfrage

Physiopraxis Teil1 Beobachtung zur Forschungsfrage

Quelle: *physiopraxis (Thieme), Hochschule Osnabrück.*

Seite 1

Die Grundlage aller wissenschaftlichen Informationen bildet die empirische Forschung. Mit ihr lassen sich auf systematische Art und Weise Erkenntnisse gewinnen [1, 2]. Die empirische Wissenschaft überprüft ihre Hypothesen durch Beobachtungen, die an der Realität gemessen werden. In den Therapiewissenschaften untersucht man beispielsweise mithilfe verschiedener Verfahren, ob eine bestimmte Therapiemaßnahme überhaupt wirksam ist oder ob zwei unterschiedliche Untersuchende mit demselben Test zum selben Ergebnis kommen. Um im Sinne der Evidenzbasierten Medizin (Evidenzbasierte Medizin (EbM)) Patientinnen *Von der Beobachtung zur Forschungsfrage*

Teil 1: Empirische Forschung in der Physiotherapie
Ein fundiertes Clinical Reasoning richtet sich nach den Standards der evidenzbasierten Medizin. Aber wie gewinnen Forschende die Informationen über die bestmögliche Therapie? Unsere zweiteilige Artikelserie erklärt anhand einer randomisierten kontrollierten Studie, wie sich Beobachtungen in der praktischen Arbeit systematisch überprüfen lassen.
bestmöglich zu behandeln, sollten klinisch tätige Therapierende Prozesse der empirischen Forschung (ABB. 2, S.13) verstehen. Wissen sie, wie diese ablaufen, können sie die richtigen Schlussfolgerungen aus Forschungsergebnissen für ihren klinischen Alltag ableiten.

Vom Beobachten zur Forschungsfrage ->

Anhand eines fiktiven Beispiels wollen wir den empirischen Forschungsprozess darstellen.

Häufig ergeben sich im klinischen Alltag Fragen, auf die es Antworten zu finden gilt. Eine

Gruppe forschender Physiotherapeutinnen könnte sich beispielsweise die Frage stellen, ob ein gezieltes Training der Rotatorenmanschette bei Patientinnen und Patienten mit ventralen Schulterschmerzen nicht effektiver sein müsste als ein konventionelles Trainingsprogramm des Schulter-Nacken-Bereichs.

Ausgehend von der Fragestellung wäre der nächste Schritt, mithilfe von Literatur einen ersten Überblick über die bestehenden Evidenzen zu erlangen. Dadurch kann man das Thema näher beleuchten, sodass sich eine konkrete Suchstrategie für die darauffolgende systematische Literaturrecherche entwickeln lässt. Diese führt man in medizinischen Datenbanken wie

PubMed durch und erfährt, welche Forschungsfragen im Rahmen von Studien bereits untersucht wurden und welche Forschungslücken es noch gibt.

Da die Ergebnisse der Forschungsarbeit dazu dienen sollen, einen Rückschluss (ABB. 1,

S.13) auf die Grundgesamtheit zu ziehen, ist essenziell, eine repräsentative Stichprobe festzulegen, die die Merkmale dieser Population trägt. Hierzu definieren Forschende in ihrem Studienprotokoll (

BAUPLAN) bestimmte Charakteristika (Einschlusskriterien), die die Eigenschaften dieser Stichprobe ausmachen. Des Weiteren müssen sie Ausschlusskriterien festlegen, die der Präzisierung der Stichprobe dienen und zudem eventuelle Störfaktoren sind, die das Outcome beeinflussen könnten. Die Ein- und Ausschlusskriterien

sollte man, wenn möglich, auf Basis bisheriger Forschung wählen. Zusätzlich richten sie sich stark nach der Population, auf die Aussagen

getroffen werden sollen. Bei der Planung des Forschungsvorhabens und der Konkretisierung der Forschungsfrage hilft dem Forschungsteam das

PICOT-Schema.

-> Patient*innen: 18–45jährige Männer oder Frauen, die an einem ventralen Schulter schmerz bei Überkopfarbeiten leiden und keine Schultertraumata, Operationen, System erkrankungen, neurologische Symp tome, Thoracic Outlet Syndrome (TOS),
Begriffe der For schungsmethodik

-> Intervention: gezieltes Training zur Kräfti

-> ControlGruppe: konventionelles Übungs nen bzgl. Art, Dauer, Dosierung etc. noch genauer beschreiben

-> Outcome: Schmerzintensität, gemessen mit der Visuellen Analog Skala (Visuelle Analogskala (VAS)).

Außerdem wollen die Forschenden sozio demografische Daten erheben. Dazu zählen in diesem Fall das Alter, das Geschlecht, die durchschnittliche Schmerzintensität und die Dauer der Symptome.

-> Time: zeitlicher Rahmen der Untersuchung (umfasst alle Messzeitpunkte im Interven tions und

Follow-up-Zeitraum). Die ver schiedenen Trainingsprogramme führen die Teilnehmenden über einen Zeitraum von sechs Wochen durch. Die Follow up Untersuchung soll nach drei Monaten statt finden.

Wissenschaftliche Untersuchungen stützen sich auf Stichprobendaten, da es nicht möglich ist, die Gesamtheit der Individuen zu untersuchen.

Studienprotokoll

Im Studienprotokoll müssen Forschende vorab ihr genaues Vorgehen anführen und präzisieren. Es ist ein wichtiger Bestandteil wissenschaft licher Untersuchungen, da es die Grundlage für die Genehmigung des Forschungsvorhabens durch die jeweilige Ethikkommission bildet. Außerdem stellt es sicher, dass die Studie für andere Forschungs gruppen wiederholbar ist.

Bauplan

Unterschied oder Zusammenhang

Je nach Forschungsidee unterscheidet man zwischen Unterschieds oder Zusammenhangshypothesen. Wird der Effekt von Dehnen im Vergleich zu Manueller Therapie auf die Beweglichkeit der Hüfte untersucht, ist es einerseits möglich, Unterschiede zu untersuchen, die zwischen den Gruppen "Dehnen" und "Manuelle Therapie" bestehen. Andererseits kann man auch den Zusammenhang zwischen z. B. Dehnen und der Beweglichkeit der Hüfte aufdecken.

Hypothesenarten

Seite 3

Anhand des PICOT Schemas formulieren die Forschenden nun die Forschungsfrage (FF), für deren Beantwortung sie zwei statistische Hypothesen aufstellen:

-> H0: Es besteht nach der Intervention kein Unterschied zwischen einem gezielten Training der Rotatorenmanschette und einem gezielten Kräftigungsprogramm der SchulterNacken Muskulatur bezogen auf die Schmerzintensität.

-> H1: Es besteht nach der Intervention ein Unterschied zwischen einem gezielten Training der Rotatorenmanschette und einem gezielten Kräftigungsprogramm der SchulterNacken Muskulatur bezogen auf die Schmerzintensität.

Die erste statistische Hypothese, die aufgestellt wird, ist die sogenannte Nullhypothese (H0). Diese geht von einer Gleichheit zwischen zwei oder mehr untersuchten Gruppen oder Messzeitpunkten aus und es gilt diese durch die Untersuchung zu entkräften. Ihr entgegen steht die Alternativhypothese (H1). Diese nimmt einen Unterschied zwischen den Gruppen bzw. Messzeitpunkten an (HYPOTHE

SENARTEN, S. 11). Das Ziel der Forschenden ist es, zu überprüfen, welche der Hypothesen richtig ist. Die Entscheidung, welche Hypothese angenommen wird, basiert auf der Analyse und der Interpretation der erhobenen Daten. Wissenschaftliche Untersuchungen stützen sich hierbei lediglich auf Stichprobendaten, da es nicht möglich ist, die Gesamtheit der Indivi

den zu untersuchen. Aus diesem Grund erfolgt im Anschluss an die Datenerhebung eine Auswertung und Analyse der Daten, die es ermöglicht, einen Rückschluss von der Stichprobe auf die Grundgesamtheit zu ziehen, wenngleich dadurch eine gewisse Unsicherheit bestehen bleibt.

Richtiges Design wählen -> Um die zuvor formulierte Forschungsfrage adäquat beantworten zu können, gilt es nun Überlegungen zur Wahl des Studiendesigns (TAB. 1) anzustellen – nicht jeder Forschungsgegenstand lässt sich mit jedem Forschungsdesign beantworten. Auch bei der späteren Interpretation der Ergebnisse spielt das Studiendesign eine große Rolle, denn die einzelnen Formen sind unterschiedlich fehler bzw. verzerrungsanfällig (ABB. 3).

Design Eigenschaften Kausalität Vorteile Nachteile
Querschnittstudie Beobachtungsstudie
Generieren von Hypothesen
Ermittlung von Behandlungsbedarf
kein geringer Untersuchungszeitraum:
schnell und einfach durchzuführen
BiasRisiko
reine Zustandserhebung, keine
Information über
Verläufe

Kohortenstudie Beobachtungsstudie
Längsschnittstudie:
retrospektiv oder
prospektiv

Vergleich von Exponierten und Nichtexponierten
Ermittlung von Risikofaktoren
Beschreibung des Krankheitsverlaufs
Bestimmung des Krankheitsrisikos
ja zeitlicher Zusammenhang zwischen
Risikofaktor und Endpunkt
erkennbar

mittleres BiasRisiko
lange Studiendauer

Fall-Kontroll-Studie Beobachtungsstudie

retrospektiv

Fälle stellen Personen mit zu untersuchender
Eigenschaft/Erkrankung dar.

Die Kontrolle stellen die Personen ohne zu
untersuchende Eigenschaft/Erkrankung dar.

nein geringer Zeit und Kostenaufwand

eignet sich für seltene Krankheiten

eignet sich für lange Latenzzeiten

BiasRisiko

Ergebnisse stark von

Kontrollgruppe

abhängig

RCT Interventionsstudie (experimentelle Studie)

(

Längsschnittstudie: prospektiv)

ja geringes BiasRisiko

zeitliche Abfolge ist klar

hoher Kosten und

Planungsaufwand

ethisch nicht immer

vertretbar

TAB. 1 Übersicht über die geläufigsten Studiendesigns [3]

Aus der fiktiven Forschungsfrage geht her

vor, dass es mehrere Messzeitpunkte gibt. Hier

eignet sich ein Forschungsdesign aus der Gat

tung der Längsschnittstudien. Zudem ist er

sichtlich, dass es sich um eine kontrollierte Stu

die handeln soll, bei der es neben der

Interventions auch eine Kontrollgruppe gibt.

Um sicherzustellen, dass die Teilnehmenden

zufällig in die Gruppen eingeteilt werden und

eine bessere Vergleichbarkeit der Gruppen

möglich ist, ist es sinnvoll, eine

Randomisie-

rung vorzunehmen. Zudem möchten die For

schenden mithilfe ihrer Untersuchung die

Effektivität einer Maßnahme evaluieren.

Folglich eignet sich zur Überprüfung der

Forschungsfrage eine

RCT.

Stichprobengröße ermitteln -> Vor Beginn

der Studiendurchführung sollte zusätzlich die

Mindestgröße der Stichprobe bestimmt wer

den. Dazu verwenden Forschende Computer

programme. Zur Berechnung wählen sie einen zur Beantwortung der Forschungsfrage passenden Hypothesentest aus. Zur Berechnung der geeigneten Stichprobengröße müssen sie Parameter etwa zur Effektstärke, zum

Seite 4

Svenja Nilsson und Natalie Pankrath sind Physiotherapeutinnen und absolvieren ihren Master in „Muskuloskelettale Therapie (OMT)“ an der Hochschule Osnabrück. Ihr Behandlungsschwerpunkt liegt auf neuromuskuloskelettalen Beschwerden und ihr besonderes Interesse gilt den quantitativen Methoden in der Physiotherapie.

Autorinnen

Typ-1-Fehler, zur statistischen Power oder zum Verhältnis der Gruppengrößen angeben. Bevor die Erhebung der Daten losgehen kann, legen sie Outcomes und geeignete Messinstrumente fest. Das primäre Outcome stellt die Zielvariable dar, die es vorrangig zu erfassen gilt. Alle weiteren Outcome Parameter bezeichnet man als sekundäre Outcomes. Bei der fiktiven RCT mit der Forschungsfrage: „Hat ein gezieltes Training der Rotatorenmanschette bei Patient*innen mit ventralen Schulter Schmerzen einen Einfluss auf die Schmerzintensität im Vergleich zu einem konventionellen Trainingsprogramm des SchulterNackenBereiches?“ lässt sich als primäres Outcome der Unterschied der Schmerzintensität nach der Intervention in den beiden Gruppen definieren. Sekundäre Outcomes könnten in diesem Falle beispielsweise der Grad der Beeinträchtigung oder das Bewegungsausmaß sein. Messen, was man messen will -> Bei der Auswahl der Messinstrumente ist es wichtig, dass diese bestimmte Gütekriterien erfüllen. Dadurch ist sichergestellt, dass sich das entsprechende Outcome reliabel und valide messen lässt (Reliabilität, Validität). Bei unserem Fallbeispiel wird das primäre Outcome Schmerzintensität mit der Visuellen Analog

Skala (VAS) gemessen. Es gibt immer mindestens einen Zeitpunkt, an dem man Messungen durchführt, um die Stichprobe zu beschreiben. Zu diesem Zeitpunkt erhebt man auch soziodemografische und klinische Daten wie das Alter, das Geschlecht und die Dauer der Symptome. Bei Längsschnittstudien gibt es zusätzlich mindestens einen weiteren Messzeitpunkt, wie auch bei der Beispielstudie. Neben den Messzeitpunkten, die innerhalb des Untersuchungszeitraums stattfinden, kann man weitere außerhalb dieses Zeitraums als sogenanntes

Follow-up definieren. Die nachträglichen Untersuchungen geben Aufschluss darüber, wie sich die Ergebnisse nach dem Abschluss der Intervention verhalten.

Wie die Erhebung und Auswertung der Daten funktionieren und worauf es bei der Interpretation zu achten gilt, lesen Sie in der nächsten Ausgabe von physiopraxis.

Svenja Nilsson und Natalie Pankrath

Literaturverzeichnis

praxis > „Ausgabe 10/21“

ABB. 2 Empirischer Forschungsprozess

ABB. 3 hierarchische Anordnung von Interventionsstudien hinsichtlich der Evidenzlevel nach dem Oxford Centre for Evidence Based Medicine [4]

ABB. 1 Ausgehend von einer

Forschungshypothese

lässt sich zum einen untersuchen, ob diese

im Einzelfall gilt

(Deduktion), während

zeitgleich die Idee ist,

von diesem Einzelfall

einen Rückschluss auf

die Grundgesamtheit

zu ziehen (Induktion).

Theorie

Empirie

Deduktion Induktion

theoretischer Hintergrund

Forschungsfrage

Hypothesenbildung: H0, H1

Methodik:

Erheben von Daten

Auswerten von Daten

Deutung der Ergebnisse

1. Sys

tematisches

Review randomi

sierter kontrollierter

Studien

2. Randomisierte

kontrollierte Studie

3. Nicht randomisierte kontrol

lierte Kohorten/FollowupStudie

4. Fallserien, FallKontrollStudien

5. Expertenkonsens

Teil 2 — Zufall oder nicht

Physiopraxis Teil2 Zufall oder nicht

Quelle: physiopraxis (Thieme), Hochschule Osnabrück.

Seite 1

Im ersten Artikelteil in der physiopraxis-Ausgabe 10/21 ging es unter anderem darum, wie das Grundgerüst eines empirischen Forschungsprozesses aufgebaut ist und wie man ausgehend von einer Literaturrecherche eine Forschungsfrage formuliert. Nachdem die Hypothesen, das Studiendesign sowie die Studienpopulation festgelegt sind, gilt es im nächsten Schritt Daten zu erheben. Diese Daten beschreiben erst einmal nur die Stichprobe. Ob die gemessenen Ergebnisse auch auf die Grundgesamtheit übertragbar sind, muss mittels spezieller Testverfahren der induktiven Statistik überprüft werden. Dazu nutzen Forschende spezielle Statistikprogramme, wie z. B. IBM SPSS Statistics. Skalenniveau bestimmt Darstellungsform
-> Nach der Durchführung der Datenerhebung findet die Analyse der Daten statt. Der erste Schritt umfasst die deskriptive Analyse/
Zufall oder nicht

Teil 2: Empirische Forschung in der Physiotherapie Mit statistischen Verfahren lässt sich beispielsweise berechnen, ob eine Intervention einer anderen überlegen ist. Warum es nie eine hundert prozentige Sicherheit gibt und was man tun kann, um die Irrtumswahrscheinlichkeit möglichst klein zu halten, erläutert der zweite Teil des Artikels.

deskriptive Statistik . Diese verfolgt das Ziel, die Merkmale der untersuchten Stichprobe in grafischer oder tabellarischer Form darzustellen und zusammenzufassen. Hierbei erhält man jedoch lediglich Informationen über die Stichprobe und zieht noch keine Schlüsse auf die Grundgesamtheit. Für die Darstellung der gewonnenen Daten ist es wichtig, das Skalenniveau (Datenskalierung) der einzelnen Variablen zu kennen. Welche grafische Darstellung typischerweise ausgewählt wird, ist abhängig vom Skalenniveau der Verteilung der Variablen (TAB. 1, S.18).

Im folgenden Studienbeispiel wollen die Forschenden mithilfe einer randomisierten kontrollierten Studie herausfinden, ob ein gezieltes Training der Rotatorenmanschette bei Patient*innen mit ventralen Schulterschmerzen einen Einfluss auf die Schmerzintensität im Vergleich zu einem konventionellen Trainingsprogramm des Schulter-Nacken-Bereiches hat. Vor der Beantwortung ihrer Forschungsfrage ist es wichtig, herauszufinden, ob die Studienteilnehmenden der einzelnen Gruppen (spezielles Training vs. konventionelles Training) bezüglich der erhobenen Variablen (Alter, Geschlecht, Schmerzintensität präinterventiv) ähnlich sind, um eine Vergleichbarkeit der Gruppen vor der Intervention sicherzustellen. Bei Alter und Schmerz handelt es sich um metrisch skalierte Variablen. Demnach eignet sich zur Beschreibung der Stichprobeneigenschaften der Mittelwert als zentrales Lagemaß in Kombination mit der Standardabweichung als Streuungsmaß. Der Mittelwert als Lagemaß beschreibt den durchschnittlichen Wert innerhalb der Stichprobendaten, in diesem Fall das durchschnittliche Alter bzw. die durchschnittliche Schmerzintensität.

Die Standardabweichung ist die durchschnittliche Abweichung vom Mittelwert und beschreibt somit die Streuung der Daten um den Mittelwert. Als grafische Darstellung könnte man hierzu beispielsweise ein Balkendiagramm oder aber auch einen Boxplot verwenden. Nutzt man Boxplots zur Darstellung, ist allerdings zu beachten, dass hier der Median als zentrales Lagemaß abgebildet wird. Die nominal skalierte Variable Geschlecht lässt sich lediglich in Häufigkeiten angeben, zum Beispiel in Form von prozentualen Angaben oder absoluten Werten. Diese sind beispielsweise als Tortendiagramm darstellbar. Bei der deskriptiven Analyse unterscheidet man zwischen univariater, bivariater und multivariater deskriptiver Statistik. Zunächst erfolgt, wie oben beschrieben, die univariate Auswertung, in der einzelne Variablen hinsichtlich bestimmter Lage- bzw. Streuungsparameter beschrieben werden. Zudem kann eine bivariate deskriptive Analyse durchgeführt werden, z.B. durch die Berechnung einer Risk Ratio, Odds Ratio oder Korrelation, mit der man einen Zusammenhang zwischen Begriffen der Forschungsmethodik

zwei Variablen darstellen kann. Auch Vergleiche zwischen zwei Gruppen, beispielsweise in Form von Mittelwertsdifferenzen, zählen zu einer bivariaten deskriptiven Analyse. Multivariate deskriptive Verfahren sind hilfreich, wenn mehr als zwei Variablen untersucht werden. Mehrere Faktoren bestimmen Testauswahl -> Um von den Ergebnissen der Stichprobe einen Rückschluss auf die Grundgesamtheit ziehen zu können, verwendet man induktive Testverfahren bzw. sogenannte Hypothesentests, welche man zunächst abhängig von der Formulierung der Forschungsfrage (FF) und der Datenskalisierung auswählt. Die Wahl des statistischen Tests hängt von mehreren Faktoren ab. Zunächst gilt es zu überprüfen, ob die Forschungsfrage Zusammenhänge oder

Unterschiede untersucht. Dabei ist wichtig zu differenzieren, ob Unterschiede zwischen Gruppen (unabhängige Stichprobe) oder innerhalb einer Gruppe (abhängige Stichprobe) analysiert werden sollen. Ausschlaggebend für die Anwendung der Hypothesentests ist außerdem die Anzahl der zu vergleichenden Gruppen. Ob ihre Ergebnisse auch auf die Grundgesamtheit übertragbar sind, müssen Forschende mittels spezieller statistischer Testverfahren überprüfen.

Nicht zuletzt muss man beachten, dass es für die einzelnen Hypothesentests noch weitere Annahmen geben kann, die für eine Anwendung des Tests erfüllt sein müssen.

Zur Beantwortung der fiktiven Forschungsfrage „Hat ein gezieltes Training der Rotatorenmanschette bei Patient*innen mit ventralen Schulterschmerzen einen Einfluss auf die Schmerzintensität im Vergleich zu einem konventionellen Trainingsprogramm des Schulter-Nacken-Bereiches?“ würde man den Unterschied der Schmerzintensität nach der Intervention in den beiden Gruppen betrachten. Da es sich bei der abhängigen Variable um die Schmerzintensität handelt, die mit der visuellen Analogskala (VAS) in Millimetern gemessen wird, müsste man einen Test auswählen, der für metrisch skalierte Variablen geeignet ist.

Da der Einfluss einer Intervention untersucht werden soll, die nur die Interventionsgruppe erhält, wird vermutet, dass sich die Schmerzintensität nach der Intervention in den beiden Gruppen voneinander unterscheiden wird. Das bedeutet, dass der Test weiterhin fähig sein muss, Unterschiede zwischen zwei unabhängigen Gruppen aufzudecken. Auf Basis dieser Überlegungen fällt die Wahl auf den t-Test für unabhängige Stichproben. Hierbei muss man jedoch beachten, dass die Durchführung dieses Testes abhängig von diversen Annahmen ist, die erfüllt sein müssen. Dazu zählen, wie oben beschrieben, die Unabhängigkeit der Messungen und die metrische Datenskalisierung. Weiterhin muss die abhängige Variable normalverteilt sein und es sollte

eine Homogenität der Varianzen vorliegen [1]. Die Bedeutung und Überprüfung dieser Annahmen erläutert der Artikel jedoch nicht weiter. Tabelle 2 gibt eine Übersicht, welchen Hypothesentest man beim Vergleich von zwei Gruppen verwendet (TAB. 2, S.19). Signifikanzlevel bietet Orientierung -> Unabhängig von dem gewählten Testverfahren sind die Ergebnisse eines Hypothesentests der p-Wert (Signifikanzwahrscheinlichkeit) und das Konfidenzintervall. Auf Basis dieser Werte treffen Forschende die Entscheidung für die entsprechende Hypothese. Die Interpretation des p-Werts orientiert sich

Seite 3

dabei an dem Signifikanzlevel bzw. am α -Level. Dieses liegt klassischerweise bei fünf Prozent bzw. 0,05. Wenn man davon ausgeht, dass das alpha-Level bei 0,05 (5%) liegt, dann würde man sich bei einem p-Wert der

= 0,05 ist, für die Annahme der H_0 -Hypothese entscheiden (es besteht nach der Intervention kein Unterschied zwischen einem gezielten Training der Rotatorenmanschette und einem konventionellen Kräftigungsprogramm der Schulter-Nacken-Muskulatur bezogen auf die Schmerzintensität). Nimmt der p-Wert einen Wert von $< 0,05$ an, würde die H_1 -Hypothese gemäß dem festgelegten α -Level angenommen werden (es besteht nach der Intervention ein Unterschied zwischen einem gezielten Training der Rotatorenmanschette und einem gezielten Kräftigungsprogramm der Schulter-Nacken-Muskulatur bezogen auf die Schmerzintensität).

Restunsicherheit bleibt -> Da lediglich eine Stichprobe der Gesamtpopulation untersucht werden kann, unterliegt die Entscheidung für die Annahme einer Hypothese immer einer gewissen Unsicherheit. Es ist also möglich, dass während dieses Entscheidungsprozesses der Typ-1- oder Typ-2-Fehler auftritt. Das heißt, dass es möglich ist, dass die Entscheidung fälschlicherweise auf eine Hypothese fällt, obwohl die konkurrierende Hypothese in

der Grundgesamtheit gültig ist. Bei einem im Vorfeld festgelegten α -Level von fünf Prozent bedeutet dies, dass die Wahrscheinlichkeit, sich für die H1-Hypothese zu entscheiden, obwohl die H0-Hypothese in der Grundgesamtheit gültig ist, höchstens fünf Prozent beträgt. Dies stellt den Typ-1-Fehler dar. Im Gegensatz dazu liegt der Typ-2-Fehler vor, wenn sich aufgrund des p-Wertes für die H0-Hypothese entschieden wird, obwohl in der Grundgesamtheit H1 gültig ist. Im Vergleich zu dem Typ-1-Fehler lässt sich der Typ-2-Fehler deutlich schwieriger, zum Teil sogar gar nicht berechnen. Eine Möglichkeit, um den Typ-2-Fehler gering zu halten, ist es, die statistische Power eines Testes zu erhöhen.

Wahren Wert eingrenzen -> Wenn man Gruppenunterschiede in Form von Mittelwertsdifferenzen untersucht, ist das Konfidenzintervall ein Parameter, der die Präzision der Schätzung der Mittelwertdifferenz angibt. Es drückt aus, dass sich der wahre Wert der Grundgesamtheit mit einer bestimmten Wahrscheinlichkeit in einem Wertebereich befindet, der durch einen oberen und einen unteren Wert begrenzt ist. In der Regel berechnet man dazu das 95 %-Konfidenzintervall. Zusätzlich lässt sich anhand des Konfidenzintervalls ablesen, ob das Ergebnis eines Hypothesentests signifikant ist oder nicht. Wenn die Grenzen des Konfidenzintervalls den Wert „0“ einschließen, bedeutet dies, dass es keine statistisch signifikante Mittelwertdifferenz gibt und somit kein statistisch bedeutsamer Gruppenunterschied vorliegt.

Lage- und Streuungsparameter nominal

= / $\neq$ z.B.

Geschlecht

ordinal

= / $\neq$, < / >

z.B. Likert-Skala

metrisch

= / $\neq$, < / >, + / - , x / :

z.B. Alter

grafische

Darstellung

Häufigkeiten x x x Histogramm

Kreisdiagramm

Tabellen

Median x x Boxplot

Quantile x x

Minimum u. Maximum x x

Mittelwert x Balkendiagramm

Standardabweichung x

TAB. 1 Lage- und Streuungsparameter und deren Darstellungsformen in Abhängigkeit vom Skalenniveau [1]

Weiterführende Literatur

-> Andy Field (2017): Discovering Statistics

Using IBM SPSS Statistics. Sage Publications, Newbury Park

-> Axel Schäfer, Thomas Schöttker-Königer

(2015): Statistik und quantitative

Methoden für Gesundheitsfachberufe.

Springer-Verlag, Berlin Heidelberg

-> Jürgen Bortz, Christof Schuster (2010):

Statistik für Human- und Sozialwissen-

schaftler. Springer-Verlag, Berlin Heidelberg

-> Nicola Döring, Jürgen Bortz (2016):

Forschungsmethoden und Evaluation.

Springer-Verlag, Heidelberg

Wissen vertiefen

Seite 4

Svenja Nilsson und Natalie Pankrath sind Physiotherapeutinnen und absolvieren ihren Master in „Muskuloskelettale Therapie (OMT)“ an der Hochschule Osnabrück. Ihr Behandlungsschwerpunkt liegt auf neuromuskuloskelettalen Beschwerden und ihr besonderes Interesse gilt den quantitativen Methoden in der Physiotherapie. Autorinnen

Der p-Wert und das Konfidenzintervall sind als Parameter der induktiven Statistik also Maße, die den Rückschluss von der Stichprobe auf die Grundgesamtheit erlauben, wenn - gleich immer eine gewisse Unsicherheit vorliegt. Mithilfe des p-Werts kann man also bestimmen, wie stark die Evidenz gegen die Nullhypothese ist.

Ergebnisse interpretieren -> Tabelle 3 bildet die Resultate der Datenanalyse des fiktiven RCT ab. In den Zeilen der Tabelle sind die erhobenen Variablen und in den Spalten die Interventions- und die Kontrollgruppe sowie ein gesamter Wert („Total“) und der p-Wert

abzulesen (TAB. 3). Exemplarisch für die deskriptive Statistik liegt das durchschnittliche Alter der Teilnehmenden in der Interventionsgruppe bei 29,4 Jahren. Die durchschnittliche Abweichung vom Mittelwert (Standardabweichung, SD) beträgt 6,6 Jahre. In der Kontrollgruppe liegt der Altersmittelwert bei 28,7 Jahren mit einer SD von 7,3 Jahren. Es befinden sich 26 Männer und 25 Frauen in der Interventionsgruppe. In der Kontrollgruppe beläuft sich die Anzahl der Männer und Frauen auf jeweils n=25. Bei der Betrachtung der deskriptiven Statistik ist zu berücksichtigen, dass diese nur TAB. 2 Übersicht über die Hypothesentests je nach Datenskalisierung [2]

TAB. 3 Ergebnisse der fiktiven RCT

Outcomes gezielte

Kräftigung

Rotatorenman-
schette (n=50)

konventionelle

Kräftigung

Schulter-Nacken-

Bereich (n=50)

Total (n=100) p-Wert

Alter 29,4 (6,6) 28,7 (7,3) 29,1 (6,9) 0,684

Geschlecht (m/w) n=26/n=25 n=25/n=25 n=51/n=49 1,0

Schmerzintensität

(VAS Baseline)

4,9 (1,9) 4,9 (2) 4,86 (2) 0,686

Schmerzintensität

(VAS post-

Intervention)

2,4 (1,2) 4,2 (1,5) 3,3 (1,6) $\leq 0,0001^*$

Skalenniveau abhängige Gruppen unabhängige Gruppen

nominal McNemar-Test Chi²-Test

ordinal Wilcoxon-Test Mann-Whitney-U-Test

metrisch t-Test für abhängige SP t-Test für unabhängige SP

abhängige Gruppen unabhängige Gruppen

als Übersicht für die Beschreibung der einzelnen

Gruppen- bzw. Stichprobenparameter dient

und man keine Aussage darüber treffen kann,

ob sich die Gruppen hinsichtlich der erhobenen

Variablen (hier: Alter, Geschlecht, VAS Baseline,

VAS post-Intervention) statistisch signifikant

voneinander unterscheiden. Dazu wird die de-

skriptive Statistik hier bereits um den p-Wert ergänzt. Er soll zeigen, ob die Gruppen hinsichtlich der erhobenen Variablen homogen sind. Für die Variable Alter wurde ein p-Wert von 0,684 ermittelt. Das bedeutet, dass sich die Teilnehmenden in der Interventions- und der Kontrollgruppe bezogen auf das Alter nicht signifikant voneinander unterscheiden. Somit ist davon auszugehen, dass die zu vergleichenden Gruppen ähnlich sind und der Randomisierungsprozess erfolgreich war.

Zufall oder nicht -> Betrachtet man die Mittelwerte der Schmerzintensität zum Messzeitpunkt „VAS post-Intervention“, ist zu erkennen, dass sich die untersuchten Gruppen um ungefähr zwei Punkte auf der VAS unterscheiden. Mithilfe des t-Tests für unabhängige Stichproben soll nun geprüft werden, ob dieser beobachtete Unterschied zwischen der Interventions- und der Kontrollgruppe statistisch signifikant ist. Das bedeutet in diesem Zusammenhang, dass überprüft wird, ob der beobachtete Unterschied nur durch Zufall entstanden ist oder ob er sich dieser auf die Art der Intervention zurückführen lässt. In der fiktiven RCT liefert der t-Test einen p-Wert von $p \leq 0,001$. Da der p-Wert in diesem Fall kleiner als 0,05 ist, ist der Unterschied zwischen der Interventions- und der Kontrollgruppe hinsichtlich der Schmerzintensität nach der Intervention statistisch signifikant. Die Wahrscheinlichkeit, sich fälschlicherweise für die Alternativhypothese entschieden zu haben, obwohl in der Grundgesamtheit die Nullhypothese gilt, liegt also bei weniger als 0,1 %. Die statistische Signifikanz ist zudem in den Werten des Konfidenzintervalls (KI) ersichtlich. Die untere Grenze des KI liegt bei 1,25 und die obere Grenze bei 2,35. Der nicht enthaltene Wert von „0“ impliziert, dass ein signifikanter Unterschied vorliegt. Die Ergebnisse des t-Tests für unabhängige Stichproben (p-Wert) zeigen also eine starke Evidenz gegen die H_0 , sodass in diesem Fall die Entscheidung auf die H_1 fällt. Diese Vorgehensweise lässt sich auf

sämtliche Hypothesentests übertragen. Die Interpretation des p-Werts und des KI sind für jeden Test gleich. Einschränkend ist zu sagen, dass reale Forschungsprojekte größere Datenmengen untersuchen und es neben der RCT noch weitere Studiendesigns gibt, die andere Auswertungsstrategien verfolgen.

Svenja Nilsson und Natalie Pankrath

Literaturverzeichnis

praxis > „Ausgabe 11-12/21“